

Ciencia de Datos para Economía y Negocios - FCE-UBA

Clase 6 — Qué esconde un promedio: ponderación, agregación y distribuciones

Nicolás Sidicaro

Apertura

¿Cuánto gana en promedio un argentino?

Es una pregunta que parece tener una respuesta.

Antes de contestar, hay cuatro decisiones escondidas

- ❶ **Población de referencia.** ¿Todos? ¿Los ocupados? ¿Los perceptores de ingreso? ¿Los mayores de 14?
- ❷ **Ponderación.** ¿Cada persona de la muestra vale uno, o vale lo que representa?
- ❸ **Nivel de agregación.** ¿Personas, hogares, aglomerados, provincias?
- ❹ **Momento de la distribución.** ¿Media, mediana, un decil, la distribución entera?

Corolario de la clase

Cambiar cualquiera de esas cuatro decisiones cambia el número. A veces cambia el **signo** de la conclusión.

Hoja de ruta

- 1 Apertura
- 2 Repaso: tendencia central y dispersión
- 3 Estadísticas ponderadas
- 4 Paradoja de Simpson
- 5 Falacia ecológica
- 6 Comparar distribuciones completas
- 7 Análisis por cuantiles
- 8 Cierre

Todos los datos de esta clase salen de la **EPH, primer trimestre de 2026** (INDEC), descargada con el paquete eph. Son 43.739 personas relevadas en 32 aglomerados urbanos, que representan a 30,1 millones de habitantes.

Repaso: tendencia central y dispersión

Los tres centros

Definiciones

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (\text{media})$$

$$Me = x_{(k)} \text{ tal que } F(x_{(k)}) = 0,5 \quad (\text{mediana})$$

$$Mo = \arg \max_x f(x) \quad (\text{moda})$$

Qué responde cada uno

- **Media:** si repartiéramos el total en partes iguales, ¿cuánto toca?
- **Mediana:** ¿cuánto gana el que está justo en el medio de la fila?
- **Moda:** ¿cuál es el valor más frecuente?

Punto clave

Solo coinciden si la distribución es **simétrica**. Los ingresos nunca lo son.

Las medidas de dispersión

Escala absoluta

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad s = \sqrt{s^2}$$

$$IQR = Q_3 - Q_1$$

Escala relativa

$$CV = \frac{s}{\bar{x}}$$

Adimensional: permite comparar la dispersión de variables medidas en **unidades distintas**.


Cuál usar

- s hereda la sensibilidad de la media a los valores extremos: se calcula *sobre* $\bar{x}$.
- IQR es robusto: solo mira el 50% central de los datos.
- CV es el único de los tres que se puede comparar entre variables de distinta escala.

Asimetría: por qué en ingresos $\text{media} > \text{mediana}$

Ingreso de la ocupación principal, ocupados (EPH 1T 2026)

Ponderado por PONDIIO. Recortado en el percentil 99 para poder verlo.



Media = \$ 1.104.227 | Mediana = \$ 900.000 | La media está 22,7% por encima de la mediana.

Qué implica reportar una u otra

La cola derecha manda sobre la media, no sobre la mediana

La media es un **promedio del total**: si el 1% más rico gana el doble, la media sube. La mediana es una **posición**: solo cambia si se mueve la persona del medio.


Escenario	Media	Mediana	CV
Original	1.278.434	809.375	1,19
1% superior x 2	1.384.383	809.375	1,73
1% superior x 5	1.702.227	809.375	3,25

Simulación lognormal ($n = 20.000$). Al inflar **solo el 1% superior**, la media se dispara y el CV explota. La mediana **no se mueve ni un peso**.

El CV como comparador entre escalas

Coeficiente de variación, EPH 1T 2026

Todas ponderadas. Pesos, horas y años no se pueden comparar; sus CV sí.



La edad es una variable **compacta** (CV bajo); el ingreso individual es **enormemente disperso**. Comparar un desvío de \$ 1.063.114 con un desvío de 16,4 horas semanales no significa nada; comparar un CV de 0,96 con uno de 0,45 sí.

Estadísticas ponderadas

¿Por qué existe el ponderador?

La EPH no es una muestra aleatoria simple

El diseño es **polietápico, estratificado y por conglomerados**:

- 1 Se estratifican los aglomerados por características socioeconómicas.
- 2 Dentro de cada estrato se sortean **radios censales** (conglomerados).
- 3 Dentro de cada radio se sortean **viviendas**.

Consecuencia

Las **probabilidades de selección son desiguales**. Un hogar de un aglomerado chico tiene mucha más chance de entrar a la muestra que uno del Gran Buenos Aires. Si tratáramos a todos por igual, sobre-representaríamos a las ciudades chicas.

El ponderador hace dos cosas

- **Corrige la probabilidad de selección**: $w_i \approx 1/\pi_i$, donde π_i es la probabilidad de que la unidad i entre en la muestra.
- **Calibra** el total muestral contra las **proyecciones poblacionales** del INDEC (por sexo y grupo de edad), y ajusta por no respuesta.

Los ponderadores no son todos iguales

Distribución de PONDERA, EPH 1T 2026

Cada observación representa entre 23 y 8.983 personas (mediana: 340)



Los cuatro ponderadores de la EPH

Variable	Unidad de análisis	Cuándo usarlo
PONDERA	Personas / hogares	Conteos y proporciones no monetarias : tasas de actividad, empleo, desocupación, nivel educativo, composición demográfica.
PONDIH	Hogares	Ingresos del hogar : ITF, IPCF, deciles de ingreso per cápita familiar.
PONDII	Personas	Ingreso individual total : P47T (laboral y no laboral).
PONDIIIO	Personas ocupadas	Ingreso de la ocupación principal : P21.

Regla práctica

El ponderador se elige por la **variable que se está promediando**, no por la base que se abrió. Los ponderadores de ingreso corrigen además por la **no respuesta de ingresos**, que no es aleatoria: los hogares de ingresos altos responden menos.

Las fórmulas ponderadas

Media y proporción

$$\bar{x}_w = \frac{\sum_{i=1}^n w_i x_i}{\sum_{i=1}^n w_i}$$

$$\hat{p}_w = \frac{\sum_{i=1}^n w_i \mathbf{1}(x_i \in A)}{\sum_{i=1}^n w_i}$$

La proporción es la media de una variable binaria.

Cuantil ponderado

Ordenamos $x_{(1)} \leq \dots \leq x_{(n)}$ y definimos la acumulada de pesos

$$F_w(x_{(k)}) = \frac{\sum_{j \leq k} w_j}{\sum_{j=1}^n w_j}$$

El cuantil q_p es el menor $x_{(k)}$ tal que $F_w(x_{(k)}) \geq p$.

Varianza ponderada

$$s_w^2 = \frac{\sum_{i=1}^n w_i (x_i - \bar{x}_w)^2}{\sum_{i=1}^n w_i - 1}$$

En R: `weighted.mean()` viene en base; para lo demás, `Hmisc` o `survey`.

Caso I: la tasa de desocupación

Cálculo	Tasa de desocupación
Sin ponderar (media simple)	6,78%
Ponderado por PONDERA	7,83%

La brecha es de 1,05 puntos porcentuales

Sobre una base de 20.996 personas económicamente activas, ignorar el ponderador **subestima** la desocupación en un 15,5% en términos relativos.

La diferencia no es un error de redondeo ni ruido muestral: es **sistemática**. Los aglomerados con mayor desocupación están sub-representados en el conteo crudo de casos, porque cada uno de sus habitantes “vale” más en el diseño.

Caso II: los ingresos

Variable	Ponderador	Media simple	Media ponderada	Brecha
Ingreso ocup. principal (P21)	PONDIIO	\$ 990.201	\$ 1.104.227	11,5%
Ingreso individual total (P47T)	PONDII	\$ 1.021.995	\$ 1.153.457	12,9%
Ingreso total familiar (ITF)	PONDIH	\$ 1.858.776	\$ 2.158.772	16,1%

Qué está pasando

En los tres casos la media ponderada es **mayor**. Las personas de los grandes aglomerados, donde los ingresos nominales son más altos, están sub-representadas en el conteo crudo de casos. El ponderador les devuelve su peso poblacional.

Consecuencia práctica

Un trabajo que reporte \$ 990.201 en lugar de \$ 1.104.227 no tiene un error de cálculo: tiene un error **conceptual**. Está describiendo la muestra, no el país.

Los errores estándar también cambian

El problema

El ponderador arregla la **estimación puntual**, pero la fórmula habitual del error estándar

$$SE(\hat{p}) = \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$

supone **muestreo aleatorio simple**. Bajo un diseño complejo, ese SE queda **subestimado**.

Supuesto	Tasa de desocupación	Error estándar
Muestreo aleatorio simple	6,78%	0,173%
Ponderado (pesos desiguales)	7,83%	0,315%

El intervalo de confianza construido con el SE equivocado es casi la mitad de ancho de lo que debería. Es decir: se reporta **más precisión de la que hay**.

Cómo se hace bien: el paquete survey

La idea

Se declara el diseño una sola vez y todos los estimadores lo respetan: valor puntual, error estándar e intervalo de confianza.

Paso	Función
Declarar el diseño	<code>svydesign(ids, strata, weights, data)</code>
Media y total	<code>svymean()</code> , <code>svytotal()</code>
Cuantiles	<code>svyquantile()</code>
Cortes por subgrupo	<code>svyby()</code> , <code>svytable()</code>
Efecto diseño	<code>svymean(..., deff = TRUE)</code>

Límite de los datos públicos

La base de usuario de la EPH **no publica los identificadores de estrato y conglomerado**. Con los datos públicos se corrige por pesos, pero no se reproducen exactamente los *SE* oficiales.

La ponderación está en todos lados

Índices de precios

El IPC no es el promedio simple de las variaciones de precios:

$$\pi_t = \sum_j \omega_j \frac{p_{jt}}{p_{j,t-1}}$$

donde ω_j es la **participación del bien j en el gasto** de los hogares, estimada con la ENGHo. El pan pesa más que el caviar.

Promedios entre territorios

El "salario medio de las provincias argentinas" no es el promedio simple de 24 números:

$$\bar{s} = \frac{\sum_k N_k \bar{s}_k}{\sum_k N_k}$$

Sin ponderar por población N_k , Tierra del Fuego pesa lo mismo que la Provincia de Buenos Aires.

El patrón común

Siempre que se resume un conjunto de **unidades heterogéneas en tamaño**, hay un ponderador implícito. Si no lo elegís vos, lo estás eligiendo igual: estás eligiendo $w_i = 1$.

Paradoja de Simpson

Definición formal

La paradoja

Sea una asociación entre X e Y medida en cada estrato g de una variable Z . Hay paradoja de Simpson cuando el signo (o el orden) de la asociación **agregada** contradice al que se observa **dentro de todos los estratos**:

$$\text{sig}(\text{Assoc}(X, Y)) \neq \text{sig}(\text{Assoc}(X, Y \mid Z = g)) \quad \forall g$$

Condición de aparición

No es un accidente aritmético raro. Aparece cuando existe una variable Z que cumple **las dos cosas a la vez**:


- 1 Z está **correlacionada con** X (los grupos que comparamos tienen composiciones distintas en Z).
- 2 Z **afecta a** Y (los estratos de Z tienen niveles distintos del resultado).

Esa Z es un **confundidor**.

La versión continua, en un gráfico

Misma nube de puntos, dos conclusiones opuestas

Líneas de color: relación dentro de cada grupo. Línea negra punteada: relación agregada.



Dentro de cada grupo la relación es **negativa**. Agregando los dos grupos, es **positiva**. La variable “grupo” está correlacionada con X (el grupo B tiene X más alta) y con Y (el grupo B tiene Y más alta).

Berkeley, 1973

La denuncia

En el otoño de 1973, la Universidad de California en Berkeley admitió al 44% de los varones que se postularon al posgrado y al 35% de las mujeres. Nueve puntos de brecha sobre más de 12.000 postulantes: parecía discriminación sistemática.

Departamento	Postulantes V	Admisión V	Postulantes M	Admisión M
A	825	62%	108	82%
B	560	63%	25	68%
C	325	37%	593	34%
D	417	33%	375	35%
E	191	28%	393	24%
F	373	6%	341	7%
Total	2.691	44%	1.835	35%

Fuente: Bickel, Hammel y O'Connell (1975), *Science*. En cuatro de los seis departamentos la tasa de admisión de mujeres era **mayor**.

Por qué se invertía el resultado

El confundidor: el departamento al que se postulaban

- Los departamentos A y B eran **poco selectivos** (admitían más del 60%) y recibían casi solo postulaciones de varones.
- Los departamentos E y F eran **muy selectivos** (admitían menos del 30%) y recibían mayoría de postulaciones de mujeres.

Las dos condiciones se cumplen

El departamento está correlacionado con el sexo del postulante (**composición**) y determina la tasa de admisión (**resultado**). Eso alcanza para invertir el agregado.

Pero...

Al desagregar no llegamos al fondo de la cuestión necesariamente, solo que entendemos un poco más el problema y nos hace repensar la pregunta de investigación.

Brecha de género en Argentina

Dos formas de medir lo mismo, EPH 1T 2026

- Brecha en el ingreso **mensual** de la ocupación principal: **28,6%**.
- Brecha en el ingreso **por hora trabajada**: **8,2%**.

La mayor parte de la brecha mensual es una brecha de **horas**: las mujeres ocupadas trabajan en promedio 31,7 horas semanales contra 39,8 de los varones.

Pero acá empieza el problema


Ese 8,2% es la brecha horaria **agregada**. Veamos qué pasa cuando la abrimos por nivel educativo.

$$\text{Ingreso horario} = P21 / (PP3E_TOT \times 4,33).$$
 Ponderado por PONDII0. Ocupados con ingreso y horas declaradas ($n = 14.174$).

La brecha agregada esconde brechas mayores

Ingreso horario medio por nivel educativo, EPH 1T 2026

La brecha agregada es MENOR que la brecha dentro de cada uno de los tres niveles



El confundidor, otra vez: la composición

Nivel educativo	Mujeres	Varones
Hasta sec. incompleto	23,5%	34,5%
Secundario completo	47,4%	46,8%
Superior completo	29,1%	18,7%

Composición de los ocupados por nivel educativo, dentro de cada sexo.

Las dos condiciones

- 1 El nivel educativo está **correlacionado con el sexo**: entre los ocupados, 29,1% de las mujeres tiene superior completo contra 18,7% de los varones.
- 2 El nivel educativo **determina el salario**: \$ 5.541 por hora en el nivel más bajo contra \$ 11.966 en el más alto.

La mecánica

Las ocupadas están **más educadas** que los ocupados. Esa ventaja de composición **compensa** parte de la desventaja salarial y hace que la brecha agregada (8,2%) sea menor que la de cualquier nivel por separado.

Qué aprendemos de Simpson

La media agregada es una media ponderada de las medias de grupo

$$\bar{y} = \sum_g \underbrace{\pi_g}_{\text{composición}} \cdot \underbrace{\bar{y}_g}_{\text{nivel del grupo}}$$

Un agregado puede moverse por dos razones distintas: porque cambian los $\bar{y}_g$ (efecto **nivel**) o porque cambian los π_g (efecto **composición**). El número solo no distingue cuál de las dos ocurrió.

Consecuencias prácticas

- Nunca reporten un agregado sin haber mirado al menos una desagregación relevante.
- Si un agregado se mueve, pregunten siempre: ¿cambió el nivel o cambió quién está adentro?
- Simpson no dice cuál es el número "verdadero". Dice que la elección de qué controlar es una **decisión sustantiva**, no técnica: hay que justificarla con teoría.

Falacia ecológica

El experimento


William Robinson comparó, con el censo de EE.UU. de 1930, la correlación entre **ser nacido en el extranjero** y **ser alfabeto**, calculada de dos maneras:

- A nivel de las **97 millones de personas**: $r \approx -0,11$. Los extranjeros eran, individualmente, algo menos alfabetos.
- A nivel de las **9 divisiones geográficas**: $r \approx +0,53$. Las regiones con más extranjeros eran las regiones más alfabetas.

La falacia ecológica

Inferir el comportamiento de los **individuos** a partir de correlaciones calculadas sobre **agregados**. Los inmigrantes se instalaban en los estados del norte, que eran los más ricos y escolarizados: el agregado captaba dónde vivían, no quiénes eran.

La misma cuenta, con la EPH 1T 2026



Tamaño del punto = población representada. A nivel individual la asociación es prácticamente **nula**; entre aglomerados es **fuertemente positiva**. Es la réplica argentina del resultado de Robinson.

Por qué la agregación infla las correlaciones

Descomposición de la varianza

$$\underbrace{Var(y)}_{\text{total}} = \underbrace{E_g[Var(y | g)]}_{\text{varianza INTRA-grupo}} + \underbrace{Var_g[E(y | g)]}_{\text{varianza ENTRE grupos}}$$

Qué hace la agregación

Al promediar dentro de cada aglomerado, el primer término **desaparece**: se borra la variabilidad entre personas del mismo lugar, que es donde vive casi todo el ruido individual. Queda solo la señal **entre** unidades.

Consecuencias

- Las correlaciones ecológicas suelen ser mucho **más altas** en valor absoluto: se elimina el denominador ruidoso.
- Pueden tener **signo opuesto**, si la asignación de personas a lugares está correlacionada con el resultado.
- **Cuanto más grandes las unidades, peor**: entre provincias engaña más que entre aglomerados.

El error espejo: la falacia atomista

Falacia ecológica

Del **agregado** al **individuo**.

"Las provincias con más gasto educativo tienen mejores notas, entonces gastar más en la educación de mi hijo le sube la nota."

Falacia atomista

Del **individuo** al **agregado**.

"Un año más de educación aumenta el salario individual un 8%, entonces si el país agrega un año de educación promedio, los salarios suben 8%."

Por qué falla la segunda

Porque en el agregado aparecen efectos que no existen a nivel individual: equilibrio general, competencia por puestos, señalización, retornos decrecientes. La educación puede servir para **ubicarse en la fila** sin mover la fila entera.

La regla

Una relación estimada en un nivel de agregación **no se traslada automáticamente** a otro. En ninguna de las dos direcciones.

Comparar distribuciones completas

De un número a una función

Estadística descriptiva

Hasta acá resumimos una distribución con **escalares**: $\bar{x}$, s , CV , Me . Cada uno es una proyección de la distribución sobre un solo eje, y toda proyección pierde información.

En una función

Densidad $f(x)$ y acumulada $F(x) = \Pr(X \leq x)$. Todo lo que vimos se deriva de ellas:

$$\bar{x} = \int xf(x) dx \quad Me = F^{-1}(0,5) \quad q_p = F^{-1}(p)$$


Por qué importa

Dos distribuciones pueden tener **la misma media y el mismo desvío** y ser completamente distintas. Comparar las funciones enteras evita apostar de antemano a qué estadístico va a captar la diferencia.

Histograma y densidad kernel

Ingreso de la ocupación principal (millones de pesos)

Mismo dato, tres anchos de banda. El histograma depende de los bins; la densidad, del bw.



La densidad kernel es $\hat{f}_h(x) = \frac{1}{\sum_i w_i} \sum_i w_i \frac{1}{h} K\left(\frac{x-x_i}{h}\right)$. El **ancho de banda** h es el parámetro que decide todo: chico, sobreajusta el ruido; grande, borra los rasgos reales.

Los picos son reales: el redondeo del que declara

Lección de lectura

Los picos que aparecen con ancho de banda estrecho **no son artefactos**: la gente declara ingresos redondos (500.000, 1.000.000, 1.500.000). Es **heaping**, y es información sobre cómo se produce el dato, no ruido.

Por qué el logaritmo

La distribución del ingreso tiene cola derecha larguísima: en escala de pesos, el 95% de la masa se aplasta contra el eje y la comparación visual entre grupos se vuelve imposible.


$$\text{Si } Y \sim \text{lognormal, } \ln Y \sim \text{normal}$$

En logaritmos la distribución se vuelve aproximadamente simétrica, y una **diferencia de niveles** pasa a leerse como un **desplazamiento horizontal** de la curva. Además, $\Delta \ln y \approx$ variación porcentual.

Densidades superpuestas: 2017 contra 2026


Densidad del log del ingreso de la ocupación principal

Ingresos normalizados por la mediana de cada año: la comparación es de FORMA, no de nivel



Normalizar por la mediana de cada período elimina el efecto de la inflación y deja a la vista lo único comparable sin deflactor: la **dispersión relativa**. La curva de 2026 es más **ancha en las dos colas**.

La función de distribución acumulada



La CDF responde directamente la pregunta útil: *¿qué proporción de la gente está por debajo de tal umbral?* Los escalones son, otra vez, el heaping en valores redondos.

Análisis por cuantiles

Deciles, percentiles y ratios

Cuantil	Ingreso ocup. principal
p10	\$ 240.000
p25	\$ 500.000
p50 (mediana)	\$ 900.000
p75	\$ 1.400.000
p90	\$ 2.000.000

EPH 1T 2026, ocupados, ponderado por PONDII0.

Ratios de dispersión distribucional

$$\frac{p90}{p10} = 8,33$$

$$\frac{p50}{p10} = 3,75$$

$$\frac{p90}{p50} = 2,22$$

Cómo se leen

- $p90/p10$: distancia entre los extremos.
Desigualdad **global**.
- $p50/p10$: qué tan lejos está el centro del **piso**.
Desigualdad de la **mitad inferior**.
- $p90/p50$: qué tan lejos está el **techo** del centro.
Desigualdad de la **mitad superior**.

Ventaja sobre el desvío estándar: son **robustos** (no los mueve un caso extremo), **adimensionales** (son ratios) y **localizan** en qué parte de la distribución está la desigualdad. El Gini, en cambio, comprime todo en un solo número y no dice dónde.

Qué cambió entre 2017 y 2026

Indicador	1T 2017	1T 2026	Variación
p90 / p10	7,67	8,33	8,7%
p50 / p10	3,33	3,75	12,5%
p90 / p50	2,30	2,22	-3,4%
Coefficiente de variación	0,81	0,96	18,2%

Lectura

La desigualdad global del ingreso de la ocupación principal **aumentó**. Y los ratios dicen **dónde**: el $p50/p10$ crece más que el $p90/p50$, o sea que buena parte del deterioro está en la **mitad inferior** de la distribución, no en el despegue de la cúpula.

Un solo índice de desigualdad no habría podido decir eso.

Growth Incidence Curve (Ravallion y Chen, 2003)

Definición

Para cada percentil p , la GIC grafica la tasa de crecimiento del ingreso de ese percentil entre dos períodos:

$$g(p) = \frac{q_p^{t_1}}{q_p^{t_0}} - 1, \quad p \in (0, 1)$$

donde q_p^t es el ingreso del percentil p en el período t .


Cómo se lee

- Curva **plana**: todos crecieron igual, la distribución relativa no cambió.
- Curva con **pendiente negativa**: crecimiento **pro-pobre**, la desigualdad baja.
- Curva con **pendiente positiva**: el crecimiento se concentró arriba, la desigualdad sube.

GIC del ingreso laboral, 1T 2017 a 1T 2026

Crecimiento del ingreso por percentil, relativo al crecimiento de la media

Puntos: valor observado percentil a percentil. Línea: suavizado loess.



Como no deflactamos, la curva está expresada **relativa al crecimiento de la media**: la línea de cero es “creció igual que el promedio”. El patrón es claro: la mitad inferior quedó **por debajo** del promedio y solo el tramo por encima del percentil 85 quedó **por encima**.

La advertencia clave: la GIC no sigue personas

El supuesto de anonimidad

La GIC compara **la posición p en t_0** con **la posición p en t_1** . No es la misma persona. Si toda la distribución se reordenara por completo entre los dos períodos, la GIC sería exactamente igual.

Lo que la GIC sí dice

"El ingreso de **quien está** en el percentil 10 hoy es $x\%$ distinto del de **quien estaba** en el percentil 10 hace nueve años."

Lo que NO dice

"A la gente que estaba en el percentil 10 hace nueve años le fue $x\%$ mejor o peor."
Eso requiere **datos de panel**: es la GIC **no anónima**, de forma muy distinta.

Por qué importa acá

La EPH tiene un panel rotativo de cuatro ondas: alcanza para un año y medio, no para nueve. Con la GIC anónima, la movilidad individual es invisible.

Hacia dónde sigue esto: regresión cuantílica

La limitación de MCO

La regresión lineal estima $E[Y | X]$: el efecto de X sobre la **media condicional**. Toda la clase de hoy fue un argumento contra confiar en una media.

La generalización

La regresión cuantílica (Koenker y Bassett, 1978) estima $Q_\tau(Y | X)$: el efecto de X sobre el **cuantil** τ de la distribución condicional. Se obtiene minimizando una pérdida asimétrica

$$\hat{\beta}_\tau = \arg \min_{\beta} \sum_i \rho_\tau(y_i - x_i' \beta), \quad \rho_\tau(u) = u \cdot (\tau - \mathbf{1}(u < 0))$$

En lugar de un coeficiente $\hat{\beta}$, se obtiene una **función** $\hat{\beta}(\tau)$: cómo cambia el efecto de la variable a lo largo de toda la distribución.

Regresión cuantílica: qué pregunta permite

El ejemplo típico

MCO responde: "un año más de educación aumenta el salario **promedio** un 8%".

La regresión cuantílica responde: "un año más de educación aumenta el salario un 4% **en el cuantil 10** y un 12% **en el cuantil 90**".

Por qué es otra pregunta

Si $\hat{\beta}(\tau)$ es creciente, la educación **amplía** la desigualdad salarial. Si es decreciente, la **comprime**. MCO no puede distinguir esos dos mundos: ambos dan el mismo coeficiente promedio.

Dos ventajas más

- Es **robusta a valores extremos**, igual que la mediana simple.
- No requiere homocedasticidad: si la varianza del error depende de X , MCO pierde eficiencia y la regresión cuantílica lo convierte en información.

En R: `quantreg::rq()`.

Cierre

Siete preguntas para cualquier estadística que lean

- 1 **¿Cuál es la población de referencia?** ¿A quiénes incluye y a quiénes deja afuera?
- 2 **¿Está ponderado, y con qué ponderador?** ¿Corresponde a la variable que se promedia?
- 3 **¿Es media o mediana?** Si es media, ¿qué tan asimétrica es la distribución detrás?
- 4 **¿A qué nivel de agregación está calculado, y sobre qué nivel se quiere concluir?**
- 5 **¿Qué pasa si lo abro por el subgrupo obvio?** ¿Se mantiene el signo o se invierte?
- 6 **Si compara períodos o grupos, ¿se movió el nivel o se movió la composición?**
- 7 **¿Sobrevive la conclusión si miro la distribución entera?** ¿Se cruzan las acumuladas?