

Ciencia de Datos para Economía y Negocios - FCE-UBA

Clase 7 — Inferencia por remuestreo: bootstrap y permutación

Nicolás Sidicaro

Apertura

El número que calculamos no es el único que podríamos haber calculado

Toda inferencia necesita una distribución de referencia.

El problema

Cuando calculamos un promedio, una mediana o una diferencia entre grupos, obtenemos **un número**. Ese número sería otro si hubiéramos observado otra muestra. La pregunta de la inferencia es **cuánto cambiaría** y qué valores serían compatibles con el azar del muestreo.

La idea central de la clase

Esa distribución de referencia se puede **derivar teóricamente** (LGN, TCL, distribución t) o **construir simulando** a partir de los propios datos (bootstrap, permutación). La segunda vía no necesita fórmulas cerradas.

El arco de la clase

- 1 **LGN y TCL:** por qué el promedio muestral es estable y aproximadamente normal. La teoría funciona, y sabemos exactamente para qué estadístico.
- 2 **Bootstrap:** qué hacer cuando el estadístico que nos interesa **no tiene teoría cerrada**. Mediana, Gini, ratio de percentiles.
- 3 **Lógica del test de hipótesis:** la receta abstracta, desacoplada de cualquier distribución particular.
- 4 **Permutación:** cómo construir la distribución de un estadístico **bajo una hipótesis de no diferencia**.

El hilo

Los tres bloques del medio responden a la misma carencia: tenemos **una** muestra y necesitamos saber cómo se comportaría el estadístico en **muchas**.

Hoja de ruta

- 1 Apertura
- 2 Ley de los Grandes Números y Teorema Central del Límite
- 3 Bootstrap
- 4 La lógica del test de hipótesis
- 5 Tests de permutación
- 6 Cierre

Los ejemplos con datos reales usan la **EPH, primer trimestre de 2026** (INDEC), la misma base de la clase anterior: 15.448 ocupados con ingreso declarado de la ocupación principal.

Ley de los Grandes Números y Teorema Central del Límite

Ley de los Grandes Números

Enunciado informal

El promedio de una muestra aleatoria **converge** a la esperanza poblacional a medida que crece el tamaño de muestra, siempre que esa esperanza **exista**.

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \longrightarrow \mu = E[X] \quad \text{cuando } n \rightarrow \infty$$

Débil y fuerte


- **Débil**: convergencia en probabilidad. Para todo $\varepsilon > 0$, $P(|\bar{X}_n - \mu| > \varepsilon) \rightarrow 0$.
- **Fuerte**: convergencia casi segura. La trayectoria misma converge, con probabilidad 1.

La distinción es técnica y no la vamos a demostrar. Lo relevante para el curso es la intuición de **consistencia**: con más datos, el estimador se acerca al parámetro.

Simulación 1: la trayectoria del promedio acumulado

Promedio de las primeras n observaciones, 8 trayectorias independientes

Datos normales de media 5 y desvío 2. Línea roja: la esperanza poblacional.




El **embudo se cierra**: la dispersión entre trayectorias cae con $1/\sqrt{n}$. Para $n = 100$ el promedio ya está en un entorno estrecho de μ ; para $n = 10.000$ las ocho trayectorias son indistinguibles.

Simulación 2: el contraejemplo (distribución Cauchy)

Lo mismo, con una distribución Cauchy centrada en 5

Mismo diseño, mismo n . El promedio acumulado no converge a nada.



La Cauchy **no tiene esperanza finita**, así que la LGN no aplica. Los promedios finales de las 8 trayectorias van de -17,3 a 10,0, con $n = 10.000$ en todas.

Lo que hay que llevarse del contraejemplo

La convergencia no es magia: depende de supuestos

Si la distribución tiene colas suficientemente pesadas, agregar datos **no estabiliza** el promedio. Cada tanto aparece una observación tan grande que domina toda la suma acumulada, y la trayectoria salta.

Por qué importa en economía

No trabajamos con Cauchys, pero sí con distribuciones de **cola muy pesada**: patrimonios, facturación de empresas, tamaño de ciudades, montos de siniestros, retornos financieros diarios. En esos casos la convergencia existe pero es **lenta**, y el n que hace falta es mucho mayor que el que sugiere la intuición.

Teorema Central del Límite

Enunciado informal

La distribución del promedio muestral **estandarizado** se aproxima a una normal cuando n crece, **cualquiera sea la distribución de origen**, mientras la varianza sea finita.

$$Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0, 1)$$

El malentendido que hay que erradicar


El TCL **no dice** que los datos se vuelvan normales. Dice que se aproxima a la normal la distribución del **estadístico** calculado sobre muestras repetidas.

Es un enunciado sobre la **distribución muestral**, no sobre la población observada. Los ingresos siguen siendo asimétricos por más que n sea enorme.

Simulación 3: cuatro poblaciones de origen

Las poblaciones de origen: ninguna es normal

Uniforme (simétrica y acotada) · Exponencial (asimétrica) · Bimodal · Lognormal (cola pesada)




De cada una vamos a extraer **10.000 muestras** de tamaño $n = 2, 5, 30, 200$, y a graficar la distribución del **promedio estandarizado** con la $N(0,1)$ teórica superpuesta.

La distribución del promedio, por población y por n

Distribución del promedio estandarizado, 10.000 muestras por celda

Línea roja: densidad $N(0,1)$ teórica



La velocidad de convergencia depende de la asimetría de la población

- **Uniforme:** con $n = 2$ ya es un triángulo, con $n = 5$ es prácticamente normal.
- **Exponencial:** la asimetría a derecha sobrevive hasta $n = 30$ y recién se disuelve cerca de $n = 200$.
- **Bimodal:** con $n = 2$ tiene varias modas; el TCL igual se impone rápido.
- **Lognormal con $\sigma_{\log} = 1,6$:** con $n = 200$ **todavía** se ve cola derecha.

Población de origen	Asimetría del promedio con $n = 30$
Uniforme	-0,01
Exponencial	0,35
Bimodal	0,02
Lognormal	7,20

Moraleja operativa

La regla de $n > 30$ es una simplificación de manual

No es un teorema. Es una regla que funciona razonablemente para distribuciones **moderadamente** asimétricas y falla cuando la asimetría es fuerte.

Dónde falla en la práctica

Ingresos, ventas, facturación, siniestros, duración del desempleo, montos de transacciones. Todo lo que tenga cola derecha larga. Con $n = 50$ observaciones de ingresos, un intervalo de confianza basado en normalidad puede tener una cobertura real bastante menor al 95% nominal.

Y este es todavía el caso **fácil**: el TCL es un resultado sobre el **promedio**. Para la mediana, el Gini o un ratio de percentiles no hay un teorema análogo de bolsillo.

El objeto que estructura el resto de la clase

Distribución muestral de un estadístico

La distribución de los valores que tomaría el estadístico $\hat{\theta}$ si repitiéramos el muestreo **muchas veces** desde la misma población.

El problema práctico

Tenemos **una sola muestra**. Nunca observamos esa distribución.

Las tres salidas

- **Teoría:** el TCL la aproxima, para el promedio y poco más.
- **Bootstrap:** la simulamos remuestreando los datos que tenemos.
- **Permutación:** la simulamos bajo el supuesto de que H_0 es verdadera.

Bootstrap

La idea

Analogía de la sustitución

Si tuviéramos la **población**, podríamos extraer muchas muestras y ver directamente cómo varía el estadístico. Como no la tenemos, usamos la **muestra observada** como la mejor estimación disponible de la población, y remuestreamos de ella.

Formalización mínima

El bootstrap reemplaza la distribución poblacional desconocida F por la **distribución empírica** $\hat{F}_n$, que asigna probabilidad $1/n$ a cada observación de la muestra:

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}(X_i \leq x)$$

Remuestrear de $\hat{F}_n$ es exactamente **sortear observaciones con reposición**.

Efron (1979). La justificación es que $\hat{F}_n \rightarrow F$: si la muestra es grande, la empírica es una buena copia de la

El algoritmo

Cuatro pasos

- 1 Tomar una muestra de tamaño n **con reposición** de los datos originales.
- 2 Calcular el estadístico de interés $\hat{\theta}^*$ sobre esa remuestra.
- 3 Repetir B veces, con B típicamente entre 1.000 y 10.000.
- 4 Usar la distribución de los B valores $\hat{\theta}_1^*, \dots, \hat{\theta}_B^*$ como aproximación a la distribución muestral de $\hat{\theta}$.

Dos detalles que no son opcionales

- El remuestreo es **con reposición**. Sin reposición se recuperaría siempre la muestra original, apenas permutada, y la variabilidad simulada sería cero.
- Es del **mismo tamaño** n que la muestra original. Con un tamaño menor se estaría estimando la variabilidad de un n distinto del que se tiene.

Una sola iteración, con diez números

Paso	Valores (en miles de pesos)
Muestra original ordenada	359 371 408 570 670 689 728 751 1.153 1.244
Índices sorteados con reposición	5 8 5 9 9 8 6 2 9 8
Remuestra bootstrap (ordenada)	371 670 670 689 751 751 751 1.153 1.153 1.153

Qué mirar

Hay observaciones **repetidas** y observaciones **ausentes**. En esta remuestra quedaron afuera 5 de las 10 observaciones originales.

Dato de color útil: en promedio cada remuestra deja afuera $1 - 1/e \approx 63,2\%$ de las observaciones. Esa misma cuenta es la que da el “out-of-bag” de random forest.

Intervalos de confianza: método percentil

El más simple, y el primero que conviene aprender

Ordenar los B valores bootstrap y tomar los percentiles $\alpha/2$ y $1 - \alpha/2$:

$$IC_{95\%} = [\hat{\theta}_{(0,025)}^*, \hat{\theta}_{(0,975)}^*]$$

En R: `quantile(vals_boot, c(0.025, 0.975))`.

Ventajas

- No supone simetría ni normalidad de la distribución bootstrap.
- Respeta el rango del parámetro: si el estadístico es un ratio positivo, el intervalo nunca da negativo.
- Es invariante a transformaciones monótonas: el IC del log es el log del IC.

Intervalos de confianza: normal y BCa

Normal con error estándar bootstrap

El desvío estándar de la distribución bootstrap estima el **error estándar** del estimador:

$$\widehat{SE}_{boot} = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}_b^* - \bar{\theta}^*)^2}$$

$$IC_{95\%} = \hat{\theta} \pm 1,96 \cdot \widehat{SE}_{boot}$$

Conecta directo con la inferencia clásica que ya vieron.

BCa

Bias-Corrected and accelerated. Corrige por **sesgo** y por **aceleración** (asimetría de la distribución bootstrap), y mejora la cobertura cuando esa distribución no es simétrica.

No desarrollamos la fórmula. En R:
`boot::boot.ci(obj, type = "bca")`.

Regla práctica

Si la distribución bootstrap es simétrica, percentil y normal coinciden. Si es asimétrica, **el percentil es preferible al normal**, y BCa es preferible a los dos.

Dónde gana el bootstrap: estadísticos sin fórmula cerrada

- **Mediana.** La fórmula teórica del error estándar es $(2\sqrt{n} f(Me))^{-1}$: depende de la **densidad evaluada en la mediana**, que no se conoce. El bootstrap lo resuelve sin esfuerzo.
- **Coeficiente de Gini.** Estadístico central en el trabajo con ingresos, y sin expresión simple para su varianza.
- **Ratio de dos medias.** El cociente de estimadores tiene distribución complicada aun cuando numerador y denominador sean normales.
- **Percentil 90, o razón p_{90}/p_{10} .** Todo lo que hicimos la clase pasada con distribuciones salariales, ahora con incertidumbre asociada.


El punto

En los cuatro casos el trabajo es exactamente el mismo: sortear con reposición, calcular, repetir. **Cambiar el estadístico no cambia el método.**

Bootstrap sobre la EPH: tres estadísticos

Distribuciones bootstrap, $B = 2.000$ remuestras (EPH 1T 2026, ocupados)

Línea llena: valor observado. Líneas punteadas: percentiles 2,5 y 97,5.



Ninguno de los tres tiene una fórmula de error estándar que valga la pena escribir. Los tres salieron del mismo for.

Los intervalos, y la comparación entre métodos

Estadístico	Estimación	IC 95% percentil	IC 95% normal
Mediana del ingreso (\$)	900.000	[850.000 ; 900.000]	[877.530 ; 922.470]
Coeficiente de Gini	0,420	[0,408 ; 0,433]	[0,408 ; 0,432]
Razón p90 / p10	8,33	[8,00 ; 10,00]	[7,38 ; 9,28]

Lectura

Para el Gini los dos métodos coinciden hasta el tercer decimal: la distribución bootstrap es simétrica y el intervalo normal es una buena aproximación.

Para la **mediana** y la **razón** p_{90}/p_{10} no coinciden. La razón es que los ingresos declarados se **amontonan en valores redondos**, así que la distribución bootstrap de un cuantil es **discreta**: salta entre unos pocos valores posibles. El intervalo percentil hereda esa discreción y es honesto al respecto; el normal la disimula detrás de una fórmula continua.

Moraleja: el bootstrap no solo da un intervalo, también **muestra la forma** de la distribución muestral. Vale la pena mirar el histograma antes de reportar el número.

Cómo se escribe, sin ningún paquete

```
bootstrap <- function(datos, estadistico, B = 2000) {  
  n <- nrow(datos)  
  resultados <- numeric(B)  
  for (b in seq_len(B)) {  
    i <- sample.int(n, size = n, replace = TRUE)      # con reposición  
    resultados[b] <- estadistico(datos[i, ])          # mismo n  
  }  
  resultados  
}  
  
bs <- bootstrap(ocupados, function(d) median(d$P21), B = 2000)  
  
quantile(bs, c(0.025, 0.975))    # IC percentil  
sd(bs)                           # error estándar bootstrap
```

Son ocho líneas. Cuando la idea está clara conviene pasar a `boot::boot()` o `rsample::bootstrap()` que

Los límites del bootstrap

No es universal

- **Falla con estadísticos que dependen de valores extremos**, como el máximo muestral. La distribución bootstrap del máximo es discreta y degenerada: en esta simulación el 62,5% de las remuestras devuelve **exactamente** el mismo máximo que la muestra original.
- **Funciona mal con muestras muy chicas**. Con $n = 10$, $\hat{F}_n$ es una aproximación pobre de F , y el bootstrap hereda ese error.
- **Requiere independencia entre observaciones**. Con series de tiempo hay que remuestrear **bloques**; con datos agrupados, **clusters** enteros.
- **No arregla el sesgo de selección**. Si la muestra no representa a la población, el bootstrap reproduce fielmente ese problema.

Corolario del último punto para los ejemplos recién vistos: la EPH tiene diseño **estratificado y por conglomerados**. Un bootstrap que sortea filas al azar, como el que hicimos, ignora esa estructura y **subestima** el error estándar. Lo correcto es remuestrear conglomerados dentro de estratos (`survey::svydesign()` y `svrepdesign()`).

La lógica del test de hipótesis

La receta, en abstracto

Por qué presentarla desacoplada de cualquier distribución

Porque así la permutación aparece después como una **implementación directa** de la receta, y no como una técnica aparte. Todos los tests que van a ver en la carrera son la misma receta con distinto relleno.

Estadístico + distribución nula $\Rightarrow$ p-valor

Lo único que cambia entre un test t , un ANOVA, un chi-cuadrado y un test de permutación es **de dónde sale la distribución nula**: de un teorema, o de una simulación.

Los cinco componentes

- H_0 , **hipótesis nula**. Una afirmación **precisa** sobre el proceso generador de datos, en general de ausencia de efecto o de diferencia. Su función es **permitir calcular probabilidades**, y por eso tiene que ser específica.
- H_1 , **hipótesis alternativa**. El complemento de interés. Bilateral o unilateral, y esa elección se define **antes** de mirar los datos.
- **Estadístico de prueba**. Un resumen de los datos elegido de modo que valores **grandes** sean poco compatibles con H_0 .
- **Distribución nula**. La distribución del estadístico **suponiendo que H_0 es verdadera**. Este es el ingrediente que en la práctica cuesta conseguir.
- **p-valor**. La probabilidad, **bajo H_0** , de observar un estadístico tan extremo o más extremo que el observado.

$$p = P(|T| \geq |t_{obs}| \mid H_0)$$

Qué NO es el p-valor

Cuatro errores que sobreviven a toda la carrera

- **No es la probabilidad de que H_0 sea verdadera.** Es una probabilidad calculada **asumiendo** que H_0 es verdadera: $P(\text{datos} \mid H_0) \neq P(H_0 \mid \text{datos})$.
- **No es la probabilidad de que el resultado se replique.**
- **No mide el tamaño del efecto.** Con n muy grande, diferencias irrelevantes producen p-valores diminutos. El p-valor mezcla magnitud del efecto con tamaño de muestra.
- **Un p-valor alto no prueba que H_0 sea verdadera.** Solo indica que los datos no aportan evidencia suficiente en su contra. Ausencia de evidencia no es evidencia de ausencia.

Consecuencia práctica: un p-valor **siempre** se reporta junto con el **tamaño del efecto** y su **intervalo de confianza**. Nunca solo.

Errores tipo I y tipo II

	H_0 verdadera	H_0 falsa
No rechazo H_0	Decisión correcta ($1 - \alpha$)	Error tipo II (β)
Rechazo H_0	Error tipo I (α)	Correcta: potencia ($1 - \beta$)

- **Error tipo I:** rechazar H_0 siendo verdadera. Probabilidad α , que **fijamos nosotros** (0,05 por convención).
- **Error tipo II:** no rechazar H_0 siendo falsa. Probabilidad β , que **no elegimos**: depende del efecto real, de n y de la varianza.
- **Potencia:** $1 - \beta$, la probabilidad de **detectar** un efecto que efectivamente existe.

El compromiso, y cómo salir de él

La relación entre los dos errores

Con todo lo demás fijo, **bajar** α **aumenta** β . Exigir más evidencia para rechazar implica dejar pasar más efectos reales. Es un problema de dónde poner el umbral, no de cuánta información hay.

La forma de mejorar los dos a la vez

- **Aumentar n** : concentra la distribución nula y la alternativa, y las separa.
- **Reducir la varianza del diseño**: mediciones más precisas, controles, bloqueo, datos apareados.
- **Elegir un estadístico más eficiente** para el tipo de dato que se tiene.

Adelanto de la próxima clase

La **potencia baja** es una de las razones centrales por las que buena parte de los resultados publicados **no se replican**: con potencia baja, un resultado significativo tiende a ser un falso positivo o un efecto fuertemente sobreestimado.

Tests de permutación

La idea

La situación típica

Dos grupos, A y B , y una diferencia observada entre ellos. La pregunta es si esa diferencia es compatible con que la **etiqueta de grupo no tenga ninguna relación** con la variable de interés.

La hipótesis nula, expresada como intercambiabilidad

Bajo H_0 las etiquetas son **intercambiables**: cualquier reasignación de etiquetas a observaciones es **tan probable** como la que efectivamente se observó.

Y de ahí sale todo

Si todas las reasignaciones son igualmente probables bajo H_0 , entonces **recorrerlas** genera exactamente la distribución nula del estadístico. No hace falta ningún teorema: la distribución nula se **construye**.

El algoritmo

Cinco pasos

- 1 Calcular el estadístico **observado** t_{obs} , por ejemplo la diferencia de medias entre grupos.
- 2 **Mezclar al azar** el vector de etiquetas, manteniendo los tamaños de grupo.
- 3 Recalcular el estadístico sobre los datos con etiquetas permutadas.
- 4 Repetir B veces.
- 5 El p-valor es la proporción de estadísticos permutados tan extremos o más que el observado.

El detalle del +1


$$p = \frac{\#\{b : |t_b^*| \geq |t_{obs}|\} + 1}{B + 1}$$

Se incluye el valor observado en el conteo, porque la permutación identidad es una permutación válida. Sin eso se pueden obtener p-valores **exactamente iguales a cero**, que no tienen sentido: el mínimo alcanzable es $1/(B + 1)$.

Los datos: salario horario por sexo, EPH 1T 2026

Salario horario de la ocupación principal, por sexo

n = 14.208 ocupados con horas declaradas. Recortado en el percentil 99.




Mediana varones: \$ 5.249 | Mediana mujeres: \$ 4.811 | **Diferencia observada: \$ 437 por hora.**

La visualización que resume todo el test

Distribución nula por permutación, B = 2.000

Diferencia de medianas del salario horario, con las etiquetas de sexo mezcladas al azar



$p = (0 + 1)/(2000 + 1) < 0,001$. La diferencia observada queda **fuera** del rango de lo que produce el azar de las etiquetas.

Por qué esta imagen vale toda la teoría

Es el test de hipótesis entero, en un gráfico



- El **histograma** es la distribución nula: lo que produciría el azar si las etiquetas no importaran.
- La **línea vertical** es el dato: lo que efectivamente observamos.
- El **p-valor** es la proporción del histograma que queda tan afuera o más que la línea.

Conviene volver a esta imagen cada vez que aparezca un p-valor

Cuando en un paper aparece un t o un F con su p-valor, lo que hay detrás es exactamente esto, con la única diferencia de que el histograma viene dado por una fórmula en lugar de una simulación.

Comparación con el t-test: dos escenarios

Los mismos dos grupos, dos mundos distintos



Escenario	p permutación	p t-test
A: normal, varianzas parecidas, n = 80	0,008	0,009
B: lognormal, cola pesada, n = 24	0,295	0,276

Cómo leer la comparación

Escenario de coincidencia

Datos normales, varianzas parecidas, n moderado. El p-valor de permutación y el del t -test dan prácticamente lo mismo.

Conclusión: el t -test es una **muy buena aproximación** cuando sus supuestos se cumplen. Y es instantáneo.

Escenario de divergencia

Cola pesada, asimetría fuerte, n chico. Los p-valores **difieren**.

Conclusión: el de permutación es válido **por construcción**, porque la distribución nula se derivó de los datos que efectivamente tenemos. El del t -test descansa en una aproximación normal que con esos datos y ese n no se sostiene.

El t -test no es “peor”. Es un caso particular que necesita supuestos: cuando valen, coincide con la permutación; cuando no valen, la permutación sigue funcionando.

Flexibilidad: el estadístico puede ser cualquiera

El punto potente

Como la distribución nula se construye **por simulación**, el estadístico puede ser cualquiera que resulte sustantivamente interesante. No hace falta que tenga teoría asociada.

Estadístico	Valor observado	p-valor
Diferencia de medias	431,9	$< 0,01$
Diferencia de medianas	437,4	$< 0,01$
Diferencia de p90	1.154,7	0,016
Diferencia de CV	0,1	0,543

Cuatro preguntas distintas, un solo método

Brecha en el promedio, en el centro de la distribución, en el techo, y en la **dispersión relativa**. Ninguna de las cuatro requirió teoría adicional: se cambió una línea de código.

800 permutaciones sobre el salario horario, EPH 1T 2026, sin ponderar.

Los límites de la permutación

Tres advertencias

- La H_0 que se testea es de **intercambiabilidad completa**, algo más fuerte que la igualdad de medias. Si los grupos difieren en **varianza** pero no en media, el test puede rechazar, y leer ese rechazo como "hay diferencia de medias" sería incorrecto.
- **Con muestras muy chicas hay un piso al p-valor alcanzable.** Con 4 observaciones por grupo hay solo $\binom{8}{4} = 70$ asignaciones distintas: el p-valor bilateral mínimo es del orden de $2/70 \approx 0,029$. Ningún B arregla eso.
- **El diseño del remuestreo tiene que respetar la estructura de los datos.** Con datos **apareados** se permuta **dentro** de cada par; con estructura jerárquica se permuta al **nivel** correspondiente. Permutar todo junto rompe el test.

Cómo se escribe, sin ningún paquete

```
test_permutacion <- function(y, grupo, B = 2000) {  
  niveles <- unique(grupo)  
  estadistico <- function(g) {  
    mean(y[g == niveles[1]]) - mean(y[g == niveles[2]])  
  }  
  obs <- estadistico(grupo)  
  nulos <- replicate(B, estadistico(sample(grupo))) # solo se mezclan etique  
  list(observado = obs,  
       nulos      = nulos,  
       p_valor    = (sum(abs(nulos) >= abs(obs)) + 1) / (B + 1))  
}
```

La línea que hace todo el trabajo es `sample(grupo)`: los datos **no se tocan**, se reasignan las etiquetas.
Implementaciones listas: `coin::independence_test()` e `infer`, que tiene una gramática al estilo tidyverse (`specify()` |> `hypothesize()` |> `generate()` |> `calculate()`).

Cierre

Bootstrap y permutación no son lo mismo

Dimensión	Bootstrap	Permutación
Pregunta que responde	¿Cuánto varía mi estimador?	¿Es lo observado compatible con la ausencia de efecto?
Qué produce	Intervalos de confianza y errores estándar	p-valores
Cómo remuestrea	Observaciones, con reposición	Reordena etiquetas , sin reposición
Bajo qué mundo simula	El mundo estimado por los datos	El mundo donde H_0 es verdadera

El bootstrap estima variabilidad. La permutación materializa la hipótesis nula.

Qué sigue

La misma receta, con la distribución nula puesta por la teoría

Los tests clásicos que vienen — ANOVA, chi-cuadrado — usan **exactamente** la misma estructura:

$$\text{estadístico} + \text{distribución nula} \Rightarrow \text{p-valor}$$

La única diferencia es que la distribución nula viene de un teorema en lugar de una simulación.

Por qué conviene haber visto primero el remuestreo

Porque cuando aparezca una $F_{k-1, n-k}$ o una $\chi^2_{(k-1)(r-1)}$, ya van a saber **qué lugar ocupa** en la receta: es el histograma de permutación, dibujado con una fórmula.

Y también van a saber qué hacer cuando los supuestos de esa fórmula no se cumplan.

Cinco preguntas para llevarse

- 1 **¿Cuál es la distribución de referencia de este número?** Si no la puedo nombrar, no estoy haciendo inferencia.
- 2 **¿Viene de un teorema o de una simulación?** Si viene de un teorema, ¿se cumplen sus supuestos con estos datos y este n ?
- 3 **¿Mi estadístico tiene una fórmula de error estándar razonable?** Si no la tiene, el bootstrap ya resuelve el problema.
- 4 **¿Estoy reportando el p-valor solo, o con el tamaño del efecto y su intervalo?** Solo el p-valor no alcanza nunca.
- 5 **¿El remuestreo respeta la estructura de mis datos?** Independencia, conglomerados, apareamiento, series de tiempo.

En una línea

Cuando la teoría no llega, la computadora sí.

- Script de simulaciones de LGN y TCL con `purrr::map` y `ggplot2` en grilla (`facet_grid`).
- Función de bootstrap escrita a mano, con el `for` explícito, antes de `boot` o `rsample::bootstraps()`.
- Función de permutación escrita a mano; `coin` e `infer` como implementaciones listas.
- Base de la EPH (1T 2026, individual) para los ejemplos de mediana, Gini y razón de percentiles.

Para practicar

Repetir el bootstrap del Gini abriendo por aglomerado, y ver cómo se ensanchan los intervalos a medida que cae el n de cada subgrupo. Es la forma más rápida de internalizar que la precisión no es una propiedad del método sino del tamaño de muestra.