

Ciencia de Datos para Economía y Negocios - FCE-UBA

Clase 8 — Análisis exploratorio de datos

Nicolás Sidicaro

Apertura

Antes de preguntar qué dicen los datos, hay que saber qué datos tenemos

Ningún modelo arregla una base que nunca miramos.

Qué es el análisis exploratorio de datos (EDA)

Un conjunto de herramientas para **describir, visualizar e interrogar** una base **antes** de estimar cualquier cosa. Busca patrones, relaciones, anomalías, valores extremos, problemas de calidad y estructuras que no esperábamos.

La idea central de la clase

El EDA no es una lista de gráficos lindos. Es una **secuencia de preguntas** que se le hacen a una base, en un orden que va de lo estructural (qué representa una fila) a lo sustantivo (qué relaciones parecen existir).

Hoja de ruta

- 1 Apertura
- 2 Conocer la base antes de graficarla
- 3 Una variable: la forma de la distribución
- 4 Dos variables: buscar relaciones
- 5 Valores atípicos
- 6 Cierre

Toda la clase usa **una sola base**: EPH del primer trimestre de 2026 (INDEC), base individual, 43.739 filas y 234 columnas. La idea es recorrer un **flujo de trabajo completo** sobre los mismos datos, en lugar de ver ejemplos desconectados.

Dos tipos de preguntas, y una advertencia

Descriptivas

- ¿Cómo se distribuye el ingreso?
- ¿Cuál es la edad promedio?
- ¿Cuánto difiere el ingreso entre regiones?

Exploratorias

- ¿Parece haber relación entre educación e ingreso?
- ¿Hay grupos de observaciones distintos?
- ¿Qué variables explican los valores extremos?

EDA $\neq$ causalidad

Que las personas con más educación tengan mayores ingresos **no** implica que aumentar la educación cause un aumento del ingreso. El EDA sirve para **generar** hipótesis, no para responderlas.

Corolario práctico: si exploramos cincuenta relaciones y reportamos la única que “dio”, el p-valor de esa relación ya no significa lo que creemos. **Explorar es legítimo; presentar la exploración como confirmación, no.**

Conocer la base antes de graficarla

La primera pregunta: ¿qué representa una fila?

Unidad de observación

Una fila puede ser una persona, un hogar, una empresa, un país, una provincia-año, una transacción. **Todo el análisis depende de esta respuesta**, y no está escrita en los datos: hay que buscarla en el diseño de la base.

En la EPH

Cada fila es una **persona** relevada en un **hogar** en un **trimestre**. La llave que identifica una fila de manera única es CODUSU (vivienda) + NRO_HOGAR + COMPONENTE.

43.739 personas, 15.447 hogares, 0 duplicados de esa llave. Consecuencia inmediata: **un promedio simple sobre las filas es un promedio de personas, no de hogares** — y sin usar PONDERA, tampoco representa a la población.

¿Qué tipo de variable es cada columna?

Tipo	Qué se puede hacer	Ejemplo en la EPH
Numérica continua	Media, desvío, histograma	P21 (ingreso), PP3E_TOT (horas)
Numérica discreta	Conteos, tablas	COMPONENTE, cantidad de hijos
Categorica nominal	Frecuencias, modo	AGLOMERADO, CAT_OCUP
Categorica ordinal	Frecuencias con orden	NIVEL_ED
Binaria	Proporciones	CH04 (sexo), ocupado / no ocupado
Fecha o período	Series, comparaciones	ANO4, TRIMESTRE

El error más común, y el más caro

Que una variable esté guardada como número **no** la hace numérica. AGLOMERADO = 32 y AGLOMERADO = 33 no son magnitudes: el promedio de aglomerado no existe. Y al revés, si el ingreso viene como texto, todo cálculo falla en silencio o devuelve NA.

¿La base está limpia? El caso de los códigos de no respuesta

Chequeo sobre la EPH 1T 2026	Casos
Filas totales (individuos)	43.739
Ocupados (ESTADO = 1)	19.573
Ocupados con P21 = -9 (no responde ingreso)	3.726
Ocupados con P21 = 0 (sin ingreso declarado)	399
Ocupados con PP3E_TOT = 999 (no responde horas)	37
Personas con CH06 = -1 (menores de 1 año)	286

Qué pasa si no miramos

El 19,0% de los ocupados **no declara** su ingreso, y ese valor viene codificado como -9, no como NA. Si calculamos la media sin tocar nada:

media cruda = \$781.515 vs. media sobre válidos = \$990.201

Una diferencia del 21,1%, producida por no leer el diseño de registro.

El checklist mínimo de higiene

- 1 **Dimensiones:** ¿cuántas filas y columnas?
- 2 **Llave:** ¿hay duplicados?
- 3 **Faltantes:** ¿cuántos y **en qué variables**?
- 4 **Códigos especiales:** -9, 99, 999, "NS/NR".
- 5 **Rangos imposibles:** edades negativas, porcentajes > 100.
- 6 **Categorías inconsistentes:** "M", "Masc", "m", "1".
- 7 **Unidades:** ¿pesos o miles? ¿mensual o anual?

Las cinco líneas que resuelven casi todo

- `glimpse(base)`: tipos y primeros valores de cada columna.
- `summary(base)`: rangos, cuartiles y NA por columna.
- `count(base, sexo)`: las categorías que **realmente** existen.
- `count(base, id) |> filter(n > 1)`: duplicados de la llave.
- `summarise(across(everything(), ~ sum(is.na(.x))))`: faltantes por variable.

Los faltantes casi nunca son aleatorios: quien no declara ingreso **no es** una persona promedio. Eliminar esas filas no es una operación neutral, es una decisión sustantiva que hay que declarar.

Una variable: la forma de la distribución

Cinco preguntas para cualquier variable numérica

El orden en que conviene hacerlas

- 1 ¿Dónde se concentran los datos? (**tendencia central**)
- 2 ¿Qué tan dispersos están? (**dispersión**)
- 3 ¿Es simétrica o tiene cola? (**asimetría**)
- 4 ¿Hay valores extremos? (**outliers**)
- 5 ¿Hay **más de un grupo** adentro? (**multimodalidad**)


Media	Mediana	Desvío	P10	P90
\$987.691	\$800.000	\$1.013.148	\$240.000	\$1.900.000

Ingreso de la ocupación principal, 13.703 ocupados de 18 a 65 años con ingreso y horas válidas (70,0% de los ocupados originales). Que la **media esté muy por encima de la mediana** ya anticipa cola derecha, sin haber graficado nada.

Los estadísticos de resumen pueden mentir

Tres distribuciones con la misma media y el mismo desvío




Media = 100 y desvío = 25 en los tres paneles; eje horizontal común



Forma	Media	Mediana	Desvío
Simétrica	100,0	100,1	25,0
Bimodal	100,0	99,6	25,0
Asimétrica	100,0	95,2	25,0



Una distribución no se entiende con tres números. Hay que verla.

Histograma, boxplot y densidad muestran cosas distintas



- **Histograma:** la forma completa, pero depende del ancho de los bins. Conviene probar más de uno.
- **Boxplot:** comprime todo a cinco números y **esconde la multimodalidad**. Un boxplot no distingue el primer panel del segundo de la lámina anterior.
- **Densidad:** ideal para **superponer** grupos; suaviza, y el grado de suavizado es una elección nuestra.

Asimetría: cuándo conviene cambiar de escala



Qué aparece al cambiar la escala

En escala original, casi todos los datos se aplastan contra el eje y solo se distingue la cola. En logaritmos la distribución se vuelve aproximadamente simétrica: recién ahí se pueden comparar grupos y ver modas.


Con **montos** (ingresos, ventas, PBI), el log suele ser la escala natural, no un truco cosmético.

Dos variables: buscar relaciones

Dos numéricas: el scatterplot

Salario horario y edad, ocupados de 18 a 65 años

Escala logarítmica; línea: suavizado loess; muestra de 4.000 casos




Las preguntas: ¿hay asociación?, ¿de qué signo?, ¿es lineal?, ¿hay grupos?, ¿hay extremos?, ¿la relación **cambia** según el nivel de x ? Acá el perfil sube, se aplana y cae: la correlación de 0,15 con el log del salario **no describe** esa forma.

Por qué no alcanza con el coeficiente de correlación

El cuarteto de Anscombe


Misma media, mismo desvío, misma correlación (0,816) y la misma recta ajustada



La moraleja

Los cuatro conjuntos tienen **estadísticos idénticos** y estructuras completamente distintas: una relación lineal, una curva, una recta arruinada por un outlier, y una nube donde un único punto genera toda la pendiente. **Graficar no es opcional.**

Una numérica y una categórica



La pregunta deja de ser “¿cuánto vale la variable?” y pasa a ser “¿**cómo cambia toda su distribución** según el grupo?”. Acá se ven a la vez el gradiente educativo y, dentro de cada nivel, una brecha por sexo: en la mediana general, las mujeres ganan 6,8% menos por hora.

Dos categorías: la tabla de contingencia

Nivel educativo	Ocupado (%)	Desocupado (%)	Inactivo (%)
Hasta sec. incompleto	61,8	5,5	32,7
Sec. comp. / univ. inc.	65,2	5,4	29,4
Univ. completo	84,1	2,9	12,9

La decisión que cambia la lectura: ¿porcentaje sobre qué?

La misma tabla admite tres versiones — % sobre el total, % por fila, % por columna — y **cada una responde una pregunta distinta**. Acá el % por fila responde: *dado* un nivel educativo, ¿cómo se reparte la condición de actividad? La versión por columna respondería otra cosa: *dados* los desocupados, ¿qué educación tienen?

Población de 18 a 65 años, sin ponderar. Con PONDERA los números cambian: **estas son proporciones de la muestra, no de la población.**

La tercera variable: condicionar cambia las conclusiones

Nivel	Varones	Mujeres	Brecha
Sin instr.	3.753	4.619	23,1%
Prim. inc.	3.849	4.042	5,0%
Prim. comp.	4.619	3.695	-20,0%
Sec. inc.	4.619	3.774	-18,3%
Sec. comp.	5.081	4.491	-11,6%
Univ. inc.	5.774	5.132	-11,1%
Univ. comp.	8.661	7.698	-11,1%

Medianas de salario horario, en pesos.

Qué muestra la apertura

La brecha global es de **6,8%**, pero **no es la misma en todos los niveles**: en los dos más bajos incluso **cambia de signo**. Un solo número escondía esa heterogeneidad.

Paradoja de Simpson

Una relación agregada puede **invertirse** al abrir por una tercera variable. Por eso el EDA no termina en pares: siempre hay que preguntar **para quién** vale lo que encontramos.

En R base son dos líneas: `boxplot(y ~ g1 + g2)` para cruzar dos grupos, o `par(mfrow = c(1, 2))` para poner un panel al lado del otro **con la misma escala**.

Valores atípicos

¿Por qué esta observación es tan distinta de las demás?

Cuatro orígenes posibles de un outlier

- ❶ **Error de carga:** un cero de más, una coma mal puesta, unidades mezcladas.
- ❷ **Código de no respuesta** leído como número: los -9 y 999 de hace cinco láminas.
- ❸ **Observación legítimamente extrema:** existe gente que gana eso.
- ❹ **El fenómeno interesante:** a veces el caso raro es la pregunta de investigación.

La regla

Un outlier **no es** un dato malo por definición. Antes de tocarlo hay que averiguar **qué es**, y cualquier decisión que se tome (recortar, winsorizar, dejarlo, analizarlo aparte) tiene que quedar **escrita en el código y declarada en el informe**.

En estos datos el ingreso máximo declarado es \$40.000.000 mensuales, 50 veces la mediana. No es evidente si es error o riqueza: **la única salida es ir a mirar esa fila entera** — rama de actividad, horas, ingreso del hogar — antes de decidir.

Qué hacer con lo que encontramos

Decisiones defendibles

- Reportar los resultados **con y sin** los casos extremos.
- Usar estadísticos **robustos**: mediana, rango intercuartil, cuantiles.
- Cambiar de **escala** en lugar de borrar.
- Analizar los extremos como **grupo propio**.

Decisiones indefendibles

- Borrar todo lo que caiga fuera de los bigotes del boxplot **porque sí**.
- Recortar hasta que el resultado dé lo que esperábamos.
- Limpiar a mano, sin dejar registro en el código.
- No decir en el informe cuántos casos se sacaron.

La diferencia no está en la técnica, sino en si la decisión se toma antes o después de ver el resultado.

Cierre

Del dato a la hipótesis

EDA $\longrightarrow$ Hipótesis $\longrightarrow$ Modelo

Un ejemplo con lo que vimos hoy

- **EDA:** el salario horario crece con el nivel educativo, y la brecha por sexo **no es igual** en todos los niveles.
- **Hipótesis:** parte de esa brecha estaría asociada a la composición por educación, ocupación y horas trabajadas, y otra parte no.
- **Análisis posterior:** un modelo que controle por esas características, con inferencia sobre los coeficientes — y, si el estadístico no tiene fórmula cerrada, bootstrap.

El EDA no reemplaza al modelo: decide cómo se construye

Qué variables usar, qué transformaciones aplicar, qué casos excluir y por qué, qué subgrupos mirar por separado y qué supuestos del modelo son plausibles con estos datos.

Seis preguntas para llevarse

- 1 **¿Qué representa una fila?** Si no lo sé, ningún promedio significa nada.
- 2 **¿Qué le falta a esta base, y a quién le falta?** Los faltantes casi nunca son aleatorios.
- 3 **¿Miré la distribución o solo los estadísticos?** Anscombe, cada vez.
- 4 **¿La relación que encontré vale para todos los grupos?** Abrir por una tercera variable.
- 5 **¿Los extremos son errores o información?** Ir a mirar la fila antes de decidir.
- 6 **¿Estoy explorando o confirmando?** Encontrar un patrón explorando no lo convierte en un resultado.

En una línea

El EDA es el trabajo de convertir una base en preguntas. Todo lo demás viene después.