

Ciencia de Datos para Economía y Negocios - FCE-UBA

Clase 9 — Inferencia estadística: ANOVA, chi-cuadrado y tests no paramétricos

Nicolás Sidicaro

Apertura

Un test no se elige por costumbre: se elige a partir de la pregunta.

Dónde estamos

En la clase 7 construimos distribuciones nulas **simulando** (permutación). Hoy vemos los tests clásicos que resuelven las preguntas más frecuentes con una distribución nula que viene de la **teoría**: F y χ^2 .

Las tres preguntas de hoy

- ¿El salario horario **difiere entre regiones**? → ANOVA, y después **Tukey** para saber cuáles.
- ¿Y si los datos tienen outliers y colas pesadas? → **Tests no paramétricos**.
- ¿El nivel educativo está **asociado** a la condición de actividad? → **Chi-cuadrado**.

Hoja de ruta

- 1 Apertura
- 2 Repaso: la lógica del test de hipótesis
- 3 Comparar varios grupos: ANOVA de un factor
- 4 Después del ANOVA: comparaciones post-hoc con Tukey
- 5 Tests no paramétricos
- 6 Chi-cuadrado de independencia
- 7 ¿Qué test uso?
- 8 El problema de hacer muchos tests
- 9 Integración

Los ejemplos con datos reales usan la **EPH, primer trimestre de 2026** (INDEC): 13.699 ocupados de 18 a 65 años con ingreso y horas válidas, y 27.712 personas de 18 a 65 años para la condición de actividad. Todos los tests son **sin ponderar**.

Repaso: la lógica del test de hipótesis

De los datos a una conclusión

Estadística descriptiva

Resume **lo que observamos**: la mediana del salario horario en la muestra es tal, la brecha entre regiones es tal otra.

Inferencia estadística

Usa la muestra para decir algo sobre la **población**, cuantificando la incertidumbre que introduce haber observado solo una parte.

Un test de hipótesis

Evalúa si los datos son **compatibles** con una afirmación precisa sobre la población (la hipótesis nula).

**No "demostramos" que una hipótesis sea verdadera:
evaluamos qué tan compatibles son los datos con ella.**

La receta: cinco pasos


- 1 Planteo H_0 .
- 2 Planteo H_1 .
- 3 Calculo un **estadístico de prueba**.
- 4 Obtengo el **p-valor** con la distribución del estadístico **bajo** H_0 .
- 5 Decido si rechazo o no rechazo H_0 .

Para pensar

¿Qué significa, **exactamente**, que $p = 0,03$?

Distribución del estadístico si H_0 fuera verdadera

Lo que produciría el azar muestral si no hubiera efecto



H_0 , H_1 y p-valor: un ejemplo

¿El salario horario promedio difiere entre varones y mujeres?

$$H_0 : \mu_V = \mu_M$$

$$H_1 : \mu_V \neq \mu_M$$

p-valor

Probabilidad de observar una diferencia **tan extrema como la obtenida, o más, suponiendo que H_0 es cierta.**

$$p = P(|T| \geq |t_{obs}| \mid H_0)$$

Tres aclaraciones que no son opcionales


- El p-valor **no** es la probabilidad de que H_0 sea verdadera: $P(\text{datos} \mid H_0) \neq P(H_0 \mid \text{datos})$.
- p **pequeño** $\rightarrow$ los datos son poco compatibles con H_0 : evidencia en su contra.
- p **grande** $\rightarrow$ no hay evidencia suficiente para rechazar H_0 . **No** prueba que H_0 sea cierta.

Ley de los Grandes Números

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \longrightarrow E(X) \quad \text{cuando } n \rightarrow \infty$$


Promedio acumulado, 8 trayectorias

Datos exponenciales de media 10 (línea roja)



3.000 promedios para cada tamaño de muestra

Misma población, distinto n



Pregunta: ¿qué pasa con la variabilidad del promedio cuando n crece? Cae con $\sigma/\sqrt{n}$: multiplicar n por 10 divide el desvío por $\sqrt{10} \approx 3,2$.

Teorema Central del Límite

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0,1)$$

La idea


No importa tanto la distribución de X : la distribución del **promedio muestral** tiende a ser aproximadamente normal.

Conexión con hoy

Es una de las razones por las que podemos hacer inferencia sobre **medias** (t-test, ANOVA) aunque los datos individuales no sean normales. Con asimetría fuerte, hace falta más n .

Promedio estandarizado, 5.000 muestras por celda

Línea roja: $N(0,1)$. Filas: población de origen.




Comparar varios grupos: ANOVA de un factor

Una pregunta frecuente

Salario horario de la ocupación principal, por región

EPH 1T 2026, escala logarítmica. Punto rojo: media geométrica.



Una variable **cuantitativa**: salario_hora.

Una variable **categorica**: region, con 6 grupos.

La pregunta

¿Las diferencias entre grupos son suficientemente grandes como para no atribuir las al **azar muestral**?

¿Por qué no hacer t-tests de a pares?

La cuenta

Con k grupos hay $\binom{k}{2} = \frac{k(k-1)}{2}$ pares. Con 6 regiones: **15 t-tests**.


El problema

Cada test tiene 5% de falso positivo. Si **ninguna** región difiere, con 15 tests la probabilidad de encontrar al menos una diferencia "significativa" ronda el 36% (simulado).

Primero conviene una pregunta **global**: ¿hay alguna diferencia? Eso es el ANOVA.

P(al menos un falso positivo)

Todos los grupos iguales (H_0 verdadera), $n = 20$ por grupo



ANOVA: la pregunta

Hipótesis

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_k$$

H_1 : al menos una media es diferente

Importante

El ANOVA **no dice qué grupos son diferentes**. Solo evalúa si hay evidencia de **alguna** diferencia. Rechazar H_0 es compatible con que difieran todas las medias, o con que una sola se aparte del resto.

Por qué se llama "análisis de la varianza" si compara medias


Porque para decidir si las medias difieren **compara dos varianzas**: la que hay entre los grupos y la que hay dentro de ellos.

La idea: descomponer la variabilidad

$$\underbrace{\sum_j \sum_i (y_{ij} - \bar{y})^2}_{SC_{total}} = \underbrace{\sum_j n_j (\bar{y}_j - \bar{y})^2}_{SC_{entre}} + \underbrace{\sum_j \sum_i (y_{ij} - \bar{y}_j)^2}_{SC_{dentro}}$$


Dentro de grupos

Cada punto contra la media de su grupo. SC = 92,0



Entre grupos

Medias de grupo contra la media general. SC = 55,1




Dentro = distancia de cada dato a su media de grupo (ruido). **Entre** = distancia de las medias de grupo a la media general (señal). Acá: $147,1 = 55,1 + 92,0$.

Las mismas medias no alcanzan para decidir

Medias de grupo idénticas en los dos paneles: 10, 12 y 14

Lo único que cambia es la dispersión dentro de cada grupo



La moraleja

Una diferencia de 2 unidades entre medias es **enorme** si los datos varían ± 1 alrededor de su media, y **poco distinguible del azar** si varían ± 4 . La señal se mide **en relación con el ruido**.

El estadístico F

$$F = \frac{\text{variabilidad entre grupos}}{\text{variabilidad dentro de grupos}} = \frac{SC_{entre}/(k-1)}{SC_{dentro}/(N-k)} = \frac{CM_{entre}}{CM_{dentro}}$$

Bajo H_0

$F \sim F_{k-1, N-k}$, si se cumplen los supuestos. El p-valor es el área a la derecha del F observado: **solo importan los valores grandes**.

Fuente	SC	gl	CM	F	p-valor
Entre grupos	55,1	2	27,57	8,10	0,002
Dentro de grupos	92,0	27	3,41		
Total	147,1	29			

Interpretación

- $F \approx 1$: las medias difieren tanto como cabría esperar por el ruido interno.
- F **grande**: las medias están muy separadas respecto de la variabilidad interna.


¿Por qué ≈ 1 bajo H_0 ?

Si las medias poblacionales son iguales, CM_{entre} y CM_{dentro} estiman **la misma varianza**.


Simulación: separar las medias, mismo ruido

Tres grupos de 15 con el mismo ruido; las medias poblacionales se separan

Medias poblacionales: 10 – separación, 10 y 10 + separación. Desvío = 2.




Distribución F(2, 42) bajo H0. Rojo: 5% más extremo ($F > 3,22$). Punteadas: F de cada panel.



¿De dónde sale la distribución F?

Histograma: F de 5.000 permutaciones de etiquetas. Curva roja: F teórica.

Datos del panel con separación = 1



Es la receta de la clase 7

El histograma de permutación y la curva $F_{2,42}$ **coinciden**. p-valor por permutación: 0,009. p-valor teórico: 0,007. La F es el histograma de permutación **dibujado con una fórmula**, y vale cuando se cumplen los supuestos.

ANOVA sobre la EPH: salario horario por región

Fuente	SC	gl	CM	F	p-valor
Entre regiones	573,0	5	114,592	230,3	< 0,001
Dentro de regiones	6.814,4	13.693	0,498		
Total	7.387,4	13.698			

Lectura del test

Variable: **log del salario horario**. $F = 230,3$ con 5 y 13.693 gl, $p < 0,001$. Rechazamos H_0 : las seis regiones **no** tienen la misma media.

Significativo no es lo mismo que grande

Tamaño del efecto: $\eta^2 = SC_{entre} / SC_{total} = 0,078$. La región explica el 7,8% de la variabilidad del log salario. Con $n = 13.699$, casi cualquier diferencia da p diminuto.

La EPH tiene diseño estratificado y por conglomerados: estos p-valores suponen muestreo aleatorio simple y son **optimistas**. La versión correcta usa `survey::svyglm()` con los ponderadores.

¿Qué supuestos tiene el ANOVA?

- 1 **Independencia** de las observaciones. El más importante, y el que ningún test arregla.
- 2 Variable dependiente **cuantitativa**.
- 3 **Homogeneidad de varianzas** entre grupos. Si falla, usar **ANOVA de Welch** (`oneway.test`).
- 4 **Normalidad de los residuos**: relevante con muestras chicas. Con n grande, el TCL ayuda.


En la EPH

El desvío del log salario va de 0,67 a 0,78 entre regiones (cociente 1,18). Welch: $p < 0,001$. La conclusión no cambia.

Discusión: ¿qué hacemos si los supuestos son muy problemáticos? Transformar (log), Welch, o un test **no paramétrico**.

QQ-plot de residuos estandarizados

Si fueran normales, caerían sobre la recta



Después del ANOVA: comparaciones post-hoc con Tukey

El ANOVA rechazó. ¿Y ahora?

La pregunta siguiente

Sabemos que **alguna** región difiere. Queremos saber **cuáles pares** de regiones difieren, y por cuánto.

El problema, otra vez

Son 15 comparaciones. Hacer 15 t-tests al 5% infla la probabilidad de declarar alguna diferencia falsa. Necesitamos que el **5% valga para la familia entera** de comparaciones, no para cada una.

Tasa de error por familia (FWER)

$$FWER = P(\text{al menos un falso positivo entre todas las comparaciones})$$

Los procedimientos **post-hoc** ajustan las comparaciones para que $FWER \leq \alpha$.

Tukey HSD: la idea

Honestly Significant Difference

En lugar de preguntar si **cada** diferencia es grande, pregunta cómo se distribuye la **mayor** diferencia entre k medias cuando H_0 es verdadera. Esa distribución es el **rango studentizado** q :

$$q = \frac{\bar{y}_{\max} - \bar{y}_{\min}}{\sqrt{CM_{dentro}/n}}$$


Regla de decisión para el par (i, j)

$$|\bar{y}_i - \bar{y}_j| > HSD_{ij} = q_{\alpha; k, N-k} \sqrt{\frac{CM_{dentro}}{2} \left(\frac{1}{n_i} + \frac{1}{n_j} \right)}$$

Si la **mayor** diferencia posible supera el umbral solo un 5% de las veces bajo H_0 , entonces **todas juntas** lo superan como mucho un 5% de las veces.

Con grupos de distinto tamaño se llama **Tukey–Kramer**. Además del test, da **intervalos de confianza simultáneos** para cada diferencia.

Simulación: Tukey controla el error de familia




Los t-tests sin corregir pierden el control rápido. Tukey se mantiene en el 5% **nominal** para cualquier k : el precio es que cada comparación individual exige una diferencia algo mayor.

Tukey sobre la EPH: los 15 pares de regiones

Diferencia en el salario horario (media geométrica), IC 95% simultáneos

Primera región menos segunda. Diferencias del log convertidas a %.



14 de 15 pares difieren significativamente; no se distinguen: Cuyo vs. NOA. Un intervalo que **cruza el cero** es un par cuya diferencia no podemos distinguir del azar.

Cómo se hace y qué alternativas hay

```
modelo <- aov(log(salario_hora) ~ region, data = ocupados)
summary(modelo)           # tabla ANOVA: F y p-valor global
TukeyHSD(modelo)          # pares: diferencia, IC simultáneo, p ajustado
```

Situación	Post-hoc
Todos los pares, varianzas parecidas	Tukey HSD
Todos los pares, varianzas distintas	Games–Howell (rstatix::games_howell_test)
Cada grupo contra un control	Dunnett (multcomp::glht)
Pocas comparaciones elegidas de antemano	t-tests con Bonferroni o Holm (pairwise.t.test)
Después de un Kruskal–Wallis	Dunn (rstatix::dunn_test)

Con este n , los t-tests sin corregir declaran 14 pares significativos y Tukey 14: con muestras grandes la corrección importa menos. Con **muestras chicas** es donde separa resultados reales de ruido.

Tests no paramétricos

¿Qué significa “no paramétrico”?

Idea central

Procedimientos que dependen **menos de supuestos sobre la forma** de la distribución de los datos. En general trabajan con los **rangos** (el orden) en lugar de los valores.

No significa

- "No tienen supuestos": siguen exigiendo **independencia**, y a veces formas similares entre grupos.
- "Siempre son mejores": con datos normales pierden algo de potencia.
- "Sirven para cualquier dato".
- "Testean medianas": en general, no.

Son útiles cuando hay

- Fuerte **asimetría**.
- **Outliers**.
- **Muestras chicas** donde el TCL no alcanza.
- Variables **ordinales** (escalas de satisfacción, rankings).

La idea común: reemplazar valores por rangos

Grupo	Valores	Rangos
A	12 15 18 20 22	1 2 3 5 6
B	19 24 27 30 33	4 7 8 9 10
B con outlier	19 24 27 30 330	4 7 8 9 10

	p t-test	p Mann-Whitney
A vs. B	0,017	0,032
A vs. B con outlier	0,324	0,032

Qué pasó

Cambiamos el 33 por un 330. El grupo B quedó **todavía más arriba**, pero:

- El **t-test** ve una varianza enorme y **deja de rechazar**.
- Los **rangos no cambian**: 330 sigue siendo "el más grande". Mann-Whitney da exactamente lo mismo.

El costo

Los rangos tiran información de magnitud: 34 y 330 valen lo mismo. A veces esa magnitud **es** lo que interesa.

Paramétrico vs. no paramétrico

Pregunta	Paramétrico	Alternativa no paramétrica
Dos grupos independientes	t-test	Mann–Whitney (Wilcoxon rank-sum)
Dos grupos apareados	t-test apareado	Wilcoxon signed-rank
Más de dos grupos	ANOVA	Kruskal–Wallis
Más de dos, medidas repetidas	ANOVA de medidas repetidas	Friedman
Asociación entre dos cuantitativas	Pearson	Spearman
Asociación categórica	—	Chi-cuadrado / Fisher

Kruskal–Wallis no es "ANOVA sin normalidad"

Es, casi literalmente, un **ANOVA sobre los rangos**. Por eso responde otra pregunta: si los grupos tienden a tener valores **más altos o más bajos** que otros, no si sus **medias** son iguales. Solo si las distribuciones tienen la misma forma se lee como diferencia de medianas.

Mann–Whitney: qué testea realmente

El estadístico

U cuenta, entre todos los pares posibles (una observación de cada grupo), **en cuántos gana el primer grupo**:

$$\hat{P}(X > Y) = \frac{U}{n_X n_Y} \quad H_0 : P(X > Y) = 0,5$$

EPH: salario horario de varones vs. mujeres

Medianas: \$ 5.278 (varones) y \$ 4.908 (mujeres). Mann–Whitney: $p < 0,001$.

Tamaño del efecto: tomando un varón y una mujer ocupados al azar, la probabilidad de que el varón gane más por hora es $\hat{P} = 0,524$: significativo, pero **apenas** por encima de 0,5. Es interpretable y no depende de la escala.

Misma media, distinta forma

Simulamos un grupo normal y uno lognormal **con la misma media** ($n = 40$ c/u). El t-test rechaza el 10,8% de las veces (las medias son iguales; algo más del 5% por la asimetría). Mann–Whitney rechaza el 71,2%, porque $P(X > Y) = 0,67 \neq 0,5$. **Ninguno se equivoca: responden preguntas distintas.**

Kruskal–Wallis

El estadístico

Ordenar las N observaciones juntas y comparar el **rango promedio** $\bar{R}_j$ de cada grupo con el rango promedio general:

$$H = \frac{12}{N(N+1)} \sum_{j=1}^k n_j \left(\bar{R}_j - \frac{N+1}{2} \right)^2$$

Bajo H_0 , $H \approx \chi^2_{k-1}$.

EPH: salario horario por región

$H = 1.261,8$ con 5 gl, $p < 0,001$.

Tamaño del efecto: $\varepsilon^2 = H/(N-1) = 0,092$, del mismo orden que el η^2 del ANOVA.

No hizo falta tomar logaritmos: los rangos del salario y los de su log son **idénticos**.


Y después, ¿qué pares?

Igual que con el ANOVA: Kruskal–Wallis solo dice que **algún** grupo difiere. El post-hoc habitual es el **test de Dunn** con corrección de Holm, o `pairwise.wilcox.test(y, g, p.adjust.method = "holm")`.

Simulación: ¿cuándo conviene cada uno?

Proporción de rechazos de H_0 (potencia), 3 grupos de $n = 15$

Grupos desplazados 0, 1 y 2 veces la separación. 2.000 simulaciones por punto.



Con **datos normales**, el ANOVA gana por poco (66% vs. 63% con separación 0,5). Con **datos asimétricos**, Kruskal-Wallis gana por mucho (73% vs. 33%). Con separación 0, los dos respetan el 5%: la diferencia no es de validez sino de **potencia**.

Si los supuestos fallan, hay más de una salida

Estrategia	Cuándo	Qué cuidar
Transformar (log)	Montos con cola derecha: ingresos, ventas	La conclusión es sobre medias geométricas
ANOVA de Welch	Varianzas distintas entre grupos	Sigue comparando medias; pide algo de normalidad
No paramétrico	Outliers, asimetría, n chico, ordinales	Cambia la hipótesis: rangos, no medias
Permutación / bootstrap	Estadístico a medida (mediana, p_{90})	Respetar la estructura de los datos (clase 7)

La regla


La elección se hace mirando los datos y **la pregunta**, antes de ver los p-valores. Probar los cuatro y quedarse con el que "da" es testeo múltiple encubierto.

Chi-cuadrado de independencia

Otra pregunta: dos variables categóricas

Condición de actividad según nivel educativo (%), 18 a 65 años

EPH 1T 2026, 27.712 personas, sin ponderar



Educación: hasta secundario incompleto / secundario completo o universitario incompleto / universitario completo.

Situación laboral: ocupado / desocupado / inactivo.

La pregunta

¿Existe **asociación** entre nivel educativo y situación laboral? ¿O las diferencias entre las barras son azar muestral?

Hipótesis de independencia

Hipótesis

H_0 : nivel educativo y situación laboral son independientes

H_1 : las variables están asociadas

Qué significa independencia

La distribución de una variable es **la misma** en todas las categorías de la otra. En la diapositiva anterior: las tres barras de nivel educativo serían **iguales a la barra del total**.

$$P(\text{fila } i \text{ y columna } j) = P(\text{fila } i) \times P(\text{columna } j)$$

Asociación no es causalidad

Rechazar H_0 dice que las variables **van juntas**. No dice que la educación **cause** la ocupación: edad, región o sexo pueden estar detrás de las dos.

Observados vs. esperados

Para hacer la cuenta con números manejables, tomamos una **muestra aleatoria de 1.000 personas** de la EPH.

Observados (O_{ij})				
	Ocup.	Desoc.	Inact.	Total
Hasta sec. inc.	211	17	111	339
Sec. c. / univ. i.	300	25	142	467
Univ. comp.	171	4	19	194
Total	682	46	272	1.000

Esperados bajo independencia (E_{ij})				
	Ocup.	Desoc.	Inact.	Total
Hasta sec. inc.	231,2	15,6	92,2	339,0
Sec. c. / univ. i.	318,5	21,5	127,0	467,0
Univ. comp.	132,3	8,9	52,8	194,0
Total	682,0	46,0	272,0	1.000,0

De dónde sale cada esperado

$$E_{ij} = \frac{(\text{total fila}_i)(\text{total columna}_j)}{\text{total general}}$$

univ. comp. y desocupado: $\frac{194 \times 46}{1.000} = 8,9$ (observados: 4)

Los esperados mantienen **los mismos totales** de fila y columna: solo redistribuyen las celdas como si no hubiera asociación.

El estadístico chi-cuadrado

$$\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

Intuición

Cuanto más lejos está lo observado de lo esperado bajo independencia, mayor es χ^2 . Dividir por E_{ij} pone las celdas en la misma escala: una diferencia de 10 pesa más donde se esperaban 20 que donde se esperaban 500.

Bajo H_0

$\chi^2 \approx \chi^2_{(r-1)(c-1)}$. Acá: $(3-1)(3-1) = 4$ gl.

Aporte de cada celda a χ^2

	Ocup.	Desoc.	Inact.
Hasta sec. inc.	1,76	0,13	3,83
Sec. c. / univ. i.	1,07	0,58	1,77
Univ. comp.	11,32	2,72	21,61

Resultado

$\chi^2 = 44,8$, 4 gl, $p < 0,001$. Rechazamos independencia.


Tamaño del efecto (V de Cramér):

$$V = \sqrt{\chi^2 / (n \cdot (\min(r, c) - 1))} = 0,15.$$

¿De dónde sale la distribución χ^2 ?

Histograma: 5.000 permutaciones. Curva roja: chi-cuadrado con 4 gl.

Mezclar al azar la situación laboral rompe la asociación y deja fijos los totales



Otra vez la receta de la clase 7

p-valor por permutación: $p = 0,0002$ (el mínimo posible con 5.000 permutaciones es $1/5001$). La curva χ^2 aproxima muy bien el histograma porque los esperados son grandes: el menor es 8,9.

¿Dónde está la asociación? Residuos estandarizados

Residuos estandarizados, toda la EPH

(O - E) / error estándar. $|res| > 2$: la celda se aparta de H0

Hasta sec. incompleto	-14,4	3,0	13,6
Sec. comp. / univ. inc.	-9,4	3,3	8,2
Univ. completo	28,5	-7,6	-26,2
	Ocupado	Desocupado	Inactivo

Con las 27.712 personas

$$\chi^2 = 848, p < 0,001, V = 0,12.$$

Cómo leer el mapa

Rojo: hay **más** casos que los esperados bajo independencia. **Azul:** hay **menos**. El chi-cuadrado dice **si** hay asociación; los residuos dicen **dónde** está.

Es el equivalente del post-hoc para tablas:
mirar celdas en lugar de pares de medias.

Condiciones y advertencias

Condiciones

- **Independencia:** cada persona aparece en una sola celda.
- Se trabaja con **conteos**, nunca con porcentajes.
- Esperados **grandes**: regla práctica, todos $E_{ij} \geq 1$ y al menos el 80% ≥ 5 .

Si los esperados son chicos

Test exacto de Fisher (`fisher.test`), agrupar categorías, o el p-valor por simulación de `chisq.test(tabla, simulate.p.value = TRUE)`.

El problema del n grande

Con la muestra de 1.000 personas, $\chi^2 = 44,8$. Con toda la EPH, $\chi^2 = 848$. La asociación es parecida (V de 0,15 y 0,12); lo que cambió es el n .

χ^2 crece **proporcionalmente al tamaño de muestra**. Por eso siempre se reporta junto con un tamaño del efecto: V de Cramér (0 = independencia, 1 = asociación perfecta).

¿Qué test uso?

Árbol de decisión

¿Qué variables tengo?	¿Qué pregunta?	Test (supuestos OK → si fallan)
Cuantitativa + categórica (comparar grupos)	2 grupos independientes 2 grupos apareados > 2 grupos ¿Cuáles difieren?	t-test → Mann-Whitney t apareado → Wilcoxon signed-rank ANOVA / Welch → Kruskal-Wallis Tukey → Dunn
Categórica + categórica	¿Están asociadas? ¿Dónde?	Chi-cuadrado → Fisher (esperados chicos) Residuos estandarizados
Cuantitativa + cuantitativa	¿Se mueven juntas?	Correlación / regresión (próximas clases)

Antes del árbol: dos preguntas que lo condicionan todo

¿Las observaciones son **independientes** o **apareadas** (antes/después, la misma persona dos veces)? ¿Cuál es la **variable resultado** y cuál define los grupos?

Tabla resumen

Pregunta	Variables	Test	Efecto
¿Dos medias son diferentes?	Cuanti + 2 grupos	t-test	d de Cohen
¿Varias medias son diferentes?	Cuanti + > 2 grupos	ANOVA	η^2
¿Qué pares de medias difieren?	Cuanti + > 2 grupos	Tukey HSD	IC de diferencias
¿Dos grupos difieren, sin normalidad?	Cuanti + 2 grupos	Mann–Whitney	$P(X > Y)$
¿Varios grupos difieren, sin normalidad?	Cuanti + > 2 grupos	Kruskal–Wallis	ε^2
¿Dos categóricas están asociadas?	Categ. + categ.	Chi-cuadrado	V de Cramér

**El test no se elige por costumbre:
se elige a partir de la pregunta y del tipo de variables.**

Las funciones en R

```
t.test(y ~ grupo, data = d)           # Welch por defecto
wilcox.test(y ~ grupo, data = d)      # Mann-Whitney
wilcox.test(antes, despues, paired = TRUE) # Wilcoxon signed-rank

modelo <- aov(y ~ grupo, data = d); summary(modelo)
oneway.test(y ~ grupo, data = d)      # ANOVA de Welch
TukeyHSD(modelo)                      # post-hoc
kruskal.test(y ~ grupo, data = d)
pairwise.wilcox.test(d$y, d$grupo, p.adjust.method = "holm")

tabla <- table(d$educacion, d$estado)
chisq.test(tabla)$expected             # chequear esperados
chisq.test(tabla)$stdres               # residuos estandarizados
fisher.test(tabla)

p.adjust(p_valores, method = "BH")    # testeo múltiple
```

El problema de hacer muchos tests

¿Qué pasa si hago muchos tests?

Pregunta

Si hago 20 tests con $\alpha = 0,05$ y en **ninguno** hay efecto real, ¿qué probabilidad tengo de obtener al menos un falso positivo?

$$1 - (1 - 0,05)^{20} \approx 64\%$$


La idea

Cuanto más tests hacemos, más probable es encontrar "algo significativo" **solo por azar**.


A la derecha, abajo: un estudio simulado con 20 variables de **ruido puro**, comparando dos grupos de 30. Salió 1 "hallazgo".

P(al menos un falso positivo)

Línea: fórmula. Puntos: simulación.



Un estudio con 20 variables sin efecto



Correcciones por testeo múltiple

Bonferroni

Con m tests, rechazar solo si

$$p < \alpha^* = \frac{\alpha}{m}$$

Controla la **FWER**: probabilidad de **al menos un** falso positivo.

- + Muy simple, vale siempre.
- Muy conservador con m grande: pierde efectos reales.

Benjamini–Hochberg (FDR)

Ordenar los p-valores $p_{(1)} \leq \dots \leq p_{(m)}$ y buscar el mayor i tal que

$$p_{(i)} \leq \frac{i}{m} \alpha$$

Rechazar los i primeros. Controla la **FDR**: proporción esperada de falsos descubrimientos **entre los rechazados**.

- + Descubre más efectos.
- Tolera algunos falsos positivos.


La diferencia conceptual

Bonferroni: "no quiero **ningún** error". FDR: "acepto que el 5% de mis hallazgos sean falsos, a cambio de encontrar más". **Holm** controla la FWER igual que Bonferroni y nunca rechaza menos.

Simulación: 100 variables, 10 efectos reales

Una corrida: los 25 p-valoros más chicos, ordenados

Rechazos: sin corrección 14, Bonferroni 4, BH 7 (hasta el último punto debajo de su línea)



Método	Efectos reales detectados (de 10)	Falsos positivos (de 90)	FDR	P(al menos un FP)
Sin corrección	9,3	4,5	31,0%	99%
Bonferroni	4,3	0,0	1,0%	4%
Benjamini-Hochberg	6,8	0,4	4,7%	32%

¿Cuándo preocuparse por el testeo múltiple?

No hace falta corregir cada vez que hay más de un p-valor

Si tenemos **una o dos hipótesis** definidas de antemano, cada una con su justificación, se reportan tal cual.

Es especialmente importante cuando

- Hacemos **muchas hipótesis simultáneas** sobre la misma pregunta.
- **Exploramos** muchas variables buscando cuáles "dan".
- Hacemos **muchas comparaciones entre grupos** (el caso de Tukey).
- Abrimos un resultado por subgrupos: por región, por sexo, por edad... hasta que alguno sale.

Ejemplo

Tengo 100 variables y quiero identificar cuáles están asociadas con una variable resultado. Sin corrección, esperaríamos unos 5 "hallazgos" aunque **ninguna** lo esté. Acá la FDR cobra toda su importancia.

Integración

¿Qué test elegirías?

- 1 Comparar el **salario horario** entre **varones y mujeres**.
- 2 Comparar el **salario horario** entre **cinco niveles educativos**.
- 3 Evaluar la asociación entre **nivel educativo** y **participación laboral** (activo / inactivo).
- 4 Comparar **ingresos** entre **tres grupos** con fuertes outliers, distribuciones muy asimétricas y 12 casos por grupo.
- 5 Evaluar **50 variables** de la EPH y determinar cuáles están asociadas con estar desocupado.

Para cada caso

¿Qué tipo de variables? ¿Cuántos grupos? ¿Qué test? ¿Qué problema adicional aparece?

Posibles respuestas

Caso	Test	Qué discutir
1	t-test (Welch) sobre el log, o Mann–Whitney	Asimetría del salario; con n grande el p-valor será diminuto: reportar la brecha y su IC
2	ANOVA sobre el log + Tukey, o Kruskal–Wallis + Dunn	El nivel educativo es ordinal : una tendencia (regresión) puede ser más informativa que 10 pares
3	Chi-cuadrado de independencia	Mirar residuos y V de Cramér; asociación no es causalidad (edad, sexo)
4	Kruskal–Wallis (o permutación)	Con $n = 12$ y outliers el TCL no alcanza; ANOVA pierde potencia
5	Un test por variable + corrección	Testeo múltiple : BH si el objetivo es explorar, Bonferroni/Holm si cada falso positivo es costoso

Checklist: antes de hacer un test

- 1 ¿Cuál es mi **pregunta**?
- 2 ¿Cuál es mi **variable resultado**?
- 3 ¿Qué **tipo de variables** tengo?
- 4 ¿Cuántos **grupos** estoy comparando?
- 5 ¿Son **independientes** o **apareados**?
- 6 ¿Qué **supuestos** tiene el test? ¿Los miré en un gráfico?
- 7 ¿Necesito una alternativa **no paramétrica**?
- 8 ¿Estoy haciendo **muchas pruebas**?
- 9 ¿Qué significa el **p-valor** en este contexto, y cuál es el **tamaño del efecto**?

Y después del test

Si rechacé con más de dos grupos: ¿**cuáles** difieren? (post-hoc, residuos). Si no rechacé: ¿tenía **potencia** para detectar un efecto relevante?

Tres ideas para llevarse

- 1 **Un test de hipótesis no "prueba" H_0 :** evalúa la evidencia en su contra. No rechazar no es lo mismo que confirmar.
- 2 **El test depende de la pregunta, del tipo de variables y de los supuestos.** ANOVA, Kruskal–Wallis y chi-cuadrado son la misma receta —estadístico + distribución nula— con distinto relleno.
- 3 **Un resultado estadísticamente significativo no implica un efecto grande o relevante.** Con la EPH todo da $p < 0,001$: lo que informa es η^2 , V , $P(X > Y)$ y los intervalos.

Primero la pregunta, después el test, siempre el tamaño del efecto.

Mini ejercicio con la EPH

Para cada situación: (1) identificar la pregunta, (2) identificar las variables, (3) elegir el test, (4) formular H_0 y H_1 , (5) interpretar qué significaría obtener $p < 0,05$.

- 1 ¿El salario horario difiere según la **categoría ocupacional** (patrón, cuenta propia, asalariado)? (CAT_OCUP)
- 2 ¿La **condición de actividad** está asociada con el **sexo**? (ESTADO, CH04)
- 3 ¿Las **horas trabajadas** difieren entre varones y mujeres ocupados? (PP3E_TOT)
- 4 ¿La **tasa de desocupación** es la misma en las seis regiones? ¿Cuáles se diferencian?
- 5 Si repito el test del punto 1 **dentro de cada uno de los 31 aglomerados**, ¿qué cambia en la interpretación?