

Ciencia de Datos para Economía y Negocios - FCE-UBA

Clase 12 — Datos faltantes, outliers y transformaciones

Nicolás Sidicaro

¿Por qué importa la calidad de los datos?

Basura entra, basura sale

Situaciones típicas con datos reales

- En la EPH, el 19,0% de los ocupados **no declara** su ingreso, y ese dato viene como -9 , no como NA.
- Un dataset de empresas tiene **ventas negativas** o con un cero de más por errores de carga.
- Hay personas con **edad = 999** o **salario = 0** que distorsionan todo.
- Faltan datos, pero **no al azar**: quien no declara ingresos no es una persona promedio.

La buena noticia

Con un **marco claro** para diagnosticar y tratar estos problemas, podemos tomar decisiones informadas en lugar de ignorarlos (o peor, no darnos cuenta).

Hoja de ruta de la clase

- ➊ **Datos faltantes:** tipos (MCAR, MAR, MNAR), diagnóstico y visualización. Un caso real con la EPH.
- ➋ **Outliers:** detección con IQR y z-score, y por qué conviene mirarlos en escala log.
- ➌ **Qué hacer:** eliminar, imputar (media, regresión, MICE) o mantener.
- ➍ **Transformaciones:** log, **estandarización vs normalización**, escalado robusto.
- ➎ **Justificación e impacto:** cómo medir, reportar y documentar estas decisiones.

Idea que atraviesa la clase

Limpiar datos **no es una tarea mecánica**. Cada decisión cambia los resultados, así que cada decisión tiene que tener una razón y quedar escrita.

Dataset de ejemplo

Vamos a trabajar con un dataset **simulado** de 200 empresas. La ventaja de simular: conocemos la verdad y podemos ver qué tan bien la recupera cada método.

```
empresas <- tibble(  
  empresa      = paste0("Empresa_", 1:200),  
  sector       = sample(c("Industria", "Comercio", "Servicios", "Agro"), 200, replace = TRUE),  
  empleados    = round(rlnorm(200, meanlog = 3.5, sdlog = 1.2)) + 1,  
  antiguedad   = sample(1:80, 200, replace = TRUE),  
  ventas_mm    = round(exp(-0.8 + 0.8 * log(empleados) + efecto_sector + rnorm(200, 0, 0.7))), 1)  
)  
  
# Faltantes: las empresas chicas reportan menos sus ventas (MAR);  
#           10 empresas sin dato de empleados, al azar (MCAR)  
# Errores de carga: empleados = 50.000 y 75.000; ventas = 5.000 y 8.000
```

Lo que sabemos (y en un dataset real no sabríamos)

Faltan 39 datos de ventas (19,5%) y 10 de empleados. Las ventas dependen del tamaño y del sector.

Datos faltantes (missing values)

¿Qué es un NA en R?

Definición

NA (*Not Available*) es el valor que R usa para representar **datos faltantes**. No es cero, no es vacío, no es un string: es la *ausencia* de información.

¿Por qué no ignorarlos?

- Muchas funciones devuelven NA si hay un solo faltante: `mean(c(1, 2, NA))` da NA.
- Con `na.rm = TRUE` el problema desaparece de la pantalla, **no de los datos**.
- Si eliminamos filas sin pensar, podemos **sesgar** el análisis.

Los faltantes disfrazados

- Códigos de no respuesta: -9, 99, 999, "NS/NR".
- Ceros que no son ceros: "salario = 0" porque no contestó.
- Strings vacíos "" o "-".

Primer paso: convertirlos a NA con `na_if()` o `if_else()`, leyendo el diseño de registro (como vimos en la clase 8).

Contar los faltantes

```
# Cantidad y porcentaje de NA por columna
```

```
empresas |>
```

```
  summarise(across(everything(), ~ sum(is.na(.x)))) |>
```

```
  pivot_longer(everything(), names_to = "variable", values_to = "n_na") |>
```

```
  mutate(pct_na = round(100 * n_na / nrow(empresas), 1))
```


```
# A tibble: 5 x 3
```

	variable <chr>	n_na <int>	pct_na <dbl>
1	empresa	0	0
2	sector	0	0
3	empleados	10	5
4	antigüedad	0	0
5	ventas_mm	39	19.5


Atajos útiles: `summary(base)` muestra los NA's por columna; `naniar::miss_var_summary(base)` y `naniar::vis_miss(base)` hacen la tabla y el gráfico en una línea.

Visualizar el patrón de faltantes

Porcentaje de faltantes



Mapa de faltantes, empresas ordenadas por tamaño



Truco: ordenar las filas por otra variable. Si los faltantes de `ventas_mm` se amontonan abajo (empresas chicas), el patrón **no es azaroso**. En `empleados` se reparten parejo.

Los tres tipos de datos faltantes

MCAR: Missing Completely At Random

La probabilidad de que un dato falte **no depende de nada**: ni del valor faltante ni de otras variables. Ejemplo: se pierde un formulario por accidente.

MAR: Missing At Random

La probabilidad de que falte depende de **otras variables observadas**, pero no del valor faltante en sí (una vez que controlamos por esas variables). Ejemplo: las empresas chicas no reportan ventas; el tamaño sí lo observamos.

MNAR: Missing Not At Random


La probabilidad de que falte depende del **propio valor faltante**. Ejemplo: las personas con ingresos altos no declaran su ingreso *porque* es alto.

El nombre *MAR* confunde: **no** significa “al azar” en el sentido cotidiano. Significa “al azar *dentro* de grupos que podemos observar”.

Mismo 30% de faltantes, tres historias distintas

Distribución del ingreso: población completa vs. quienes responden

En los tres paneles falta el 30% de los datos



- **MCAR:** las curvas coinciden. Perdemos precisión, no exactitud.
- **MAR:** faltan más los educados, que ganan más. La media observada está sesgada, **pero** la educación la observamos.
- **MNAR:** faltan los ingresos altos *por ser altos*. Nada de lo que observamos lo explica del todo.

¿Por qué importa el tipo?

Mecanismo	Eliminar filas con NA	Imputar con regresión sobre educación
MCAR	+1,5%	+2,0%
MAR	-11,8%	+0,2%
MNAR	-22,4%	-18,3%

Sesgo de la media de ingresos respecto de la verdad, en la simulación anterior.

Consecuencias según el tipo

- **MCAR**: eliminar filas con NA no genera sesgo (pero se pierde poder estadístico).
- **MAR**: eliminar sesga, pero **imputar con las variables que explican el faltante** lo corrige.
- **MNAR**: ni eliminar ni imputar lo resuelve. Imputar achica el sesgo solo en la medida en que las variables observadas se correlacionan con el ingreso.

MAR y MNAR: casos concretos

MAR: ejemplos

- **EPH:** los **ocupados** están menos en el hogar y responden menos. La no respuesta depende del estado ocupacional, que conocemos por otros miembros del hogar.
- **Encuestas de satisfacción:** los clientes **jóvenes** completan menos. Depende de la edad (observada), no de la satisfacción.
- **Balances:** las PyMEs chicas no publican estados contables. Depende del **tamaño/sector** (observables).

MNAR: ejemplos


- **Ingresos altos:** se sub-declaran *porque* son altos.
- **Evasión fiscal:** las empresas que más evaden son las que menos reportan.
- **Deserción escolar:** quien abandona no completa la encuesta de cierre; su bajo aprendizaje causa el faltante.
- **Estudios clínicos:** los pacientes más graves dejan de reportar.

¿Qué hacer con MNAR?


No se corrige solo con lo observado. Opciones: modelos de selección (Heckman), **análisis de sensibilidad** ("si los que no responden ganaran un 20% más, ¿cambia la conclusión?"), o al menos una **variable indicadora** del faltante y un reporte explícito del sesgo posible.

¿Cómo diagnosticar el tipo?

% sin dato de ventas, por tamaño



% sin dato de ventas, por sector




- **Comparar** a los que tienen y no tienen el dato en otras variables: la mediana de empleados es 11 entre las empresas **sin** ventas y 38 entre las que sí reportan. Evidencia de **MAR** por tamaño.
- Si ninguna variable observada se asocia con el faltante, **podría** ser MCAR (test formal: `nanian::mcar_test()`, de Little).
- **MNAR no se puede testear** con los datos: depende de lo que no vemos. Se argumenta con conocimiento del tema.


Un caso real: la no respuesta de ingresos en la EPH

% de ocupados con P21 = -9. Línea: promedio (19,0%). EPH 1T 2026, sin ponderar.

Por región



Por categoría ocupacional



La no respuesta está lejos de ser pareja: varía por región y es mayor entre patrones y cuentapropistas. Depende de variables que **sí observamos**, lo cual es compatible con MAR (aunque no descarta un componente MNAR: los ingresos altos también se sub-declaran).

¿Qué hace el INDEC con esos faltantes?

No imputa valores: reponderar

La EPH trae **ponderadores ajustados por no respuesta** (PONDIIIO para el ingreso de la ocupación principal, PONDII para el ingreso individual total, PONDIIH para el del hogar). El peso de quien no responde se **redistribuye entre respondentes parecidos**. Quien no responde tiene ponderador 0.

Ponderador	Ingreso medio (P21)
PONDERA	\$1.095.162
PONDIIIO	\$1.104.227

Ocupados que responden, EPH 1T 2026.

Moraleja para el TP

Para cualquier estadística de ingresos de la EPH, usar el ponderador de ingresos que corresponde. Usar PONDERA equivale a suponer que la no respuesta es MCAR.

Reponderar es una cuarta estrategia (además de eliminar, imputar y mantener): corrige MAR si los grupos usados para redistribuir capturan el mecanismo.

Outliers: detección y diagnóstico

¿Qué es un outlier?

Definición

Un **outlier** (valor atípico) es una observación que se aleja significativamente del resto de los datos. Puede ser un error de carga o un dato genuinamente extremo.

El dilema clave

- Si es un **error** (alguien puso un cero de más): hay que corregirlo o eliminarlo.
- Si es un dato **real** (una empresa factura 100 veces más que el promedio): eliminarlo sesga el análisis.
- **No hay una regla automática.** Las reglas **marcan candidatos**; decide el analista con contexto del dominio.


Preguntas para cada candidato

¿Es físicamente posible? ¿Es coherente con sus otras variables (una empresa con 3 empleados y ventas de 8.000 MM)? ¿Hay una fuente externa para verificarlo?

Exploración visual: el primer paso


Escala original

11 puntos fuera de los bigotes



Escala logarítmica

4 puntos fuera de los bigotes



En escala original, los dos errores de carga aplastan todo lo demás y el boxplot marca como “atípicas” a muchas empresas grandes **que son genuinas**. En log, la caja se ve y solo sobresalen los valores realmente anómalos. Ventas, ingresos y precios casi siempre conviene mirarlos en log.

Método 1: rango intercuartílico (IQR)

La regla del IQR (Tukey)

- 1 Calcular **Q1** (percentil 25) y **Q3** (percentil 75).
- 2 **IQR** = $Q3 - Q1$.
- 3 Son outliers los valores fuera de $[Q1 - 1,5 \times IQR, Q3 + 1,5 \times IQR]$.

Es el criterio que usa `geom_boxplot()` para dibujar los puntos.

¿Por qué 1,5?

Es una convención. Para datos normales, el intervalo cubre el 99,3% de las observaciones. Con $3 \times IQR$ se marcan outliers "extremos".

Ventaja y límite

Usa cuartiles, así que los propios outliers **no mueven los límites**. Pero supone cierta simetría: con cola derecha larga marca muchos datos genuinos. Solución: aplicarlo sobre $\log(x)$.

IQR en R

```
ventas <- empresas$ventas_mm[!is.na(empresas$ventas_mm)]

lim_inf <- quantile(ventas, 0.25) - 1.5 * IQR(ventas)
lim_sup <- quantile(ventas, 0.75) + 1.5 * IQR(ventas)

empresas |> filter(ventas_mm < lim_inf | ventas_mm > lim_sup)    # candidatos

# Lo mismo sobre el logaritmo (variables con cola derecha)
lv <- log(ventas)
lim_sup_log <- exp(quantile(lv, 0.75) + 1.5 * IQR(lv))           # de vuelta a $
```

	Límite inferior	Límite superior	Candidatos
IQR en escala original	-18,8	44,9 MM	11 de 161
IQR en escala log	0,61 MM	175,5 MM	4 de 161

El límite inferior en escala original es negativo: la regla “no ve” la cola izquierda, porque las ventas no pueden ser negativas.

Método 2: z-score

La idea del z-score

Mide cuántas **desviaciones estándar** se aleja un valor de la media:

$$z_i = \frac{x_i - \bar{x}}{s}$$

Convención: si $|z| > 3$, se considera outlier (asumiendo distribución aproximadamente normal).

Limitaciones

- Supone distribución **simétrica**. Ingresos y ventas suelen tener cola derecha larga.
- La media y el desvío **se calculan con los propios outliers**: un valor enorme infla s y “esconde” a los demás (**efecto masking**).
- Alternativa robusta: usar mediana y MAD, $z_i^{rob} = \frac{x_i - \text{mediana}}{\text{MAD}}$ (en R, `mad()` ya viene escalado para ser comparable con s).

El efecto masking, en números

```
z      <- (ventas - mean(ventas)) / sd(ventas)      # z clásico
z_rob  <- (ventas - median(ventas)) / mad(ventas)    # z robusto
sum(abs(z) > 3); sum(abs(z_rob) > 3)
```

Versión	Desvío de ventas	Casos con $ z > 3$
z clásico, todos los datos	740,0 MM	2
z clásico, sin los 2 valores más grandes	27,4 MM	4
z robusto (mediana y MAD)	—	17
z robusto sobre log(ventas)	—	3


Lectura

Con los dos errores adentro, el desvío se infla y el z-score solo ve a esos dos. Al sacarlos aparecen 4 candidatos nuevos que estaban **enmascarados**. El z robusto, en cambio, marca demasiados en escala original (la asimetría) y se vuelve razonable en log. **La escala importa más que la regla.**

Comparación visual: qué marca cada regla

Las mismas ventas, tres reglas de detección

Eje en escala log para poder ver todos los puntos



El IQR lineal marca 11 empresas, el z-score 2 y el IQR en log 4. Las reglas **no coinciden**, y por eso son un punto de partida: los candidatos se revisan uno por uno.

¿Qué hacer con los problemas?

Las opciones: eliminar, imputar o mantener

Las opciones

- ➊ **Eliminar:** descartar la fila o el valor problemático.
- ➋ **Imputar:** reemplazar el valor faltante (o erróneo) por una estimación.
- ➌ **Mantener:** dejar el dato como está, quizás recortado (winsorizar) o con una indicadora.
- ➍ **Reponderar:** dar más peso a los casos parecidos a los que faltan (como el INDEC en la EPH).

No hay una respuesta universal

La decisión depende de:

- El **tipo de faltante** (MCAR, MAR, MNAR).
- Si el outlier es **error o dato genuino**.
- Cuántos datos se pierden al eliminar.
- El **objetivo del análisis**: describir, predecir o hacer inferencia.

Cuándo eliminar

Eliminar está bien cuando...

- Los NA son **MCAR** y representan un **porcentaje bajo** (menos del 5%).
- El outlier es claramente un **error de carga** (edad = 999, ventas negativas) y no se puede corregir.
- Hay suficientes datos y perder observaciones no afecta la representatividad.

```
# Eliminar filas con NA en ventas (listwise deletion / casos completos)  
empresas_limpio <- empresas |> filter(!is.na(ventas_mm))  
# Ojo: drop_na() sin argumentos elimina la fila si falta CUALQUIER columna  
  
# Eliminar errores evidentes, conservando los NA para tratarlos aparte  
empresas_limpio <- empresas |> filter(ventas_mm < 5000 | is.na(ventas_mm))
```

Recordar: `lm()` y muchas funciones eliminan casos incompletos **en silencio**. Revisar siempre el *n* efectivo del modelo con `nobs(modelo)`.

Imputar: la escalera de métodos

Método	Qué hace	Qué conserva	Qué rompe
Media / mediana	Reemplaza todos los NA por un mismo número	El n	Achica la varianza; aplana relaciones
Por grupo	Mediana dentro de cada sector, región, etc.	Diferencias entre grupos	Varianza dentro del grupo
Regresión	Predice el NA con un modelo sobre otras variables	La media condicional	Exagera correlaciones; achica la varianza
Regresión estocástica	Predicción + un residuo aleatorio	Media, varianza y correlaciones	Trata al valor inventado como si fuera cierto
MICE	Regresión estocástica repetida m veces, encadenada entre variables	Todo lo anterior + la incertidumbre	Más costoso; hay que combinar resultados

Regla

Cuanto más arriba en la tabla, más simple y más distorsiona. Si imputás más del 20–30% de una variable, probablemente esa variable **no sea confiable** para el análisis, con cualquier método.

Imputación simple en R

```
# 1) Mediana global (robusta a outliers)
empresas |> mutate(ventas_imp = coalesce(ventas_mm, median(ventas_mm, na.rm = TRUE)))


# 2) Mediana por grupo
empresas |>
  group_by(sector) |>
  mutate(ventas_imp = coalesce(ventas_mm, median(ventas_mm, na.rm = TRUE))) |>
  ungroup()

# 3) Regresión: ajustar con los casos completos y predecir los faltantes
modelo <- lm(log(ventas_mm) ~ log(empleados) + sector, data = empresas)
empresas |>
  mutate(pred = exp(predict(modelo, newdata = empresas)),
         ventas_imp = coalesce(ventas_mm, pred),
         imputado = is.na(ventas_mm)) # siempre marcar qué se imputó
```

`coalesce(x, y)` devuelve x y, donde x es NA, usa y. Es la forma más legible de imputar.

Cuatro métodos sobre los mismos datos

log(ventas) vs log(empleados): falta el 30% de las ventas (MAR: más en empresas chicas)



- **Media:** una línea horizontal de puntos inventados. Ignora que son empresas chicas.
- **Regresión:** los imputados caen **exactamente sobre la recta**. Demasiado perfectos: nadie real se comporta así.
- **Regresión estocástica y MICE:** se parecen a datos reales. La diferencia está en lo que viene después.

¿Qué método recupera la verdad?

Método	Media log(ventas)	Desvío	Correlación con x	Error estándar de la media
Verdad (sin faltantes)	0,703	1,374	0,404	0,0793
Casos completos	0,844	1,343	0,408	0,0925
Media	0,844	1,126	0,304	0,0650
Regresión	0,659	1,198	0,515	0,0692
Regresión estocástica	0,658	1,365	0,428	0,0788
MICE (m = 20, Rubin)	0,651	1,373	0,454	0,0978

- **Casos completos** sobreestima la media (faltan las chicas) y **media** además achica el desvío y la correlación.
- **Regresión** acierta la media pero **exagera la correlación** y achica el desvío: los puntos inventados no tienen ruido.
- Estocástica y MICE recuperan media, desvío y correlación. Pero solo MICE tiene un **error estándar honesto**: más grande, porque reconoce que no sabemos los valores faltantes.

Regresión vs MICE: ¿para qué sirve cada uno?

	Imputación por regresión	MICE (imputación múltiple)
¿Qué produce?	Una base completa	m bases completas (típicamente 5 a 50)
¿Cuántas variables con NA?	Pensada para una , con predictores completos	Varias a la vez , con cualquier patrón de faltantes
¿Cada valor imputado?	La mejor predicción puntual	Una predicción + ruido, distinta en cada base
¿Incertidumbre?	Se ignora: trata lo imputado como observado	Se incorpora: la variación entre bases entra en el error estándar
¿Para qué sirve?	Completar una variable para describir, graficar, o predecir cada caso	Estimar parámetros con inferencia válida: IC, tests, coeficientes
¿Cuándo usarla?	Pocos NA, un buen modelo predictivo, objetivo descriptivo o predictivo	NA MAR no triviales (más de 5–10%) y objetivo inferencial
Costo	Bajo: un <code>lm()</code> y un <code>predict()</code>	Mayor: correr el análisis m veces y combinar

En una línea

La regresión responde “¿cuál es el valor más probable de este dato?”. MICE responde “¿qué puedo concluir sobre la población, sabiendo que me faltan datos?”. Ninguno de los dos arregla un MNAR.

Cómo funciona MICE por dentro

MICE = Multiple Imputation by Chained Equations

- 1 Rellenar todos los NA con valores provisorios (ej.: al azar entre los observados).
- 2 Para **cada variable con NA**, por turnos: ajustar una regresión sobre las demás y reimputar sus NA con predicción + ruido.
- 3 Repetir el ciclo varias veces (maxit) hasta que se estabilice. Eso da **una** base.
- 4 Hacer todo m veces con distinto azar: m bases.

El “encadenado” es el paso 2: ventas se imputa con empleados, y empleados con ventas.

Reglas de Rubin para combinar

Con $\hat{\theta}_j$ y U_j (estimación y varianza) en cada base:

$$\bar{\theta} = \frac{1}{m} \sum_{j=1}^m \hat{\theta}_j$$


$$T = \underbrace{\bar{U}}_{\text{dentro}} + \left(1 + \frac{1}{m}\right) \underbrace{B}_{\text{entre bases}}$$

B es la varianza de los $\hat{\theta}_j$: si las bases dan resultados muy distintos, hay mucha incertidumbre por los faltantes y el IC se ensancha.

La prueba: ¿cubre el intervalo de confianza?

¿Qué porcentaje de los IC 95% contiene la media real?

400 simulaciones de 300 empresas con 32% de ventas faltantes (MAR). Lo correcto es 95%.



Casos completos y media fallan por **sesgo**. Regresión y regresión estocástica aciertan la media en promedio, pero sus intervalos son **demasiado angostos** porque tratan lo imputado como observado: cubren 86% y 90% en vez de 95%. MICE, con las reglas de Rubin, cubre 97%. **Para hacer inferencia, la imputación simple da falsa precisión.**

MICE en R

```
library(mice)

base <- empresas |>
  mutate(log_ventas = log(ventas_mm), log_empl = log(empleados)) |>
  select(sector, antiguedad, log_ventas, log_empl)      # solo variables útiles

# Paso 1: generar m = 20 bases imputadas
imp <- mice(base, m = 20, method = "pmm", seed = 42)   # pmm: predictive mean matching

# Paso 2: correr el MISMO análisis en cada base
fit <- with(imp, lm(log_ventas ~ log_empl + sector))

# Paso 3: combinar con las reglas de Rubin
summary(pool(fit), conf.int = TRUE)
```

pmm imputa con valores **realmente observados** de casos con predicción parecida: no inventa ventas negativas ni fuera de rango. norm usa regresión bayesiana. **No** promediar las m bases en una sola: eso vuelve a la imputación simple.

Mantener está bien cuando...

- El outlier es un dato **genuinamente extremo** y relevante (las grandes empresas existen).
- El NA es **informativo**: que falte el dato dice algo (típico de MNAR).
- Se puede crear una variable indicadora: `ventas_reportadas = !is.na(ventas_mm)`.

```
# Indicadora de faltante: útil como variable en modelos y para reportar  
empresas <- empresas |> mutate(ventas_reportadas = !is.na(ventas_mm))
```

```
# ¿Las que no reportan son distintas en lo que sí vemos?
```

```
empresas |>  
  group_by(ventas_reportadas) |>  
  summarise(mediana_empleados = median(empleados, na.rm = TRUE), n = n())
```

Winsorización: recortar sin eliminar

¿Qué es?

En lugar de **eliminar** los outliers, se **reemplazan** por el valor del percentil elegido (ej.: 1 y 99, o 5 y 95). Así se conserva la observación pero se limita su influencia.

Ventajas

- No se pierde ninguna observación (el n no cambia).
- Reduce el efecto de valores extremos en media, desvío y regresiones.
- Es transparente: “se winsorizó al percentil 1–99”.

¿Cuándo preferirla?

Cuando los extremos son **genuinos pero influyentes** y no querés perder la información de esas filas en las demás variables. **No** es para errores de carga: un error recortado sigue siendo un error.

```
winsorizar <- function(x, p_inf = 0.01, p_sup = 0.99) {  
  lims <- quantile(x, probs = c(p_inf, p_sup), na.rm = TRUE)  
  pmin(pmax(x, lims[1]), lims[2])  
}  
empresas <- empresas |> mutate(ventas_wins = winsorizar(ventas_mm))
```

Resumen: qué hacer en cada situación

Situación	Eliminar	Imputar	Mantener / otra
MCAR, pocos NA	Sí	Puede (no hace falta)	No necesario
MAR, objetivo descriptivo	Sesga	Sí: regresión o por grupo	Reponderar
MAR, objetivo inferencial	Sesga	Sí: MICE	Reponderar
MNAR	Sesga	No lo resuelve	Indicadora + sensibilidad
Error de carga	Sí , si no se corrige	Tratar como NA e imputar	No
Outlier genuino	No	No	Sí , o winsorizar / log

Clave

Cualquier decisión debe estar **documentada y justificada**. Decir “eliminé los NA” sin explicar por qué no es aceptable.

Transformaciones de variables

¿Por qué transformar?

Motivación

Muchos métodos funcionan mejor cuando las variables tienen ciertas propiedades: simetría, escala comparable, linealidad. Las transformaciones ayudan a lograrlo.

Situaciones típicas

- Los ingresos tienen **cola derecha larga** → **logaritmo** (cambia la **forma**).
- Queremos **combinar o comparar** variables en unidades distintas (ventas en millones vs años de antigüedad) → **estandarización** (cambia la escala).
- Necesitamos valores en un **rango fijo** $[0, 1]$ con extremos que signifiquen algo → **normalización min-max** (cambia la escala).

Orden recomendado

Primero resolver errores y faltantes, después la forma (log), y al final la escala (estandarizar o normalizar).

Transformación logarítmica

¿Cuándo usarla?

Variable **positiva** con **asimetría a la derecha**. Muy común en economía: ingresos, PBI, precios, ventas.



$$x' = \log(x)$$

Transforma diferencias **relativas** en diferencias absolutas: pasar de 10 a 20 y de 1.000 a 2.000 es el mismo salto.

Cuidados

- $\log(0) = -\infty$. Con ceros: $\log(x + 1)$ ($\log1p$), razonable si los valores son grandes respecto de 1.
- Con negativos, log no existe. Alternativa: $\text{asinh}(x)$, que se comporta como log en los extremos y acepta 0 y negativos.
- En regresión, los coeficientes se leen como **elasticidades** o cambios porcentuales.

Transformación logarítmica: el efecto



Sin los dos errores de carga. A la izquierda, casi todo se amontona cerca de cero y unos pocos valores estiran el eje; a la derecha, la distribución es aproximadamente simétrica y los métodos que suponen normalidad (z-score, IC, regresión) se comportan mejor.

Estandarización (z-score)

¿Qué hace?

Centra en la media y divide por el desvío: el resultado tiene **media 0 y desvío 1**.

$$z_i = \frac{x_i - \bar{x}}{s} \quad \text{en R: } \text{scale}(x) \text{ o } (x - \text{mean}(x)) / \text{sd}(x)$$

Un valor se lee como “cuántos desvíos está por encima o por debajo del promedio”. **No tiene rango fijo**: puede ser $-2,3$ o $+7$.

Usar estandarización cuando...

- Se **combinan variables de distinta unidad** en un método que usa distancias o varianzas: k-means, KNN, PCA. Sin escalar, “ventas en millones” domina a “antigüedad en años” solo por la unidad.
- Se usan modelos con **penalización** (ridge, lasso): la penalidad trata igual a todos los coeficientes, así que las variables deben estar en la misma escala.
- Se quiere comparar **posiciones relativas**: “este alumno está 1,5 desvíos arriba en matemática y 0,3 en lengua”.
- Se quieren coeficientes **comparables** entre sí en una regresión (coeficientes estandarizados).

Normalización min-max

¿Qué hace?

Lleva la variable al rango $[0, 1]$: el mínimo pasa a ser 0 y el máximo, 1.

$$x'_i = \frac{x_i - x_{min}}{x_{max} - x_{min}}$$

Un valor se lee como “qué fracción del camino recorre entre el peor y el mejor”.

Usar normalización cuando...

- Se necesita un **rango acotado y comparable** cuyos extremos tengan sentido: **índices compuestos** (IDH, índices de competitividad), puntajes de 0 a 100.
- La variable ya tiene **límites naturales** (porcentajes, escalas Likert, píxeles de 0 a 255).
- El algoritmo espera entradas acotadas (redes neuronales con activaciones sigmoides).


Cuándo evitarla

Con **outliers**: un único valor extremo fija el máximo y comprime a todos los demás cerca de 0. Y con **datos nuevos**: un valor fuera del rango original da menos de 0 o más de 1.

El problema de fondo: cuánto pesa cada variable

Ventas y antigüedad de las empresas, reescaladas de dos formas

Sin los dos errores de carga: la cola derecha de ventas es genuina



Desvío después de reescalar	Min-max	Estandarización
Ventas	0,111	1,00
Antigüedad	0,268	1,00

Qué nos dice la lámina anterior

Con min-max, el outlier decide

La empresa mediana queda en 0,040 en ventas normalizadas y el 90% por debajo de 0,14: casi todo el rango $[0, 1]$ lo ocupan unas pocas empresas muy grandes. En antigüedad, la mediana está en 0,45. En un k-means o en un índice que sume ambas variables, **la antigüedad pesaría casi todo y las ventas casi nada**, sin que nadie lo haya decidido.

Con estandarización, cada variable pesa lo mismo

Ambas quedan con desvío 1, por construcción. Las empresas grandes siguen siendo extremas (la mayor está a 8,4 desvíos de la media), pero la variable en su conjunto pesa lo mismo que la otra. Y todavía mejor: **primero log, después estandarizar**.

Escalado robusto: $\frac{x - \text{mediana}}{\text{IQR}}$

Usa estadísticos que los outliers no mueven: el grueso de los datos queda en una escala comparable y los extremos **siguen viéndose como extremos** en vez de comprimir al resto. Es la opción con outliers genuinos que no queremos eliminar (los errores se corrigen antes). En tidymodels: `step_normalize()` estandariza, `step_range()` hace min-max.

Un ejemplo donde min-max es lo correcto: el IDH

Índice de Desarrollo Humano (PNUD)

Combina salud, educación e ingreso. Cada dimensión se normaliza con **límites fijos** (“goalposts”) elegidos de antemano, no con el mínimo y máximo de la muestra:

$$I_{salud} = \frac{EV - 20}{85 - 20}$$

Luego se combinan con una media geométrica. Para el ingreso, primero se aplica **log** y después min-max.

País	Esperanza de vida	Índice de salud
País A	64,0	0,677
País B	72,5	0,808
País C	77,0	0,877

Por qué funciona acá

(1) El resultado tiene que estar en $[0, 1]$ para leerse como “porcentaje del camino al objetivo”. (2) Los límites fijos hacen que el índice de un país **no cambie** porque otro país mejore, y que sea comparable entre años. (3) El log previo evita que el ingreso de los países ricos comprima al resto.

Estandarización vs normalización: cómo elegir

	Estandarización (z-score)	Normalización (min-max)
Resultado	Media 0, desvío 1	Mínimo 0, máximo 1
Rango	Sin límites	Acotado a $[0, 1]$
Un valor significa	Desvíos respecto del promedio	Posición entre el peor y el mejor
Depende de	Todas las observaciones (media y desvío)	Solo de dos observaciones: la mín. y la máx.
Con outliers	Afectada, pero la variable conserva su peso	Muy afectada: comprime al resto
Pregunta que responde	"¿Qué tan inusual es este caso?"	"¿Qué tan cerca está del máximo?"
Usos típicos	k-means, PCA, KNN, ridge/lasso, comparar variables	Índices compuestos, escalas acotadas, redes neuronales

Guía rápida

- 1 ¿Hay extremos que distorsionan? Primero **log** (si es positiva y asimétrica) o **escalado robusto**.
- 2 ¿El resultado tiene que estar en un rango con extremos interpretables? **Min-max**, idealmente con límites fijos.
- 3 ¿Vas a combinar variables en distancias, varianzas o penalizaciones? **Estandarizar**.

Dos aclaraciones que evitan errores

En una regresión lineal común, escalar no cambia nada sustantivo

Estandarizar o normalizar las x en un `lm()` cambia la **unidad** de los coeficientes, pero no el R^2 , ni los estadísticos t , ni los p-valores, ni las predicciones. Se hace solo para interpretar (coeficientes comparables) o cuando hay penalización.


Los parámetros se calculan una sola vez

Si separás entrenamiento y prueba (o recibís datos nuevos), la media, el desvío, el mínimo y el máximo se calculan **solo con los datos de entrenamiento** y se aplican tal cual a los nuevos. Recalcularlos con todo filtra información del test (*data leakage*). Mismo criterio para imputar: la mediana se calcula en entrenamiento.

Ojo con la palabra “normalizar”

Se usa para cosas distintas: min-max, estandarización (“normalizar a media 0”), dividir por la norma del vector, o transformar para que la distribución sea normal. En un informe, **decir la fórmula**, no solo el nombre.

Comparación de transformaciones



Estandarizar y normalizar son transformaciones **lineales**: los tres histogramas grises son idénticos, solo cambian los números del eje. Si la variable era asimétrica, sigue siéndolo. El log es la única que cambia la forma.

Resumen de transformaciones

Transformación	Fórmula	Cuándo usar	Cuidado
Logarítmica	$\log(x)$	Asimetría derecha, elasticidades	No acepta ≤ 0
Estandarización	$(x - \bar{x})/s$	Combinar variables en distancias, PCA, penalización	Afectada por outliers
Min-max	$(x - \min)/(\max - \min)$	Índices y escalas acotadas con extremos con sentido	Muy sensible a outliers y a datos nuevos
Robusta	$(x - \text{med.})/IQR$	Estandarizar con outliers genuinos	Rango sin límites

Regla general

El logaritmo cambia la **forma** de la distribución. Estandarización, min-max y escalado robusto cambian la **escala** pero no la forma.

Justificación e impacto

Evaluar el impacto: antes vs después

Principio

Toda decisión de limpieza cambia los datos. Hay que **medir y reportar** cuánto cambian las estadísticas clave para verificar que la decisión es razonable.

Versión de ventas (MM de \$)	n	Media	Mediana	Desvío	P5	P95
Original	161	98,1	10,4	740,0	1,7	53,8
Sin errores de carga (2 obs.)	159	17,6	10,4	27,4	1,7	45,8
Winsorizado p1–p99	161	44,1	10,4	238,3	1,7	53,8
Sin outliers IQR	150	12,5	10,1	10,3	1,6	35,6

Sacar solo los **dos errores de carga** baja la media de 98,1 a 17,6 MM, mientras la mediana casi no se mueve (10,4 vs 10,4). Winsorizar al p1–p99 no alcanza: con 161 casos, el percentil 99 cae entre los dos errores. Y sacar todos los outliers por IQR elimina empresas grandes **reales** y subestima ventas.

Evaluar el impacto: qué mirar

Señales de alerta

- La **media cambia mucho** pero la **mediana casi no**: los extremos estaban tirando la media. Confirmar que eran errores, no datos genuinos.
- El **n cae drásticamente**: se pierden demasiadas observaciones. Reconsiderar el criterio o winsorizar.
- El **desvío baja mucho**: se gana estabilidad pero se puede estar ocultando variabilidad real.
- Las **conclusiones cambian**: correr el análisis con y sin limpieza. Si difieren, reportar ambos.

Una frase modelo para el informe

“Se eliminaron 2 observaciones (1,2%) con ventas incompatibles con su cantidad de empleados, atribuibles a errores de carga. La media de ventas pasó de 98,1 a 17,6 MM; la mediana se mantuvo estable (10,4 vs 10,4 MM).”

Documentar las decisiones

¿Por qué documentar?

Todo cambio a los datos (eliminar, imputar, transformar) debe quedar **registrado y justificado**. El análisis tiene que ser reproducible, incluidas las decisiones de limpieza.

Checklist para el TP

- 1 **Cuántos NA** hay por variable y qué porcentaje representan (incluidos los códigos como -9).
- 2 **Qué mecanismo** es plausible (MCAR, MAR, MNAR) y **con qué evidencia**.
- 3 **Qué criterio** se usó para detectar outliers, en qué escala, y cuántos se encontraron.
- 4 **Qué acción** se tomó con cada problema y por qué (eliminar, imputar con qué método, winsorizar, mantener).
- 5 **Qué transformaciones** se aplicaron (con la fórmula) y para qué.
- 6 **Tabla antes vs después** y, si cambian las conclusiones, resultados con y sin limpieza.

Mini ejercicio con la EPH

Con la base individual de la EPH (ocupados, ESTADO == 1):

- 1 ¿Qué porcentaje tiene $P21 == -9$? Convertir esos casos a NA. ¿Qué pasa con la media si no lo hacemos?
- 2 Comparar la tasa de no respuesta por **sexo**, **nivel educativo** y **aglomerado**. ¿Hay evidencia de MAR? ¿Qué argumento hay para sospechar MNAR?
- 3 Detectar outliers de P21 con IQR en escala original y en log. ¿Cuántos marca cada una? Mirar 5 casos: ¿parecen errores?
- 4 Calcular el ingreso medio con PONDERA y con PONDII0. ¿Cuál corresponde y por qué?
- 5 Imputar $\log(P21)$ con una regresión sobre edad, sexo, nivel educativo y región, y con mice. Estimar la brecha de ingresos por sexo con ambos. ¿Cambia el punto? ¿Y el error estándar?

Diagnosticar, decidir, documentar, medir el impacto.