

Ciencia de Datos para Economía y Negocios - FCE-UBA

Clase 15 — Clustering y reducción de dimensionalidad

Nicolás Sidicaro

Apertura

Tenemos muchas variables. ¿Y ahora?

La pregunta de hoy

Tenemos 151 países y 7 variables para cada uno: esperanza de vida, escolarización, ingreso, desigualdad, emisiones, fecundidad adolescente. **¿Qué estructura hay en esos datos?**

Problema A: encontrar grupos

- Países con perfiles parecidos.
- Consumidores, municipios, empresas con estructuras similares.
- **No hay** una variable “correcta” que queramos predecir.


⇒ **Clustering**

Problema B: resumir variables

- Muchas variables miden casi lo mismo (ingreso, educación, salud).
- Queremos **2 o 3 dimensiones** que resuman la mayor parte de la información.

⇒ **Reducción de dimensionalidad (PCA, MCA)**

Un mapa para no perderse



Hoy: no supervisado (centro y derecha)

- 1 **Supervisado vs. no supervisado**: clasificación $\neq$ clustering.
- 2 **Distancia**: qué significa que dos observaciones sean “parecidas”.
- 3 **Cluster jerárquico**: algoritmo, dendrograma, linkage, cómo caracterizar grupos.
- 4 **k-means y DBSCAN**: otros algoritmos, otras ideas de “grupo”. ¿Los grupos existen?
- 5 **PCA**: muchas variables numéricas $\rightarrow$ pocos componentes.
- 6 **MCA**: la misma lógica para variables categóricas.
- 7 **Integración**: combinar técnicas y leer los resultados sin sobreinterpretarlos.

Idea que atraviesa la clase

Estas técnicas encuentran estructura **dadas** las variables, la escala, la distancia y el algoritmo que elegimos. El resultado es una herramienta para describir, **no un descubrimiento de la “verdad” de los datos.**

Los datos que vamos a usar

País	Esp. vida	Esc. esperada	Esc. prom.	INB pc	Gini	Emis. pc	Fec. adol.
Noruega	83,4	18,6	13,1	69.190	25,4	13,3	0,7
Estados Unidos	78,2	16,4	13,6	65.565	38,9	17,8	7,0
Argentina	76,1	19,0	11,1	22.048	36,7	9,5	12,7
Brasil	73,4	15,6	8,3	14.616	44,2	11,6	22,9
India	67,7	12,6	6,6	6.951	35,7	2,8	7,3
Nigeria	53,6	10,5	7,6	4.755	43,0	1,8	42,3

- Fuentes: PNUD y otras, vía Argendata, año 2022. De 193 países quedan **151** con las siete variables (el Gini es el que más falta).
- INB per cápita en dólares PPA; emisiones en toneladas de GEI por habitante; fecundidad adolescente: nacimientos cada mil mujeres de 15 a 19 años.
- Ingreso y emisiones entran **en logaritmo** (colas largas).
- Para el MCA usamos otra base: los **ocupados de la EPH**.

Supervisado y no supervisado

Clasificación $\neq$ clustering

Clasificación (supervisado)

Hay una variable objetivo Y (“alto riesgo” / “bajo riesgo”) y queremos predecirla con $X_1, X_2, \dots$.

El algoritmo **aprende de ejemplos donde conocemos la respuesta**, y se evalúa comparando la predicción con la Y verdadera.

Ej.: regresión logística, árboles, random forest.


Clustering (no supervisado)

Solo tenemos $X_1, \dots, X_p$. **No hay respuesta correcta** contra la cual comparar.


Buscamos grupos de observaciones que se parezcan entre sí y se diferencien de las demás.

Ej.: jerárquico, k-means, DBSCAN.


Clasificación: conocemos el grupo de cada punto



Clustering: no hay etiquetas



¿El clustering descubre grupos que “realmente existen”?



No necesariamente

El algoritmo **siempre** devuelve grupos, aunque los datos no tengan ninguna estructura. El resultado depende de las **variables** elegidas, su **escala**, la **distancia**, el **algoritmo** y sus **parámetros**. Cambiando cualquiera de ellos, cambian los clusters.

Distancia: ¿qué es “parecido”?

Todo clustering necesita una noción de cercanía

Persona	Edad	Ingreso
A	25	1.000.000
B	60	1.050.000
C	27	1.400.000

La más usada es la **distancia euclídea**: la distancia “en línea recta”.

$$d(A, B) = \sqrt{(x_{A1} - x_{B1})^2 + \dots + (x_{Ap} - x_{Bp})^2}$$

¿A quién se parece A?

- **Sin estandarizar**: $d(A, B) = 50.000$ y $d(A, C) = 400.000$. A se parece a **B**, que tiene 35 años más. La edad casi no cuenta: está en otra escala.
- **Estandarizando** (dividiendo por el desvío: 15 años y 500.000 pesos): $d(A, B) = 2,34$ y $d(A, C) = 0,81$. Ahora A se parece a **C**.

Regla práctica

Si las variables están en unidades distintas, **estandarizar**. Es una decisión, y cambia el resultado.

Las distancias más usadas


Distancia	Cálculo	Cuándo se usa
Euclídea	$\sqrt{\sum_j (x_{Aj} - x_{Bj})^2}$	Numéricas continuas en escalas comparables (estandarizadas). La usan k-means y Ward. Castiga mucho una diferencia grande en una sola variable.
Manhattan (city block)	$\sum_j x_{Aj} - x_{Bj} $	Suma diferencias como cuadras de una grilla. Menos sensible a outliers; útil con variables discretas o con muchas variables.
Mahalanobis	$\sqrt{(x_A - x_B)' \Sigma^{-1} (x_A - x_B)}$	Corrige escala y correlación : si tres variables miden casi lo mismo, no cuenta tres veces esa diferencia. Outliers multivariados.
Correlación	$1 - r(x_A, x_B)$	Importa la forma del perfil, no el nivel: series de tiempo (provincias con el mismo ciclo), perfiles de gasto o exportación.
Coseno	$1 - \frac{x_A \cdot x_B}{\ x_A\ \ x_B\ }$	Compara proporciones sin importar la escala: textos (frecuencia de palabras), canastas de consumo.
Jaccard	$1 - \frac{\#(\text{ambos tienen})}{\#(\text{alguno tiene})}$	Binarias de presencia/ausencia donde el 0-0 no informa: qué productos exporta un país, qué servicios contrata un cliente.
Gower	promedio de diferencias por variable, cada una en $[0, 1]$	Datos mixtos : numéricas (diferencia sobre el rango) y categóricas (igual = 0, distinta = 1). Encuestas; con k-medoids o jerárquico.

No hay una distancia “correcta”: cada una responde a una idea distinta de “parecido”. Elegirla es parte del análisis.


Algoritmos de clustering

Dos grandes familias

Jerárquico: particiones anidadas (un árbol)



Particional: una sola partición en k grupos



Jerárquicos (Ward, single, complete...)

- **Aglomerativos:** arrancan con cada observación sola y van juntando (los más usados). **Divisivos:** arrancan con un solo grupo y van partiendo.
- Dan **todas** las particiones a la vez; k se elige **después**, cortando el árbol.
- Necesitan la distancia entre **todos** los pares: con 100.000 filas ya no entra en memoria.


Particionales (k-means, k-medoids)

- Hay que fijar k **antes** de correr.
- Buscan la mejor partición en k grupos moviendo observaciones de un grupo a otro hasta que no se puede mejorar.
- Rápidos: sirven para cientos de miles de filas.


Otras familias, con otras ideas de “grupo”: por **densidad** (DBSCAN) y basadas en **modelos** probabilísticos (mezclas gaussianas). Las vemos al final del bloque.

¿Qué es un buen grupo? Inercia dentro y entre grupos

Within: WSS = 96



Between: BSS = 400 (+ = centro general)



La **inercia** es la suma de distancias al cuadrado a un centro: una medida de dispersión, como la varianza (sin dividir por n). La inercia total se parte en dos:

$$\underbrace{\sum_i \|x_i - \bar{x}\|^2}_{\text{TSS (total)}} = \underbrace{\sum_g \sum_{i \in g} \|x_i - \bar{x}_g\|^2}_{\text{WSS (within)}} + \underbrace{\sum_g n_g \|\bar{x}_g - \bar{x}\|^2}_{\text{BSS (between)}}$$

Acá: $496 = 96 + 400$.

La idea que usan Ward y k-means


Un buen clustering tiene grupos **homogéneos** (WSS chica) y **distintos entre sí** (BSS grande). Como la TSS está fija, **minimizar WSS es lo mismo que maximizar BSS**.

$R^2 = \text{BSS}/\text{TSS}$: qué parte de la dispersión total explica la pertenencia a un grupo. Acá, 81%.


Cluster jerárquico

La idea: ir juntando de a dos

Orden en que se van uniendo los grupos



Dendrograma




- 1 Arranca con cada observación como un grupo propio: A, B, C, D, E, F.
- 2 Une los dos grupos **más cercanos**. Recalcula distancias. Repite.
- 3 Termina con un único grupo. El resultado es una **jerarquía** de agrupamientos.

Pregunta pendiente: una vez que A y B forman un grupo, ¿a qué distancia está ese *grupo* de C?

Linkage: ¿qué distancia hay entre dos grupos?

Los mismos datos, cortados en $k = 3$ con cada criterio




- **Single linkage:** distancia entre los dos puntos **más cercanos** de cada grupo. Sigue “cadenas” y deja grupos minúsculos.
- **Complete linkage:** entre los dos puntos **más lejanos**. Grupos compactos.
- **Average linkage:** **promedio** de todas las distancias entre pares. Intermedio.

Ward

Al juntar dos grupos, la **WSS siempre sube**: los puntos quedan más lejos del nuevo centro común. Ward calcula ese aumento para cada par posible y une el que **menos la hace subir**: en cada paso pierde la menor inercia entre grupos (BSS) posible. Grupos compactos y parejos; es el más usado.

El dendrograma

24 países, Ward sobre las siete variables estandarizadas




Cómo se lee

Cuanto **más abajo** se unen dos países (o grupos), **más parecidos** son. Cuanto más arriba, más distintos. **El orden horizontal no significa nada**: cada rama se puede girar sin cambiar el árbol.

¿Qué mide la altura de una fusión?


Inercia entre grupos que se pierde en cada fusión

% de la inercia total (TSS)



$R^2 = \text{BSS} / \text{TSS}$ con k grupos

% de la inercia total




- Con single, complete o average, la altura es la **distancia entre los dos grupos** que se unen, según ese criterio.
- Con **Ward**, la altura mide **cuánto aumenta la WSS** con esa fusión, que es lo mismo que la **inercia entre grupos (BSS) que se pierde**: $\Delta WSS = \text{altura}^2 / 2$. Sumando todas las fusiones se obtiene la inercia total ($1.050 = \text{TSS}$).

Lectura

Pasar de 2 grupos a 1 cuesta el 48% de la inercia; de 4 a 3, solo el 4%. Con 4 grupos conservamos un R^2 del 64%. Las fusiones de arriba son caras (unen grupos muy distintos); las de abajo, baratas.

¿Cuántos clusters hay? Cortar el árbol



Cortar a distintas alturas da distintas particiones. Conviene cortar **justo debajo de un salto grande** de altura: por encima, las fusiones juntarían grupos muy distintos y perderían mucha inercia entre grupos. Pero es una guía, no una regla: **el número de clusters es una decisión analítica.**

¿Qué caracteriza a cada grupo?


Grupo	n	Esp. vida	Esc. prom.	INB pc*	Gini	Emis.*	Fec. adol.	Ejemplos
1	13	60,1	4,0	1.464	40,2	3,6	63,3	Costa de Marfil, Sudán del Sur
2	41	65,3	5,7	3.515	41,3	1,9	33,0	Guatemala, Burundi
3	67	72,8	10,0	14.778	37,6	5,9	15,6	Guyana, Tuvalu
4	30	81,6	12,7	47.912	30,4	8,8	2,4	Irlanda, Letonia

(*) Mediana. Resto: promedio. Ward, $k = 4$, sobre los 151 países. Grupos numerados de menor a mayor ingreso.

Los clusters no traen la interpretación incorporada

El algoritmo produce grupos; **el nombre y la lectura económica los ponemos nosotros**. Mejor que “descubrimos cuatro tipos de países”: “con estas variables y este método, obtenemos una partición en cuatro grupos con estas características”. Argentina queda en el grupo 3.


Perfil de los grupos en una sola imagen



Cada variable se estandariza con la **media y el desvío de todos los países**, no con los del grupo. La celda es el promedio de esos valores dentro del grupo: 0 = el grupo está en el promedio general; +1 = está, en promedio, un desvío (de la muestra completa) por encima. Así se comparan variables en distintas unidades; para comunicar, conviene volver a las **unidades originales** (tabla anterior).

k-means y otros algoritmos


k-means: la idea



- 1 Elegimos k y ubicamos k **centros** al azar (rombos).
- 2 Cada punto se asigna al **centro más cercano**.
- 3 Cada centro se mueve al **promedio** de sus puntos (de ahí “*means*”).
- 4 Se repiten 2 y 3 hasta que nada cambia. Acá, en 5 iteraciones.

Cada paso baja la **WSS**: es el mismo objetivo que Ward, pero sin construir un árbol.


¿Cuántos grupos? Elbow, Silhouette y Gap



Elbow: la WSS **siempre** baja al agregar grupos. Buscamos el “codo”, donde deja de bajar mucho. Acá no hay uno nítido.



Silhouette: para cada punto, $s = \frac{b-a}{\max(a,b)}$, con a = distancia media a su grupo y b = al grupo vecino más cercano. Va de -1 a 1 . Con $k = 1$ no hay grupo vecino: no está definida. Máximo en $k = 2$ (0,41); por debajo de 0,5, estructura débil.




Gap: compara la WSS con la que daría una nube **sin grupos** del mismo rango. Sí arranca en $k = 1$: sube hasta $k = 3$ y después se aplana.

Usamos $k = 4$: más informativo que 2, a costa de algo de silhouette. Es una decisión.

¿Los grupos existen? Un test contra datos sin grupos

(a) Contra etiquetas al azar


$R^2 = \text{BSS} / \text{TSS}$ (%)



(a) Repartir los países al azar en 4 grupos da un R^2 de 2% en promedio; el k-means, 66%. Le gana **siempre**, pero el test es **circular**: el algoritmo eligió los grupos para que difieran. Por eso tampoco sirve un ANOVA de las variables entre clusters.

(b) Contra datos simulados sin grupos

Silhouette promedio, k-means $k = 4$



(b) El test correcto compara con datos **sin grupos**: 200 bases simuladas de una normal multivariada con las **mismas medias y correlaciones**, a las que se aplica el mismo k-means. Solo en el 4% de las simulaciones la silhouette supera a la observada: la estructura de grupos de los países **apenas** se distingue de una nube sin grupos.

Otras formas de evaluar los grupos

- **Gap statistic** (lámina anterior): la misma lógica que (b), con una referencia uniforme; además sugiere un k .
- **Estabilidad por bootstrap**: remuestrear las observaciones, volver a agrupar y medir cuántas veces un grupo “reaparece” (índice de Jaccard entre el grupo original y el más parecido del remuestreo). Grupos que se deshacen con pequeños cambios en los datos no son confiables.
- **Acuerdo entre métodos**: si Ward, k-means y otros algoritmos dan particiones parecidas (*Adjusted Rand Index* cercano a 1), la partición es más creíble.
- **Validación externa**: ¿los grupos se diferencian en variables que **no** se usaron para construirlos? (por ejemplo, el IDH o el continente). Esto sí puede testearse con un ANOVA o un χ^2 sin circularidad.

Hipótesis nula correcta

La pregunta no es “¿estos grupos son distintos?” (siempre lo son, por construcción), sino “¿obtendría grupos tan marcados si los datos **no** tuvieran grupos?”.

k-means vs. Ward en los países


Ward \ k-means	1	2	3	4
1	13	0	0	0
2	11	29	1	0
3	1	2	51	13
4	0	0	0	30

Con $k = 4$, coinciden en el **81%** de los países. Los que cambian de grupo son los que están “en el borde”.

Cosas a saber de k-means

- Hay que elegir k **de antemano**.
- El resultado depende del **arranque al azar**: con un solo arranque, el 80% de 200 corridas terminó en una solución peor que la mejor. Hay que correrlo con muchos arranques (25 o más) y quedarse con el mejor.
- Supone grupos **redondos y de tamaño parecido** (usa distancia euclídea a un centro).
- Es **sensible a outliers**: el promedio se deja arrastrar. Alternativa: **k-medoids** (PAM), que usa una observación real como centro.
- Escala bien: sirve para cientos de miles de observaciones.

Cuando los grupos no son “nubes redondas”



k-means corta el plano en regiones “alrededor de un centro”: no puede separar una medialuna de otra ni un anillo de su interior. **DBSCAN** define grupo de otra manera: **zonas densas** de puntos, separadas por zonas vacías.

DBSCAN: grupos por densidad

Dos parámetros:

- ϵ (eps): radio del vecindario.
- minPts: cuántos vecinos tiene que tener un punto en ese radio para ser “núcleo”.

Los núcleos cercanos se encadenan y forman un grupo. Los puntos que no están cerca de ningún núcleo quedan como **ruido** (en las medialunas: 5).


Ventajas

No hay que elegir k ; detecta formas arbitrarias; separa outliers en lugar de forzarlos a un grupo.

Desventajas

Muy sensible a eps; falla si los grupos tienen densidades distintas; sufre con muchas variables (todo queda “lejos”).

Para elegir eps: el elbow del k-NN distance plot (4º vecino)




El zoológico de algoritmos de clustering

Algoritmo	¿Elegir k?	Grupos	Outliers	En R
Jerárquico (Ward)	Después (corte)	Compactos	Los fuerza a un grupo	<code>hclust()</code> , <code>HCPC()</code>
k-means	Sí	Redondos	Lo arrastran	<code>kmeans()</code>
k-medoids (PAM)	Sí	Compactos	Robusto	<code>cluster::pam()</code>
DBSCAN	No	Cualquier forma	Ruido	<code>dbscan::dbscan()</code>
HDBSCAN / OPTICS	No	Cualquier forma	Ruido	<code>dbscan::hdbscan()</code>
Mezclas gaussianas	Sí (o por BIC)	Elipses	Sensible	<code>mclust::Mclust()</code>

- **HDBSCAN** es DBSCAN probando muchos eps a la vez: tolera grupos de densidades distintas y solo pide un tamaño mínimo de grupo.
- **Mezclas gaussianas** (GMM, *Gaussian Mixture Models*): suponen que los datos vienen de varias distribuciones normales, una por grupo, cada una con su centro y su forma elíptica. Estiman esas distribuciones y asignan a cada observación una **probabilidad** de pertenecer a cada grupo, en lugar de una asignación dura.
- No hay un algoritmo “mejor”: cada uno trae **su propia definición de qué es un grupo**.

Componentes principales (PCA)

Otra pregunta: ¿cuántas cosas distintas miden estas variables?




Hasta ahora usamos muchas variables para **agrupar países**. Ahora hacemos otra cosa: usar muchas variables para **construir pocas dimensiones**.

Salud, educación e ingreso están **muy correlacionados**: en buena medida cuentan la misma historia. ¿Hace falta mirar siete variables, o con dos o tres nuevas variables resumimos casi todo?

PCA

Construye variables nuevas $PC_1, PC_2, \dots$, que son **combinaciones lineales** de las originales y **no están correlacionadas** entre sí.

La geometría del PCA



Negro: 5 observaciones. Rojo: su proyección sobre PC1.


Cada punto gris es una observación con dos valores (x_1, x_2). Marcamos cinco en negro.

- **Proyectar** un punto sobre PC1 es bajar en perpendicular hasta la recta (línea punteada). Donde cae (punto rojo) es su **score**: describimos la observación con **un** número en lugar de dos.
- Lo que se pierde es el largo de la línea punteada. **PC1** es la recta que hace esas pérdidas lo más chicas posible; equivalentemente, la que deja los puntos rojos **lo más dispersos posible** (mayor varianza). Acá conserva el **93%** de la varianza total.
- **PC2** es la dirección perpendicular a PC1 que captura la varianza **restante** (7%).

Con p variables hay p componentes. Rotar los ejes no pierde información: la pérdida viene cuando **nos quedamos con los primeros**.

¿Cuánto resumen los componentes? Varianza explicada

Comp.	Autovalor	% var.	% acum.
PC1	4,84	69,2	69,2
PC2	0,82	11,7	80,9
PC3	0,58	8,3	89,2
PC4	0,25	3,6	92,8
PC5	0,24	3,4	96,2
PC6	0,17	2,4	98,6
PC7	0,10	1,4	100,0



Los dos primeros componentes resumen el **81%** de la varianza de las siete variables. Para elegir cuántos: buscar el **elbow** (codo) del scree plot, quedarse con autovalores > 1 (Kaiser: acá 1), o fijar un % acumulado. Son heurísticas, no leyes.

No significa que expliquen el 81% “de la realidad” ni que sean “81% correctos”. Es varianza **de las variables que pusimos**.

Loadings: ¿qué mide cada componente?

Variable	PC1	PC2	PC3
Esperanza de vida	0,41	-0,19	-0,07
Escolariz. esperada	0,40	0,09	-0,24
Escolariz. promedio	0,41	0,16	-0,16
INB pc (log)	0,43	0,16	-0,05
Gini	-0,27	0,71	-0,59
Emisiones pc (log)	0,30	0,60	0,65
Fecund. adolescente	-0,39	0,20	0,38


Pesos de cada variable estandarizada en cada componente. $PC_1 = 0,41 \cdot z_{\text{vida}} + 0,40 \cdot z_{\text{esc.esp}} + \dots$

- **PC1 (69%)**: todas las variables de salud, educación e ingreso con peso parecido y del mismo signo; fecundidad adolescente y Gini con signo opuesto. Una lectura posible: “**nivel de desarrollo**”. Correlación con el IDH del PNUD: 0,98.
- **PC2 (12%)**: **Gini** y **emisiones**, las dos variables menos atadas al bloque del desarrollo. Valores altos: más desigualdad y más emisiones de lo que correspondería a su nivel de desarrollo.

El nombre lo ponemos nosotros

PCA da números. “Desarrollo” es nuestra interpretación, y otro analista podría leerlo distinto.

Círculo de correlaciones (correlation circle)



Cada flecha es la **correlación** de una variable con PC1 (eje x) y con PC2 (eje y).

- Flecha **larga** (cerca del círculo): la variable está bien representada en este plano.
- Flechas en la **misma dirección**: variables correlacionadas positivamente.
- Flechas **opuestas**: correlación negativa.
- Flechas **perpendiculares**: poca correlación.

Las tres variables educativas y de salud casi se superponen: **redundancia**. Es lo que PCA aprovecha para resumir.

¿Qué variables son relevantes? Contribution, $\cos^2$ y v.test

Variable	Contrib. PC1 (%)	Contrib. PC2 (%)
Esperanza de vida	17,0	3,5
Escolariz. esperada	16,3	0,9
Escolariz. promedio	16,5	2,4
INB pc (log)	18,5	2,6
Gini	7,6	51,1
Emisiones pc (log)	9,1	35,6
Fecund. adolescente	15,1	3,9


Continente (suplementaria)	v.test PC1	v.test PC2
África	-8,7	1,6
Am. del Sur	0,9	3,4
Am. Norte y Central	0,1	2,0
Asia	1,0	-2,2
Europa	8,0	-2,1
Oceanía	-0,6	-1,5

- **Contribution:** % con que cada variable construye el eje (suman 100). Referencia: si todas aportaran igual, $100/7 = 14,3\%$. Por encima (en negrita), la variable “arma” el eje.
- **$\cos^2$:** qué tan bien representada está la variable en el plano PC1-PC2 (de 0 a 1). Acá va de 0,73 a 0,92.
- **v.test:** es un valor z. Se usa para variables **suplementarias** categóricas: ¿el promedio de los países de un continente en el eje está lejos de 0? $|v| > 2 \approx$ significativo al 5%. La misma idea aparece al describir clusters.

¿Y un test para las variables activas?

Sería circular: el eje se construyó con ellas, así que siempre da significativo. Se usan las contribuciones; para medir incertidumbre, **bootstrap** de los loadings.

El mapa de los países



Siete variables comprimidas en un plano que conserva el 81% de la varianza. Los países cercanos tienen perfiles parecidos. A la derecha, los más desarrollados. Arriba, los que tienen más desigualdad y más emisiones de las que les “tocarían” por su desarrollo: África austral, buena parte de América Latina, Estados Unidos, Rusia.

El signo de un componente es arbitrario

Dos resultados equivalentes

Variable	Corrida 1	Corrida 2
Esperanza de vida	0,41	-0,41
INB pc (log)	0,43	-0,43
Fecund. adolescente	-0,39	0,39

Multiplicar un componente por -1 da **exactamente la misma dimensión**. Distintos programas (o versiones) pueden devolver uno u otro.

Entonces

- No leer “positivo = bueno” ni “negativo = malo”.
- Lo que importa son los signos **relativos**: qué variables van juntas y cuáles van en contra.
- Se puede invertir para que sea más legible (acá lo hicimos para que PC1 crezca con el ingreso), y decirlo.

¿Estandarizar o no? Covarianzas vs. correlaciones

Variable	Desvío	Sin estand.	Estand.
Esperanza de vida	7,8	0,000	0,42
Escolariz. esperada	3,1	0,000	0,41
Escolariz. promedio	3,3	0,000	0,41
INB pc (USD)	18.769,6	1,000	0,41
Gini	7,7	0,000	0,29
Emisiones pc (t)	5,3	0,000	0,26
Fecund. adolescente	19,3	0,001	0,40

Carga (en valor absoluto) de cada variable en PC1. Variables en niveles, sin logaritmos.

Sin estandarizar (matriz de covarianzas), PC1 explica el 100,00% de la varianza. . . porque es **el ingreso en dólares** y nada más (carga 1,000). Su desvío es miles de veces mayor que el del resto.

Estandarizando (matriz de correlaciones), todas pesan parecido y PC1 explica el 66%.

Regla

Variables en unidades distintas $\Rightarrow$ estandarizar.
Revisar siempre qué hace por defecto el programa que usamos: no todos estandarizan.

Análisis de correspondencias múltiples (MCA)

¿Y si las variables son categóricas?

PCA trabaja con promedios, varianzas y correlaciones: necesita números. Con variables como *categoría ocupacional* o *nivel educativo* no podemos calcular una correlación de Pearson.

MCA es el análogo del PCA para variables categóricas: busca las **asociaciones entre categorías** que mejor resumen la estructura de los datos.

La pregunta

PCA: ¿qué combinaciones de variables numéricas capturan la mayor variación?

MCA: ¿qué categorías tienden a aparecer juntas, y qué dimensiones resumen esos patrones?

Truco: la tabla disyuntiva completa

Cada categoría se convierte en una columna 0/1:

Ind.	Educación		Empleo	
	Univ.	Sec.	Formal	Informal
A	1	0	1	0
B	0	1	0	1
C	1	0	1	0

MCA es, en esencia, un análisis de esta tabla con una distancia que da **más peso a las categorías raras** (distancia χ^2).

Los datos: ocupados de la EPH

14.348 ocupados (patrones, cuentapropistas y asalariados) del **1er trimestre 2026**, ponderados con PONDERA.

Variables activas (construyen las dimensiones):

- Categoría: patrón, cuenta propia, asalariado registrado / no registrado (descuento jubilatorio).
- Educación: hasta secundario incompleto, secundario completo, universitario completo.
- Cobertura de salud: obra social, prepaga o plan estatal, sin cobertura.
- Tamaño del establecimiento: hasta 5, 6 a 40, más de 40 personas.
- Intensidad: subocupado, ocupado pleno, sobreocupado.

Variables suplementarias (no construyen las dimensiones; se proyectan después para interpretarlas):

- Sexo, grupo de edad, región.

¿Por qué separar?

Queremos describir la **estructura del empleo** con atributos del puesto, y después preguntar **quiénes** ocupan cada zona del mapa. Si sexo o región fueran activas, el mapa mezclaría las dos preguntas.

Inercia: los porcentajes en MCA son bajos (y está bien)

Dim.	Autovalor	% inercia	% Benzécri
Dim 1	0,501	22,8	95,6
Dim 2	0,254	11,5	3,1
Dim 3	0,232	10,6	1,1
Dim 4	0,213	9,7	0,2
Dim 5	0,200	9,1	0,0



La primera dimensión resume solo el **23%** de la inercia (el equivalente de la varianza). No es una señal de mal ajuste: la tabla disyuntiva **infla artificialmente** la dimensionalidad, porque cada variable con J categorías aporta $J - 1$ dimensiones.

La **corrección de Benzécri** descuenta ese efecto (solo considera autovalores mayores que $1/Q$, con $Q = 5$ variables activas): con ella, la primera dimensión resume el 96%.

Consecuencia práctica

No comparar los % de un MCA con los de un PCA. Mirar **dónde cae el scree plot** y, sobre todo, si las dimensiones **se pueden interpretar**.

El mapa de categorías




Cómo leer el mapa

- **Dim 1: formalidad.** A la izquierda, asalariado registrado ($-1,03$), establecimientos de más de 40 personas, obra social, universitarios. A la derecha, sin cobertura ($1,13$), establecimientos de hasta 5, subocupación, cuenta propia.
- **Dim 2: dos formas de informalidad.** Arriba, el asalariado no registrado ($1,32$) en establecimientos medianos; abajo, el cuentapropista.
- **Suplementarias:** los jóvenes caen hacia la informalidad asalariada; Patagonia, hacia la formalidad. Sexo, casi en el origen.

Reglas de lectura

- Categorías **lejos del origen**: diferencian mucho en esa dimensión. **Cerca del origen**: perfil promedio, poco discriminantes.
- Categorías **de distintas variables** cercanas: tienden a darse en las mismas personas.
- Las categorías **de una misma variable** no pueden aparecer juntas en un individuo: su distancia no se lee como asociación.
- Leer siempre con **contribuciones** y $\cos^2$: el plano puede representar mal a algunas categorías.

¿Qué variables arman cada dimensión?



Para cada variable, el η^2 con una dimensión mide qué parte de la variación de las coordenadas se explica por la variable (es el R^2 de un ANOVA: coordenada $\sim$ variable).

- **Categoría, tamaño y cobertura** construyen la Dim 1.
- La Dim 2 es casi toda **categoría**: separa las dos informalidades.
- La intensidad horaria pesa poco en el plano.

Cuidado con

- **Categorías raras** (pocos casos): quedan lejísimos del origen y dominan el mapa, o se “roban” una dimensión entera. Agruparlas antes.
- **Variables numéricas**: hay que discretizarlas (tramos), y los cortes cambian el resultado.
- **Calidad de representación**: una categoría cerca del origen en el plano puede estar lejos en otra dimensión. Mirar contribuciones y $\cos^2$ antes de interpretar su posición.
- Cercanía en el mapa **no es causalidad**, y tampoco es “probabilidad de aparecer juntas”.

Integración

PCA y clustering no compiten: se combinan

Muchas variables

↓
PCA (o MCA)

↓
Pocos componentes (sin ruido ni redundancia)

↓
Cluster jerárquico (Ward)


↓
Consolidación con **k-means**

↓
Grupos + su descripción

Es el método **HCPC** (*Hierarchical Clustering on Principal Components*).

Tres grupos son **cortes a lo largo de PC1**; el cuarto aparece por **PC2** (África austral, Brasil, Bolivia). Entre grupos vecinos no hay vacío: los países forman un **continuo** y los clusters lo **resumen**. Otra receta, otra partición: frente al Ward de antes, HCPC junta los dos grupos más pobres y parte en tres el intermedio.

HCPC con 4 grupos sobre los países



Cuadro comparativo

Técnica	Datos	¿Qué busca?	Resultado	Decisión clave
Clasificación (superv.)	Num. / categ.	Predecir una clase	Clase predicha	Qué predictores
Cluster jerárquico	Num. (o distancia)	Jerarquía de grupos	Dendrograma + grupos	Linkage, dónde cortar
k-means	Numéricos	k grupos compactos	Grupos + centros	k, arranques
DBSCAN	Numéricos	Zonas densas	Grupos + ruido	eps, minPts
PCA	Numéricos	Resumir variables	Loadings, scores	Escalar, cuántos PC
MCA	Catégoricos	Resumir variables	Mapa de categorías	Agrupar raras

Común a todas las técnicas no supervisadas

Las decisiones previas (qué variables, cómo transformarlas, cómo escalarlas) pesan tanto como el algoritmo. **Documentarlas** y **probar alternativas** (análisis de sensibilidad).

Lo que un resultado NO significa

Errores de interpretación frecuentes

- Un cluster **no demuestra** que exista un grupo “natural”. El algoritmo encuentra grupos incluso en datos al azar.
- Que un país cambie de grupo entre dos métodos **no es un error**: es información sobre lo frágil que es la frontera.
- El número de clusters **no lo descubre** el algoritmo: lo decidimos nosotros, con ayuda de heurísticas.
- Una varianza explicada alta **no significa** que el análisis sea “bueno” ni que capture lo importante del fenómeno.
- Un componente principal **no es necesariamente** una variable real o latente con una única interpretación.
- Loadings altos o categorías cercanas en un mapa **no implican causalidad**.
- Cambiar las variables, la escala o el método puede **cambiar** clusters y componentes.

Para llevarse

- 1 **Supervisado vs. no supervisado**: ¿hay una Y que quiero predecir?
- 2 El clustering depende de cómo definimos **distancia**; con unidades distintas, **estandarizar**.
- 3 En el jerárquico, el **dendrograma** muestra una jerarquía; **cortarlo** es una decisión.
- 4 k-means minimiza la WSS, pide k y muchos arranques; DBSCAN busca **densidad** y marca ruido. Cada algoritmo trae su propia idea de “grupo”.
- 5 Los grupos hay que **caracterizarlos**: el nombre lo ponemos nosotros.
- 6 PCA transforma muchas variables en **pocas dimensiones** que capturan varianza.
- 7 **Loadings** para interpretar, **varianza explicada** para saber cuánto resumen; el signo es arbitrario.
- 8 MCA aplica la misma lógica a **categóricas**; sus % de inercia son bajos por construcción.

Próxima clase: práctica

PCA, MCA, cluster jerárquico y k-means / DBSCAN en R, con las mismas bases que hoy.