Ciencia de Datos para Economía y Negocios - FCE-UBA

Visualización, clase 1 — Introducción a la visualización de datos

Nicolás Sidicaro

Pregunta guía de hoy

La pregunta

¿Cómo elegimos una representación visual que permita **entender mejor** un fenómeno económico?

La idea central

Un gráfico no es una decoración de una tabla ni una salida automática del software. Es una **representación**: facilita ciertas comparaciones, hace visibles algunos patrones y puede dificultar u orientar otras interpretaciones. Visualizar datos es **tomar decisiones analíticas**.

Al terminar la clase deberían poder

- Identificar qué pregunta responde una visualización.
- Elegir y justificar un gráfico según la pregunta, las variables y el público.
- Distinguir gráficos para **comunicar** y para **explorar**.
- Reconocer buenas prácticas y problemas frecuentes.
- Explicar qué limitaciones tiene un gráfico y qué lecturas equivocadas puede favorecer.

Hoja de ruta

1. ¿Para qué visualizamos datos?
2. Elegir un gráfico según la pregunta
3. Dos objetivos: comunicar y explorar
4. Discusión: desigualdades laborales
5. Buenas prácticas y errores frecuentes
6. Taller de selección y crítica
7. Cierre

¿Para qué visualizamos datos?

Visualizar es analizar, no solo presentar

Solemos pensar el gráfico como el **último paso**: el análisis ya está hecho y el gráfico lo "muestra lindo". Pero el gráfico también sirve **durante** el análisis:

- para **ver** la estructura de los datos antes de resumirlos;
- para **detectar problemas**: errores de carga, cambios de metodología, valores imposibles;
- para **generar preguntas** que no teníamos al empezar.

Una media, una correlación o un R^2 **resumen**. Un gráfico **muestra**. Para resumir bien, primero hay que haber mirado.

Lo que no hace un gráfico

No reemplaza la **definición de las variables**, la evaluación de la **calidad de los datos** ni el **razonamiento estadístico**. Un gráfico de una variable mal medida es un gráfico prolijo de algo equivocado.

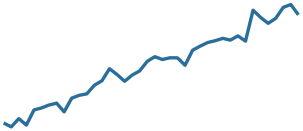
Toda visualización elige

Qué variable, qué período, qué escala, qué grupos, qué comparación queda adelante y cuál queda atrás. No existe el gráfico "neutral": existe el gráfico cuyas decisiones están **explicitadas y justificadas**.

Qué patrones puede hacer visibles un gráfico

Tendencia

¿Sube, baja, cambia de ritmo?



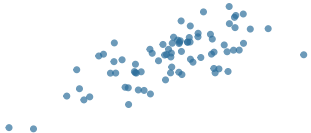
Diferencias

¿Qué grupo tiene más?



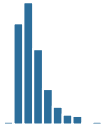
Asociación

¿Se mueven juntas?



Distribución

¿Qué forma tiene?



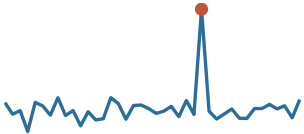
Concentración

¿Pocos explican casi todo?



Anomalías

¿Error o fenómeno real?



Datos simulados con fines ilustrativos.

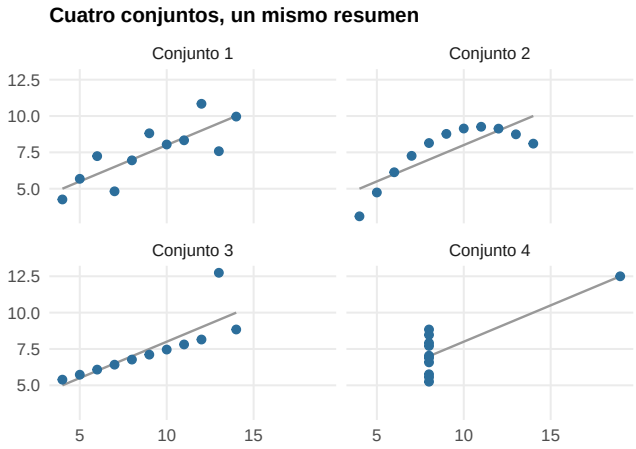
Cada patrón responde a una **pregunta distinta**. Por eso, antes de elegir un gráfico, conviene saber qué tipo de patrón estamos buscando.

Mismo resumen, datos muy distintos

El **cuarteto de Anscombe** (1973): cuatro conjuntos de 11 pares (x, y) con

- la misma media de x (9) y de y (7,5),
- la misma varianza,
- la misma correlación (0,82),
- la misma recta de regresión.

La tabla de resúmenes dice que son **iguales**. El gráfico muestra que son cuatro fenómenos diferentes: una relación lineal con ruido, una curva, una recta con un valor atípico y un único punto que fabrica la correlación.



Ejemplo disparador: salario real e inflación en una tabla

Período	Inflación i.a.	Salarios i.a.	Salario real
dic-2017	24,8%	27,5%	102,1
dic-2018	47,6%	29,7%	89,7
dic-2019	53,8%	40,9%	82,2
dic-2020	36,1%	33,0%	80,3
dic-2021	50,9%	53,4%	81,6
dic-2022	94,8%	90,4%	79,7
dic-2023	211,4%	152,7%	64,7
dic-2024	117,8%	145,5%	72,9
dic-2025	31,5%	38,2%	76,6
jul-2026	33,8%	36,2%	78,2

Fuente: INDEC, IPC nacional e índice de salarios (total). Base dic-2016 = 100. El salario real es el índice de salarios dividido por el IPC (dic-2016 = 100). i.a.: variación interanual.

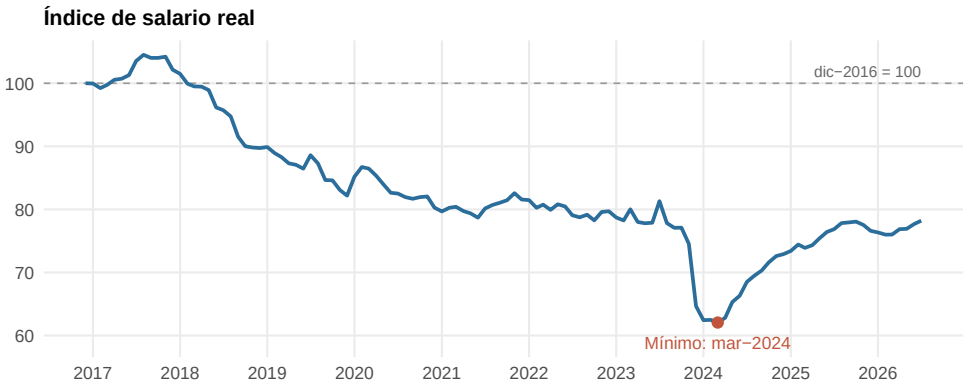
¿Qué vemos con facilidad en la tabla?

- El **valor exacto** de cada año: la inflación de diciembre de 2023, por ejemplo.
- Comparaciones **puntuales** entre dos celdas.

¿Qué cuesta ver?

- Cuándo empezó la caída del salario real y cuándo se aceleró.
- Si hubo recuperaciones dentro de cada año.
- La **forma** del recorrido completo: la tabla muestra 10 puntos de 116 meses.

El mismo dato en un gráfico



Fuente: INDEC, IPC nacional e índice de salarios (total). Base dic−2016 = 100.

En segundos aparecen la **tendencia** (caída desde 2018), los **quiebres** (2018, 2019, fin de 2023) y las **recuperaciones parciales**. Lo que se pierde: el valor exacto de cada mes, que en la tabla está a la vista.

Tabla y gráfico: qué aporta y qué pierde cada uno

La tabla

- Permite **buscar** un valor y leerlo con precisión.
- Sirve cuando el lector necesita los números para usarlos (un informe técnico, un anexo).
- Escala mal: con muchas filas o columnas el patrón se vuelve invisible.
- Pierde la **forma**: tendencias, quiebres y asimetrías hay que reconstruirlos mentalmente.

El gráfico

- Permite ver **patrones** y **comparar** de un vistazo.
- Aprovecha la percepción visual: posiciones, longitudes, pendientes.
- Pierde precisión: leer "78,3" en un eje es difícil.
- Destaca algunos aspectos y **deja otros en segundo plano**: el que elige la escala, el período y el orden elige qué se ve primero.

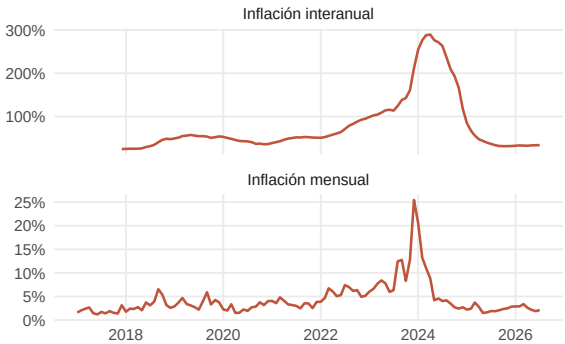
No compiten

Se complementan: un gráfico para ver el patrón y una tabla (o etiquetas en el gráfico) para los pocos valores que el lector necesita con precisión.

Decisiones antes de representar las dos series

- **¿Nominal o real?** El salario nominal se multiplicó por 94 desde 2016; el real cayó. Son dos preguntas distintas.
- **¿Qué medida de inflación?** Mensual (ruidosa, muestra aceleraciones) o interanual (suave, con rezago).
- **¿Qué base?** Todo índice depende del período base elegido: cambiarlo cambia dónde está el "100".
- **¿Qué período?** Empezar en un pico o en un valle cambia el mensaje (lo vemos en el bloque 4).
- **¿Qué salario?** Registrados, no registrados, total. El componente no registrado del índice se publica con rezago.

La misma inflación, dos encuadres



Fuente: INDEC, IPC nacional.

Observar un patrón no es explicar su causa

El gráfico muestra que el salario real cae cuando la inflación se acelera. Es una **regularidad descriptiva** muy útil. Pero el gráfico **no dice**:

- por qué los salarios corren detrás de los precios (indexación, rezagos de paritarias, poder de negociación);
- si la caída fue igual para todos los trabajadores o si el promedio esconde grupos muy distintos;
- qué habría pasado con otra política.

Para eso hacen falta **teoría**, otros datos y otras herramientas (las regresiones de la clase pasada, por ejemplo).

Preguntas para la discusión

1. ¿Qué vemos con mayor facilidad en la tabla?
2. ¿Qué patrones aparecen más rápido en el gráfico?
3. ¿Qué decisiones hubo que tomar antes de graficar las dos series?
4. ¿Qué **no** podemos concluir a partir del gráfico por sí solo?

Elegir un gráfico según la pregunta

La pregunta precede al gráfico

El error más común es arrancar por la geometría: "hagamos un gráfico de torta". El orden razonable es el inverso:

1. **¿Qué quiero saber?** Comparar, ver una evolución, una distribución, una relación, una composición.
2. **¿Con qué variables?** Numéricas o categóricas, cuántas categorías, cuántas observaciones, si hay tiempo o espacio.
3. **¿Para quién?** Uno mismo explorando, un equipo técnico, un decisor, el público general.
4. **¿Qué representación** permite hacer *esa* comparación con menos esfuerzo y menos riesgo de error?

El tipo de variable orienta, no determina

El salario es una variable numérica, pero con ella podemos preguntar:

- ¿cómo se **distribuye**? → histograma, ECDF
- ¿cómo **evolucionó**? → líneas
- ¿cómo se **relaciona** con la productividad? → dispersión
- ¿cómo **difiere** entre ramas? → boxplots, puntos

Misma variable, cuatro gráficos distintos.

Preguntas analíticas y representaciones (1/2)

Pregunta analítica	Representaciones	Ejemplo	Precaución
¿Cómo evoluciona una variable?	Líneas; puntos por período	Inflación mensual, salario real	Revisar orden temporal, frecuencia y cambios de escala
¿Qué categorías tienen valores mayores o menores?	Barras; puntos ordenados	Exportaciones o VAB por sector	Ordenar categorías; las barras empiezan en cero
¿Cómo se distribuye una variable?	Histograma; densidad; ECDF; boxplot	Distribución de salarios	Un resumen único oculta asimetrías, varias modas y colas
¿Cómo se relacionan dos variables?	Dispersión	Productividad y salarios	Asociación no es causalidad; cuidar solapamiento y extremos

Preguntas analíticas y representaciones (2/2)

Pregunta analítica	Representaciones	Ejemplo	Precaución
¿Cómo difieren las distribuciones entre grupos?	Boxplots; violines; densidades; puntos	Salarios por rama	Los resúmenes ocultan diferencias internas y tamaños de muestra
¿Cómo se compone un total?	Barras apiladas, agrupadas o separadas	Composición sectorial de las exportaciones	Las apiladas dificultan comparar segmentos sin base común
¿Cómo varía un fenómeno entre regiones?	Mapa temático; puntos o barras por región	Desempleo por provincia	Distinguir cantidades absolutas de tasas
¿Qué relación hay entre muchas variables?	Matriz de dispersión; mapa de correlaciones; facetas	Indicadores empresariales o de desarrollo	La complejidad dificulta la lectura; correlación no prueba causalidad

¿Cómo evoluciona una variable?

La línea conecta observaciones **ordenadas en el tiempo**: la pendiente se lee como ritmo de cambio.

- La **frecuencia** importa: mensual muestra el pico de 25,5% de dic-2023; un dato anual lo esconde.
- Si hay pocos períodos o faltantes, conviene marcar los **puntos** para no sugerir datos que no existen.
- Las marcas de contexto (cambios de gobierno, de metodología) ayudan, pero no explican.



¿Qué categorías tienen valores mayores o menores?





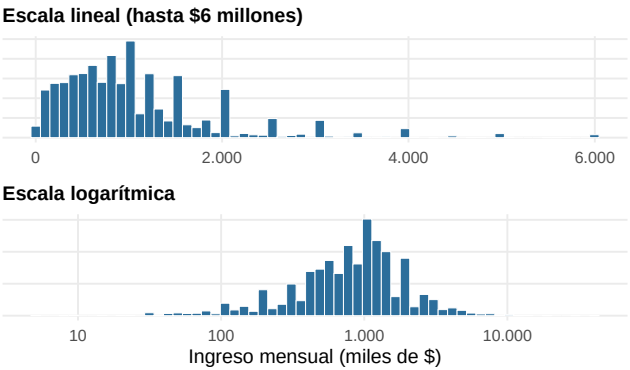
Los mismos datos, dos lecturas. Con categorías **nominales** (sin orden propio), ordenar por valor convierte la búsqueda en un ranking. Con categorías **ordinales** (tramos de edad, quintiles) se respeta su orden natural.

¿Cómo se distribuye una variable?

El ingreso laboral es muy **asimétrico**: muchos ingresos bajos y medios y una cola larga de ingresos altos.

- En escala lineal, la cola aplasta todo lo demás.
- En escala **logarítmica** se ve la forma del centro de la distribución.
- La media (1.104 mil) queda por encima de la mediana (900 mil): la cola la empuja.

Un único número no describe esta forma.



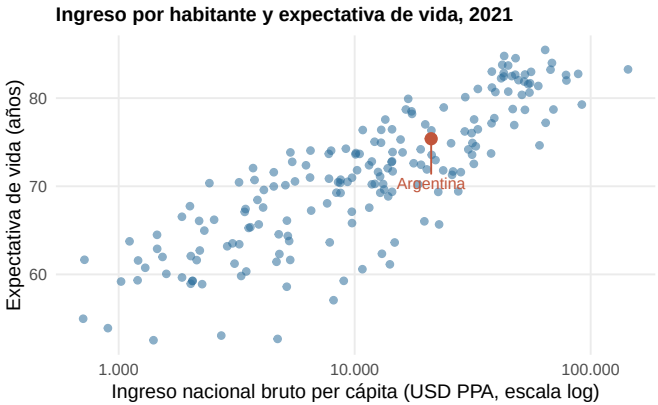
Fuente: EPH, INDEC, 1T2026.
Ocupados con ingreso de la ocupación principal > 0 (n = 15.448), ponderados.

¿Cómo se relacionan dos variables?

Cada punto es un país (189 en 2021). El diagrama de dispersión muestra la **forma** de la relación: positiva, fuerte y no lineal en niveles (por eso el eje x va en logaritmos).

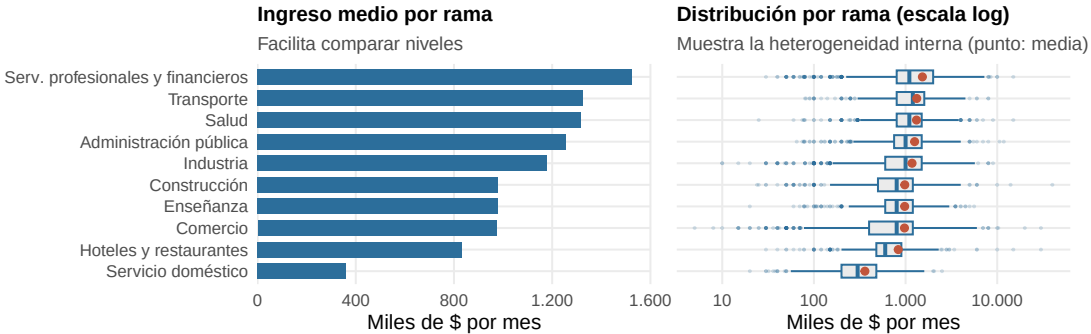
Lo que no muestra

Que el ingreso *cause* mayor expectativa de vida. Ambas pueden depender de terceras variables (instituciones, sistema de salud, educación) y la causalidad puede ir en ambos sentidos. Además: ¿qué pasa con los países que se alejan de la nube?



Fuente: Argendata (Fundar) en base a PNUD.

¿Cómo difieren las distribuciones entre grupos?



Fuente: EPH, INDEC, 1T2026.
Ocupados con ingreso de la ocupación principal > 0 (n = 15.448), ponderados.

Las barras responden "¿qué rama paga más *en promedio*?". Los boxplots responden "¿cuánto varía el ingreso *dentro* de cada rama y cuánto se solapan?". En casi todas las ramas hay trabajadores que ganan más que la mediana de las ramas "mejor pagas".

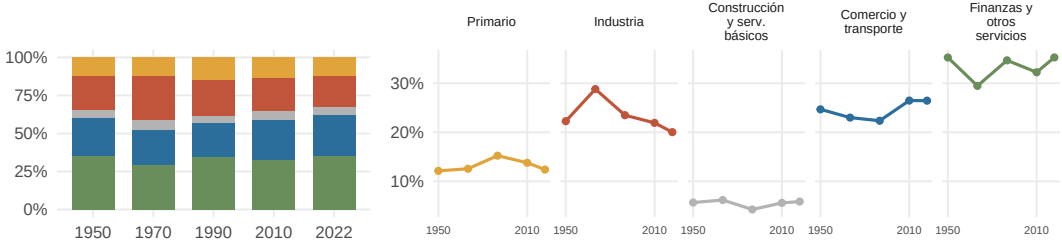
¿Cómo se compone un total?

Barras apiladas al 100%

Cuesta comparar los segmentos del medio

Un panel por sector, misma escala

Cada participación se compara contra una base común

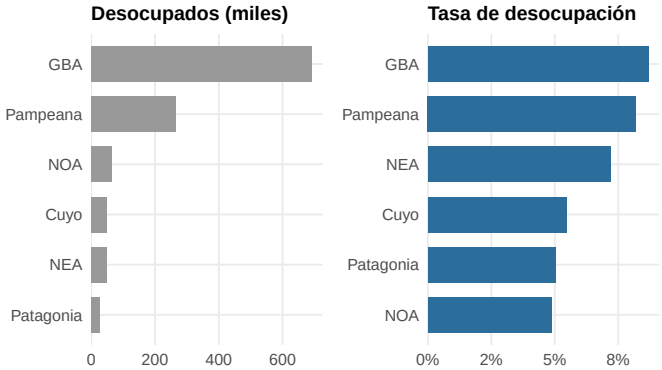


Participación en el VAB a precios constantes. Fuente: Argendata (Fundar).

En las apiladas, solo el segmento de abajo comparte una línea de base: para los demás hay que comparar longitudes que "flotan". Si la pregunta es "¿cuánto pesa cada sector?", las apiladas sirven; si es "¿cómo cambió cada sector?", conviene separarlos. Con exportaciones por sector vale exactamente lo mismo.

¿Cómo varía un fenómeno entre regiones?

El GBA concentra la mayor **cantidad** de desocupados porque concentra la mayor cantidad de población. Un mapa o un ranking de cantidades absolutas sería, sobre todo, un mapa de **población**. La **tasa** (desocupados sobre población activa) permite comparar regiones de distinto tamaño. En un mapa coroplético el problema se agrava: las provincias grandes en superficie ocupan más tinta aunque tengan poca población.



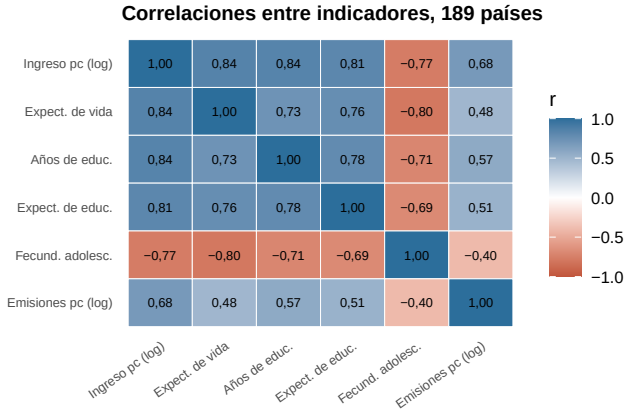
Fuente: EPH, INDEC, 1T2026 (31 aglomerados urbanos).

¿Qué relación hay entre muchas variables?

Con muchas variables, mirar todos los pares de dispersión es inmanejable. Un **mapa de correlaciones** resume cada par en un número y un color.

- Sirve para **explorar**: qué variables van juntas, cuáles son redundantes.
- Pierde la forma de cada relación (Anscombe otra vez): una correlación alta puede venir de unos pocos puntos.
- Ninguna celda dice qué causa qué.

Ingreso y emisiones van en logaritmos.



Fuente: Argendata (Fundar), 2021.

Cuatro criterios para elegir

1. **La pregunta precede al gráfico.** Antes de elegir una geometría, definir qué comparación o qué patrón se quiere estudiar. Si no se puede decir en una frase qué debería ver el lector, todavía no es momento de graficar.
2. **El tipo de variable orienta, pero no determina.** Una variable numérica puede mirarse por su distribución, su evolución o su relación con otra.
3. **No existe un gráfico universalmente mejor.** Depende de qué hay que comparar y de quién lo va a usar. Un boxplot es claro para un analista y críptico para un público general.
4. **Las alternativas se evalúan por lo que permiten ver.** Un promedio facilita comparar niveles; una distribución deja ver la heterogeneidad. Ninguna es "la correcta": responden preguntas distintas.

Para pensar antes de seguir

¿Usarían el mismo gráfico para comparar salarios **promedio** entre sectores y para estudiar la **desigualdad** dentro de cada sector? ¿Y la misma representación para mostrar el **volumen** exportado y la **participación** de cada sector en el total?

Dos objetivos: comunicar y explorar

Dos propósitos distintos

Comunicar

Transmitir un **resultado**, una conclusión o un argumento a un público determinado. Parte de una pregunta relativamente definida: el analista ya sabe qué encontró y quiere que el lector lo vea.

Ejemplo: el gráfico de una nota económica que muestra que el salario real todavía no recuperó el nivel de 2017.

Explorar

Investigar los datos: detectar patrones inesperados, generar hipótesis, entender su estructura. No parte de una conclusión: la conclusión, si aparece, es el resultado.

Ejemplo: comparar distribuciones de ingresos por edad, sexo, rama y región para ver qué diferencias merecen una investigación posterior.

El mismo tipo de gráfico (una línea, un boxplot) puede usarse con los dos propósitos. Lo que cambia es la **pregunta**, el **usuario** y las **decisiones** con que se construye.

Visualización para comunicar

Características frecuentes:

- Selecciona la evidencia relevante para sostener una conclusión.
- Establece una **jerarquía de lectura**: qué se ve primero.
- Reduce lo que distrae del mensaje principal.
- Usa **títulos informativos** (dicen la conclusión, no el tema), anotaciones y contexto.
- Explicita unidades, fuente, período y definiciones.
- Le indica al lector **qué comparación** hacer y por qué importa.

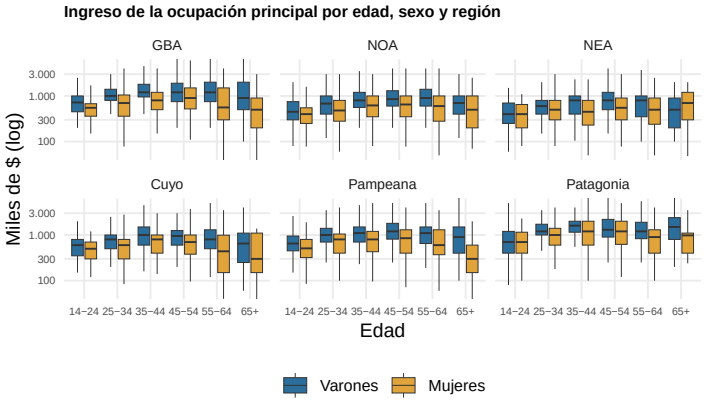


Visualización para explorar

Características frecuentes:

- Compara muchos grupos o variables a la vez.
- Facilita detectar anomalías, observaciones influyentes y heterogeneidad.
- Suele combinar varias vistas complementarias.
- Es flexible: se rehace muchas veces a medida que cambian las hipótesis.
- Prioriza la **amplitud** de la información por sobre la simplicidad del mensaje.

Este gráfico no tiene un mensaje: tiene **preguntas**. ¿La brecha crece con la edad? ¿Es igual en todas las regiones?



Fuente: EPH, INDEC, 1T2026. Ocupados con ingreso > 0, ponderados.

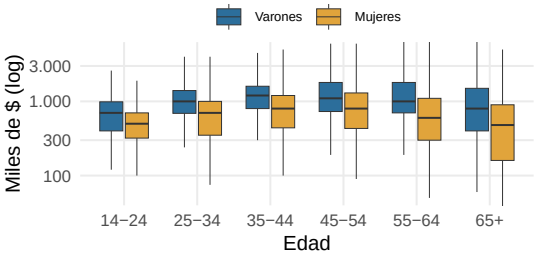
Comunicación y exploración, lado a lado

Dimensión	Comunicación	Exploración
Pregunta inicial	Definida, orientada a un resultado	Abierta; puede cambiar durante el análisis
Usuario principal	Lector o decisor que necesita comprender un resultado	Analista que investiga los datos
Selección de información	Focalizada en la evidencia relevante	Amplia, para buscar patrones y alternativas
Complejidad	Reducir la carga de lectura sin perder lo necesario	Acepta más densidad si facilita la investigación
Interacción	Útil a veces, no siempre necesaria	Filtros, comparaciones, búsqueda de anomalías
Producto típico	Gráfico para un informe, una nota o una presentación	Gráficos de diagnóstico, distribuciones, vistas múltiples

De la exploración a la comunicación

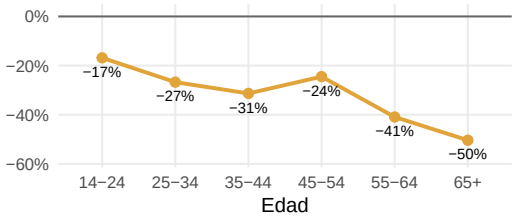
Exploración: todo el país

Distribuciones completas, sin mensaje



Comunicación: la brecha es mayor entre los de más edad

Ingreso medio de las mujeres respecto de los varones



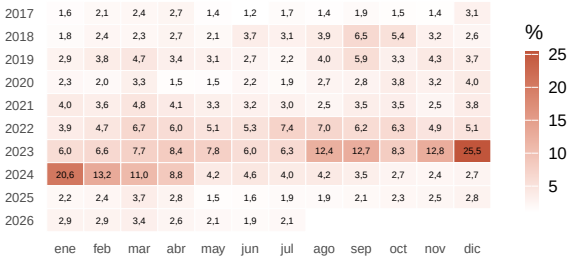
Fuente: EPH, INDEC, 1T2026.
Ocupados con ingreso de la ocupación principal > 0 (n = 15.448), ponderados.

La exploración sugirió un patrón; el gráfico comunicacional lo **aísla**: una sola medida, una referencia (el cero), etiquetas con los valores y un título que dice la conclusión. Se ganó claridad y se perdió información (la dispersión dentro de cada grupo): es una decisión, y hay que poder justificarla.

Mismo dato, dos destinos: la inflación

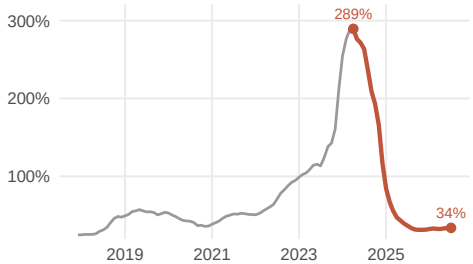
Exploración: inflación mensual, mes por mes

¿Hay estacionalidad? ¿Cuándo empezó cada aceleración?



Comunicación: la inflación interanual bajó de 289% a 34%

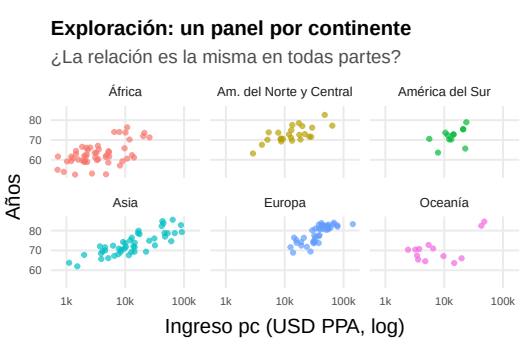
Variación interanual del IPC, hasta jul−2026

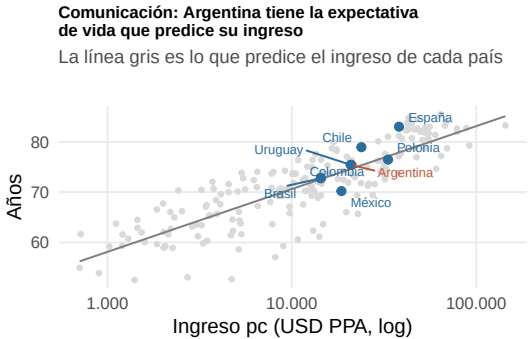


Fuente: INDEC, IPC nacional.

La grilla de la izquierda muestra **todos** los datos y deja que el analista busque: meses que se repiten, quiebres, el salto de diciembre de 2023. Es difícil de leer para un público general. La línea de la derecha elige **una medida** (la interanual, más estable), marca dos puntos y pone la conclusión en el título.

Mismo dato, dos destinos: ingreso y expectativa de vida





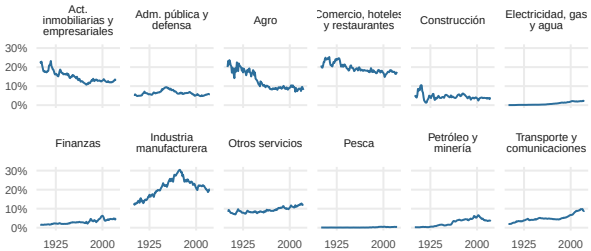
Fuente: Argendata (Fundar) en base a PNUD, 2021.

La exploración separa por continente para ver si la relación cambia de región en región. La comunicación vuelve a juntar todo, **atenúa** los demás países en gris, marca a la Argentina y a un grupo de **comparación** elegido a propósito, y convierte la distancia a la línea en un número que se puede decir en voz alta.

Mismo dato, dos destinos: la estructura productiva

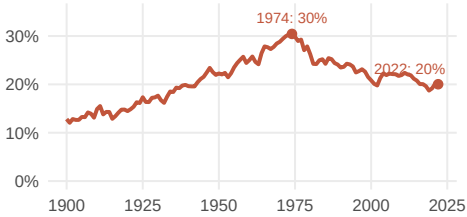
Exploración: los 12 sectores, misma escala

¿Qué sectores ganaron y perdieron peso?



Comunicación: la industria pesa 10 puntos menos que en 1974

Industria manufacturera, % del VAB



VAB a precios constantes. Fuente: Argendata (Fundar).

Los paneles chicos (*small multiples*) son una herramienta típica de exploración: muchas series, misma escala, sin elegir ganador. El gráfico comunicacional se queda con **una** serie y **dos** puntos. Ojo: el eje desde cero y el período completo son decisiones que hacen honesta la comparación, no detalles.

No son categorías rígidas

- Una visualización exploratoria puede convertirse en la **base** de un gráfico comunicacional (lo que acabamos de hacer).
- Un gráfico estático también sirve para explorar, y un tablero interactivo puede usarse para comunicar.
- Un mismo gráfico puede ser exploratorio para quien lo hizo y comunicacional para el equipo que lo recibe.
- La diferencia central es el **propósito y el uso esperado**, no la tecnología ni el tipo de gráfico.

Un riesgo frecuente

Llevar un gráfico exploratorio tal cual a una presentación: diez paneles, sin título informativo, sin fuente, con la leyenda que generó el software. El lector no sabe qué mirar. El problema contrario también existe: explorar solo con gráficos "limpios" de promedios y nunca ver la distribución.

Discusión: desigualdades laborales

Pregunta

Consigna

Si tenemos datos sobre **empleo, salarios, edad, género y sector productivo**, ¿qué gráficos usaríamos para estudiar desigualdades laborales?

Primero, **traducir** la pregunta general en preguntas analíticas. Por ejemplo:

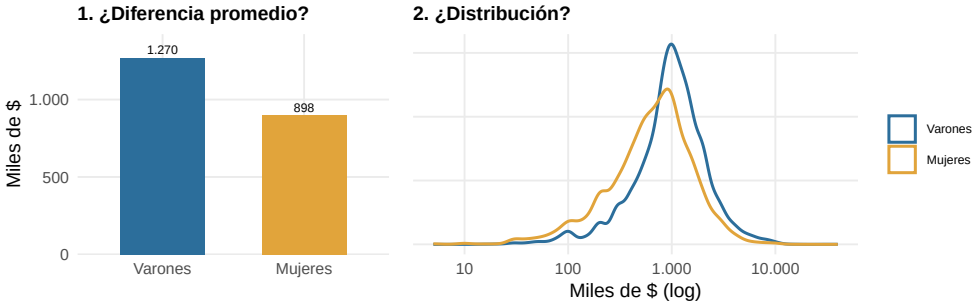
- ¿Cuál es la diferencia salarial promedio entre grupos?
- ¿Cómo se distribuyen los salarios dentro de cada grupo?
- ¿Las diferencias cambian entre sectores o grupos de edad?
- ¿Qué subgrupos merecen investigarse con más detalle?

Para cada una:

- ¿qué variables y de qué tipo?
- ¿qué gráfico la responde mejor?
- ¿ese gráfico sirve para explorar, para comunicar o para las dos cosas?

No hay una única respuesta correcta: el objetivo es hacer explícitos los **criterios** de elección.

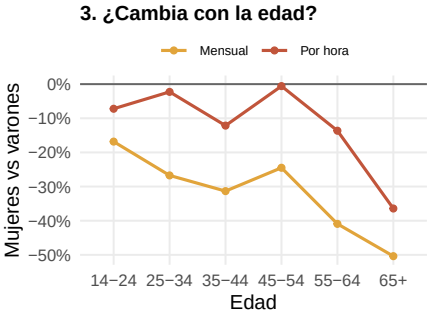
Cuatro preguntas, cuatro gráficos

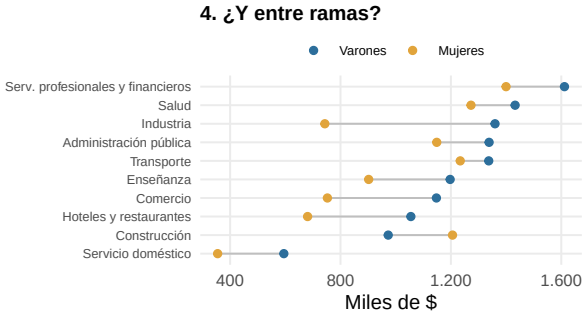


Fuente: EPH, INDEC, 1T2026.
Ocupados con ingreso de la ocupación principal > 0 (n = 15.448), ponderados.

Misma base, preguntas distintas. El promedio (1) da un número fácil de comunicar: las mujeres ganan 29% menos por mes. La distribución (2) muestra *dónde* está la diferencia: la curva de las mujeres está corrida hacia la izquierda y tiene más masa en ingresos bajos.

Cuatro preguntas, cuatro gráficos (continuación)





Fuente: EPH, INDEC, 1T2026.
Ocupados con ingreso de la ocupación principal > 0 (n = 15.448), ponderados. Ingreso por hora: ingreso mensual / (horas semanales x 4,3).

El 3 muestra una **decisión de definición**: la brecha *mensual* es mayor que la *horaria*, porque parte de la diferencia refleja menos horas trabajadas. ¿Cuál mostrar depende de la pregunta. El 4 muestra que la brecha existe en casi todas las ramas, pero con tamaños muy distintos: es un buen candidato para seguir explorando.

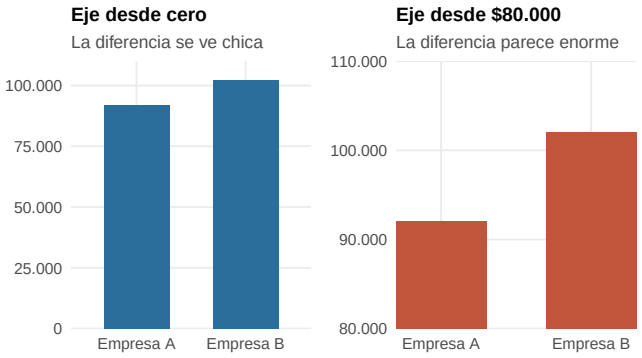
Buenas prácticas y errores frecuentes

Ejes y escalas: las barras empiezan en cero

En una barra, el lector compara **longitudes**. Si el eje empieza en 80.000, la barra de B parece casi el doble de larga que la de A, aunque la diferencia sea del 11%.

Pregunta para discutir

¿Qué cambia al mostrar una diferencia salarial de $10.000 en una escala de 0 a $100.000 y en otra de $80.000 a $110.000? ¿Hay alguna pregunta para la cual el segundo encuadre sea razonable?



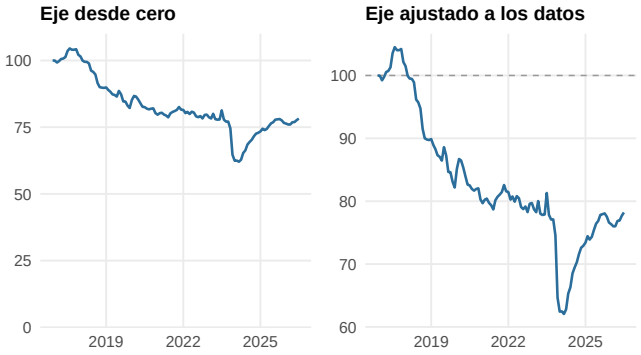
Datos simulados con fines ilustrativos.

Ejes y escalas: en las líneas, depende

En una línea se lee la **posición** y la **pendiente**, no una longitud desde cero. Por eso un eje que no empieza en cero **no es necesariamente incorrecto**:

- para ver variaciones de pocos puntos, hacer zoom es necesario;
- con el eje desde cero, toda la dinámica del salario real queda aplastada.

El riesgo está en el **encuadre**: un zoom extremo puede convertir una oscilación menor en un "derrumbe". Conviene dejar visible una referencia (el 100, un nivel previo).



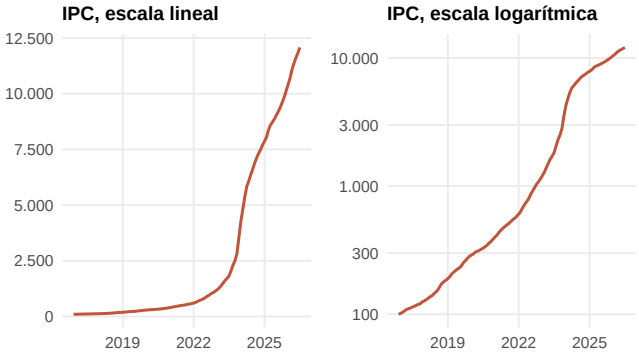
Índice de salario real (dic−2016 = 100). Fuente: INDEC.

Ejes y escalas: la escala logarítmica

En escala lineal, la misma distancia vertical es la misma **diferencia absoluta**. En escala logarítmica, es la misma **tasa de cambio**.

- El IPC se multiplicó por 121: en lineal, los primeros años parecen planos aunque la inflación ya rondaba el 25-50% anual.
- En log, la pendiente es la tasa de inflación: se ve la aceleración de 2023 y la desaceleración posterior.

Cuidado: en log las distancias ya no se leen como diferencias. Hay que avisarle al lector.

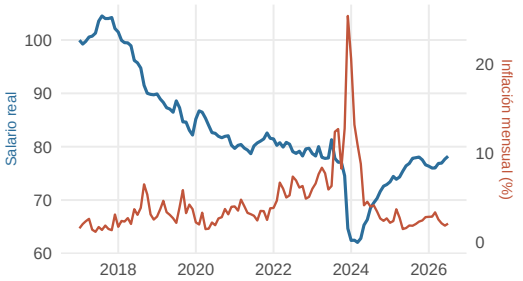


IPC nacional (dic−2016 = 100). Fuente: INDEC.

Ejes y escalas: los ejes dobles

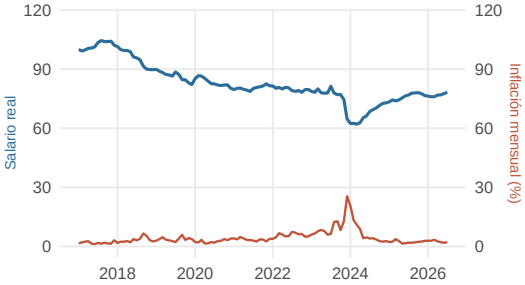
Versión 1

Las series parecen cruzarse y moverse en espejo



Versión 2

Mismos datos: la inflación parece irrelevante



Con dos ejes, la escala de cada uno es **arbitraria**: elegirlas permite hacer que las series se crucen, se separen o "se sigan". Los cruces y los paralelismos no significan nada. Alternativas: dos paneles alineados en el tiempo, indexar ambas series a una base común o un diagrama de dispersión de una contra otra.

Unidades, denominadores y comparabilidad

- Diferenciar **valores absolutos**, porcentajes, tasas e índices: “subió 5” no dice si son pesos, puntos porcentuales o puntos de índice.
- Explicitar el **denominador** de una proporción y el universo: ¿desocupados sobre población total o sobre población activa? ¿31 aglomerados o todo el país?
- No comparar magnitudes con unidades o períodos distintos sin aclararlo (mensual vs anual, miles vs millones).
- En mapas, no confundir **cantidades** con **tasas**.
- Indicar si los valores son **nominales o reales**: con alta inflación, casi cualquier serie nominal “crece”.

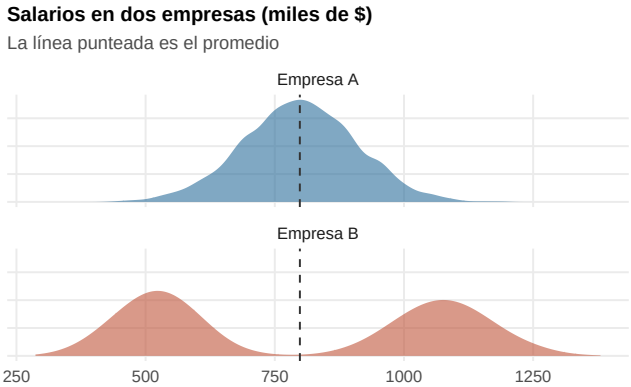


Agregación: el mismo promedio, dos realidades

Las dos empresas pagan un salario promedio de **800 mil**. Una tabla de promedios las mostraría iguales.

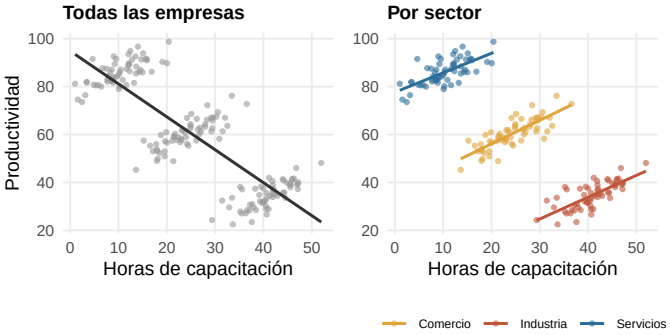
- En A, casi todos cobran cerca del promedio.
- En B hay dos grupos (operarios y profesionales) y **casi nadie** cobra el promedio.

Los promedios ocultan **dispersión**, **asimetría** y **subgrupos**. Antes de comparar promedios conviene mirar la distribución.



Agregación: la paradoja de Simpson

Una asociación observada en datos **agregados** puede cambiar o **invertirse** al mirar subgrupos. En el ejemplo, con todas las empresas juntas, más capacitación se asocia con **menos** productividad (pendiente -1,37). Dentro de cada sector, la relación es **positiva** (0,91). ¿Por qué? Los sectores que más capacitan son los de menor productividad de partida. La **composición** genera la pendiente agregada.



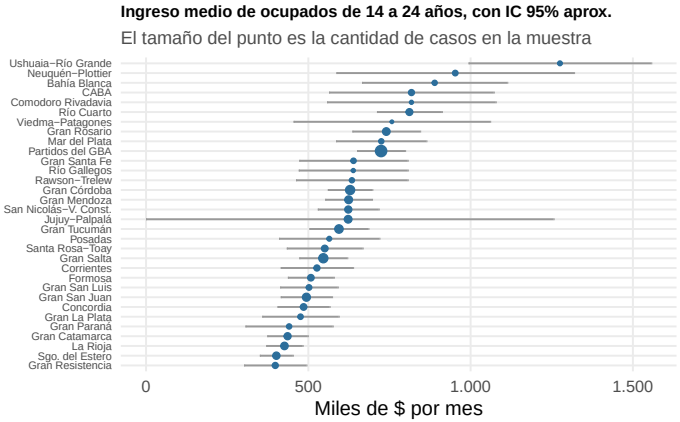
Datos simulados con fines ilustrativos.

Incertidumbre y tamaño de muestra

Cada punto es el ingreso medio de los ocupados de 14 a 24 años en un aglomerado de la EPH. Los intervalos son muy distintos porque las **muestras** son muy distintas (entre 8 y 153 casos).

- Con muestras chicas, el ranking es **inestable**: muchas diferencias no son distinguibles del azar.
- Cuando la pregunta lo requiere, mostrar la **incertidumbre** en vez de presentar estimaciones como valores exactos.

Intervalo aproximado: media $\pm$ 1,96 $\cdot$ desvío / $\sqrt{n}$, sin considerar el diseño muestral.



Fuente: EPH, INDEC, 1T2026.

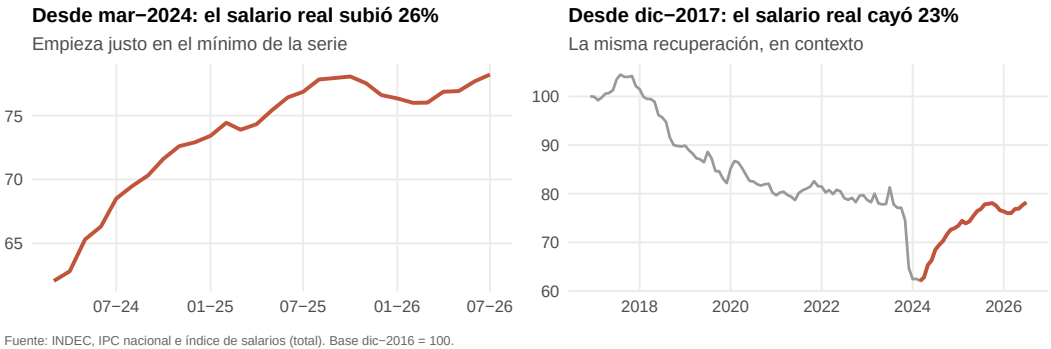
Relaciones, causalidad y valores atípicos

- Una **correlación no prueba** que una variable cause la otra. Dos series con tendencia (el IPC y casi cualquier variable nominal) siempre parecen "relacionadas".
- Un **valor atípico** puede ser un error de carga, un caso genuino o la señal de un fenómeno que merece investigarse. No se borra sin mirarlo, y si se excluye se dice.
- Las muestras chicas vuelven **inestables** las comparaciones.
- No omitir observaciones o períodos sin justificarlo.

Antes de leer una relación en un gráfico

1. ¿Hay una tercera variable que mueva a las dos?
2. ¿Cuántas observaciones hay y cuánto pesan los extremos?
3. ¿El patrón se mantiene en subgrupos (Simpson)?
4. ¿Cambia si cambio el período o la muestra?

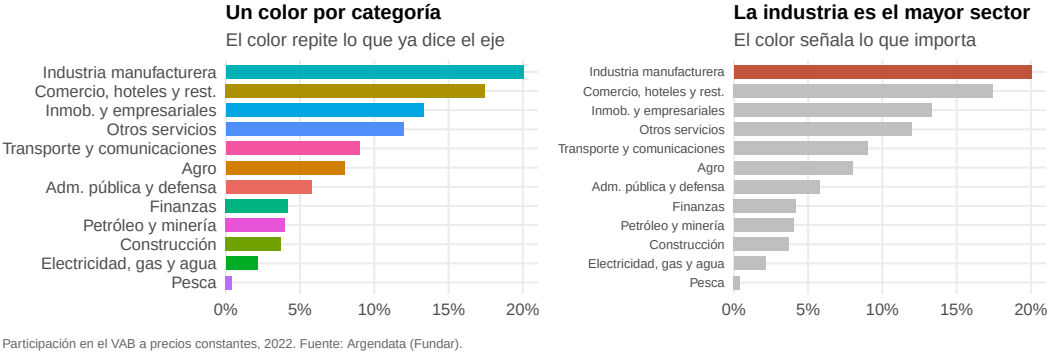
Elegir el período cambia el mensaje



Fuente: INDEC, IPC nacional e índice de salarios (total). Base dic−2016 = 100.

Ambos gráficos son **correctos**. Lo que cambia es la ventana: elegir el punto de partida es elegir el mensaje. Si se recorta un período, hay que poder justificar por qué (una pregunta que lo requiere, un cambio de metodología), y decirlo.

Color: una función, no una decoración



Participación en el VAB a precios constantes, 2022. Fuente: Argendata (Fundar).

El color tiene que **codificar algo**: una categoría que no está en otro lado, un valor, un énfasis. Mantener el mismo significado en todos los gráficos de un informe (si "mujeres" es naranja, que lo sea siempre) y no depender solo del color: alrededor de 1 de cada 12 varones tiene alguna forma de daltonismo.

Etiquetas y contexto

Lo que no puede faltar

- **Título** informativo (en un gráfico para comunicar, la conclusión).
- **Unidades**: pesos corrientes o constantes, %, puntos, índice con su base.
- **Período** y frecuencia.
- **Fuente** de los datos.
- **Notas metodológicas** pertinentes: universo, filtros, ponderación, deflactor.

Lo que suele sobrar

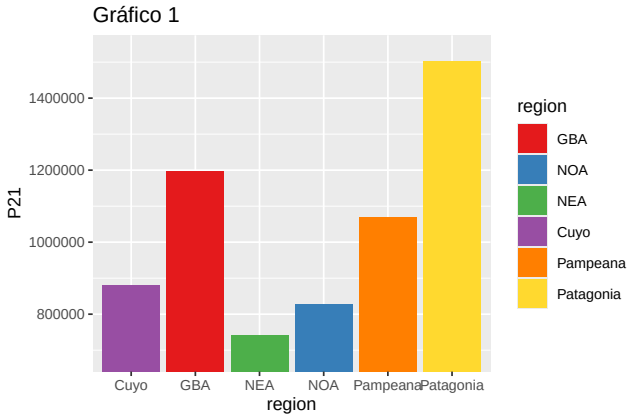
- Leyendas cuando las categorías ya están en el eje o pueden etiquetarse directo.
- Una etiqueta sobre cada punto de una serie larga.
- Grillas gruesas, fondos, sombras, efectos 3D.
- Elementos que compiten con la información principal.

Criterio transversal

Estas pautas **no son reglas automáticas**. Un eje que no empieza en cero, una escala log o un recorte de período pueden ser la mejor decisión. La evaluación siempre considera la pregunta, los datos y la interpretación que el gráfico puede producir.

Taller de selección y crítica

Caso 1: ¿qué revisarían de este gráfico?



En grupos, cinco minutos:

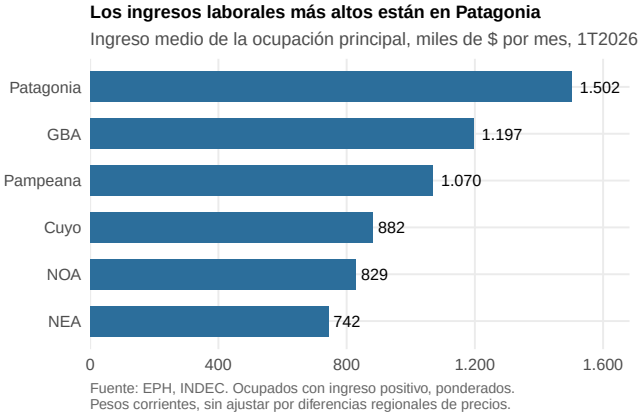
1. ¿Qué interpretación podría inducir?
2. ¿Qué decisiones revisarían?
3. ¿Cómo lo rediseñarían? ¿Para qué pregunta?

Pista: hay al menos cinco problemas, y ninguno es "técnico".

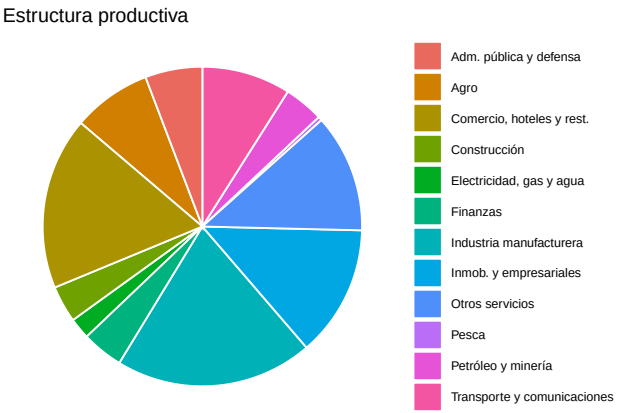
Caso 1: una posible reformulación

- **Eje desde cero**: la diferencia entre regiones era real, pero el eje truncado la multiplicaba.
- **Ordenado por valor**, no alfabético.
- **Un solo color**: el color no codificaba nada que no dijera el eje.
- Sin leyenda redundante.
- **Título informativo**, unidades y nombres legibles en lugar de los nombres de las columnas.
- **Fuente y notas**: universo, ponderación, período.

¿Alcanza el promedio? Si la pregunta es por desigualdad entre regiones, quizás no (y la Patagonia tiene precios más altos: ¿nominal o real?).



Caso 2: ¿qué revisarían de este gráfico?



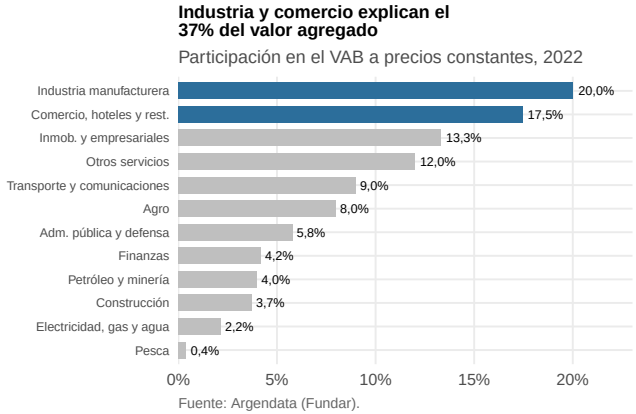
1. ¿Cuál es el tercer sector más grande? ¿Cuánto pesa?
2. ¿Pesa más el agro o la construcción?
3. ¿Qué hay que hacer para responder? (Ir y volver entre la torta y la leyenda.)
4. ¿Qué pregunta responde bien este gráfico?

Pista: el ojo compara mal **ángulos y áreas**, y doce colores no se distinguen entre sí.

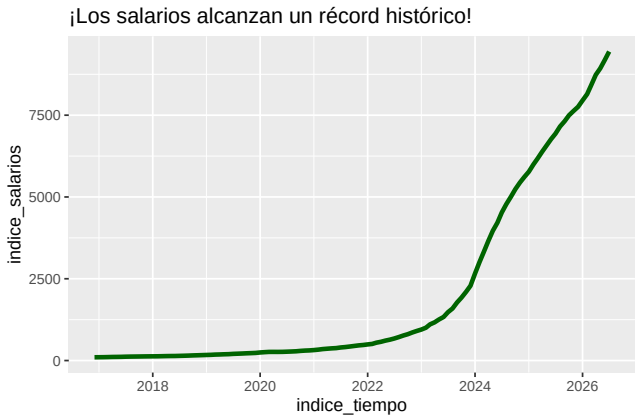
Caso 2: una posible reformulación

- **Barras ordenadas**: comparar longitudes sobre una base común es mucho más preciso que comparar ángulos.
- **Etiquetas directas** con el porcentaje: desaparece la leyenda y el ir y venir.
- **Color con función**: resalta los dos sectores que sostienen el título.
- Título que dice qué mirar; unidades, año y fuente.

¿Cuándo sirve una torta? Con dos o tres partes y una pregunta del tipo "¿es más o menos de la mitad?".



Caso 3: ¿qué revisarían de este gráfico?



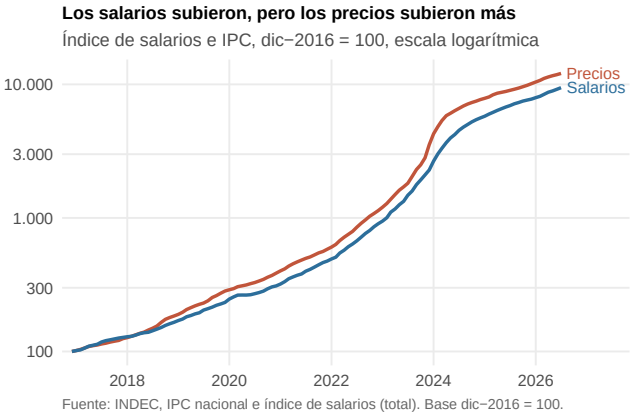
1. ¿El título es falso?
2. ¿Qué haría falta para saber si a los trabajadores les alcanza más o menos el salario?
3. ¿Qué es "indice_salarios"? ¿En qué unidad está? ¿Desde cuándo?
4. ¿Hay algún mes en el que este gráfico *no* mostraría un récord?

Pista: con inflación alta, casi cualquier serie en pesos corrientes marca récords todos los meses.

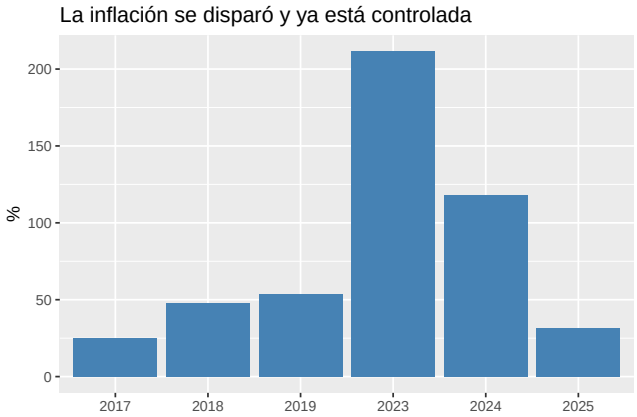
Caso 3: una posible reformulación

- **Comparar contra los precios**: salarios e IPC en la misma base (dic-2016 = 100).
- **Escala logarítmica**: con series que se multiplican por 100, la distancia vertical entre las líneas es la brecha porcentual.
- **Etiquetas directas** en lugar de leyenda.
- Título que dice la comparación relevante, no un dato que siempre es cierto.

Otra opción, la del bloque 1: graficar directamente el **salario real** (salario / IPC).



Caso 4: ¿qué revisarían de este gráfico?

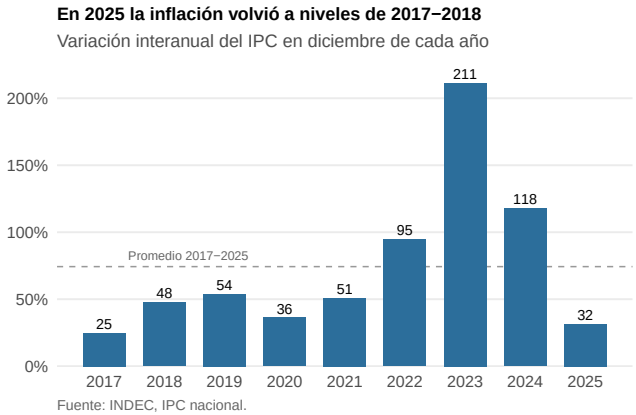


1. Miren el eje horizontal con atención. ¿Qué falta?
2. ¿Cambia la historia si aparecen los años que faltan?
3. ¿Qué mide cada barra: inflación mensual, anual, promedio del año?
4. ¿"Controlada" respecto de qué?

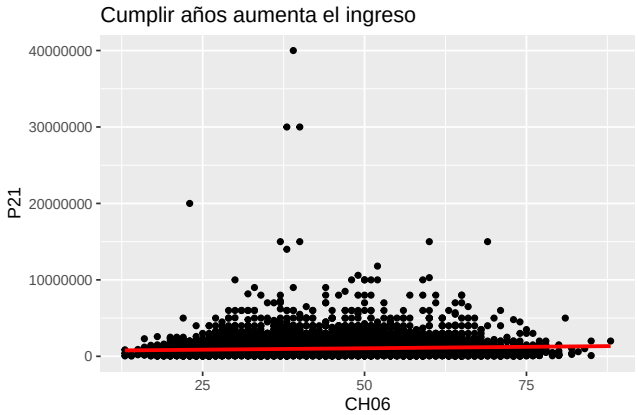
Pista: un eje de **categorías** pone todo a la misma distancia, aunque entre dos barras haya tres años.

Caso 4: una posible reformulación

- **Todos los años**: la inflación no "se disparó" en 2023; venía subiendo desde 2020. Omitir años sin decirlo es elegir el mensaje.
- **Tiempo como tiempo**: cada año en su lugar, sin saltos ocultos.
- **Qué se mide**, en el subtítulo: variación interanual de diciembre.
- **Una referencia**: el promedio del período ayuda a juzgar si el último dato es bajo o alto.
- Título descriptivo y verificable.



Caso 5: ¿qué revisarían de este gráfico?



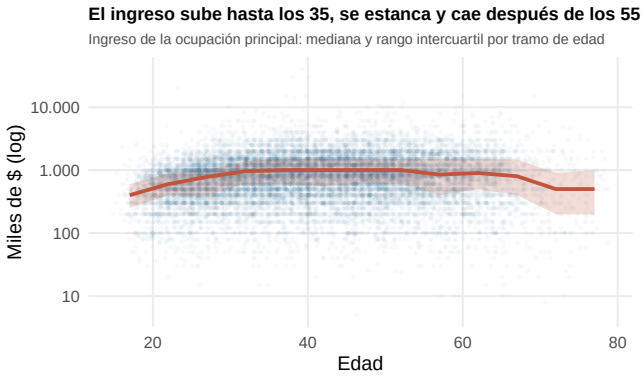
1. Hay 15.448 personas en el gráfico. ¿Cuántas se ven?
2. ¿Dónde está la mayoría de los datos? ¿Qué ocupa casi todo el espacio?
3. ¿La recta describe bien lo que pasa a los 20, a los 45 y a los 70 años?
4. ¿El título describe o atribuye una causa?

Pista: *sobreploteo* (puntos encimados), escala dominada por unos pocos valores extremos y un modelo impuesto de antemano.

Caso 5: una posible reformulación

- **Transparencia** en los puntos: se ve dónde se concentran.
- **Escala logarítmica**: los ingresos altos dejan de aplastar al resto.
- En lugar de una recta, **mediana y rango intercuartil** por tramo de edad: la relación no es lineal.
- Título **descriptivo**: la edad no "causa" ingreso; resume experiencia, cohorte, tipo de empleo, jubilación.

Se ve además que los ingresos declarados se **redondean** (las líneas horizontales en $500.000, $1.000.000): otro hallazgo de la exploración.



Cierre

Tres preguntas para cualquier visualización

1. **¿Qué quiero mostrar o investigar?**

   La pregunta define la comparación. Si no la puedo decir en una frase, el gráfico va a intentar decir todo y no va a decir nada.

2. **¿Qué comparación permite realizar este gráfico?**

   Niveles, cambios, formas, relaciones, partes de un total. Cada geometría hace fácil una comparación y difícil otras.

3. **¿Qué interpretación equivocada podría producir y qué información hace falta para evitarla?**

   Escalas, denominadores, promedios que esconden distribuciones, períodos recortados, correlaciones leídas como causas.

La idea con la que nos vamos

Una buena visualización no es la más sofisticada: es la que representa los datos de forma **adecuada para una pregunta y un uso determinados**.

Síntesis y próximas clases

Lo que vimos

- Visualizar es una decisión **analítica**.
- El gráfico se elige por la **pregunta**, no por el tipo de variable solamente.
- **Comunicar** y **explorar** piden decisiones distintas sobre los mismos datos.
- Ejes, escalas, unidades, promedios, períodos y colores pueden cambiar la interpretación.
- Todo gráfico tiene **limitaciones**: parte del trabajo es saber cuáles.

Lo que sigue

- **Clase 2**: construir estas representaciones en R con `ggplot2`, la gramática de gráficos.
- **Clase 3**: diagnosticar y rediseñar gráficos para comunicar y para explorar.

Para la próxima

Traer un gráfico económico de un diario, un informe o una red social y responder sobre él las tres preguntas del cierre.

Bibliografía

Lectura crítica y evidencia

- Cairo, A., *The Truthful Art*. Evidencia, lectura crítica y comunicación visual.
- Cairo, A., *How Charts Lie*. Cómo las decisiones de representación favorecen interpretaciones equivocadas.
- Tufte, E. R., *The Visual Display of Quantitative Information*. Referencia clásica sobre integridad gráfica.

Elección, comunicación e implementación

- Wilke, C. O., *Fundamentals of Data Visualization*. Elección de gráficos, escalas, distribuciones e incertidumbre (libre en `clauswilke.com/dataviz`).
- Nussbaumer Knaflic, C., *Storytelling with Data*. Comunicación de resultados y selección de evidencia.
- Wickham, H., *ggplot2: Elegant Graphics for Data Analysis*. Para la clase 2.
- Anscombe, F. J. (1973), *Graphs in Statistical Analysis*, The American Statistician.